

Università degli Studi di Torino
SCUOLA DI SCIENZE DELLA NATURA
Corso di Laurea Magistrale in Informatica



Tesi di Laurea Magistrale

**Design, ingegnerizzazione e realizzazione di
un sistema di dialogo basato su LLM nel
dominio delle tecnologie assistive**

RELATORE

Prof. Alessandro Mazzei

CO-RELATORI

Pier Felice Balestrucci

Michael Oliverio

CANDIDATO

Stefano Vittorio Porta

859133

Anno Accademico 2023/2024

Dichiarazione di Originalità

Dichiaro di essere responsabile del contenuto dell'elaborato che presento al fine del conseguimento del titolo, di non avere plagiato in tutto o in parte il lavoro prodotto da altri e di aver citato le fonti originali in modo congruente alle normative vigenti in materia di plagio e di diritto d'autore. Sono inoltre consapevole che nel caso la mia dichiarazione risultasse mendace, potrei incorrere nelle sanzioni previste dalla legge e la mia ammissione alla prova finale potrebbe essere negata.

Ringraziamenti

Todo

Abstract

Nel campo delle tecnologie assistive, l'accessibilità di contenuti complessi – come grafi, diagrammi e mappe concettuali – rappresenta una sfida significativa, soprattutto per utenti con disabilità visive. Questa tesi si propone di realizzare un sistema di dialogo basato su Large Language Models capace di “tradurre” tali contenuti in interazioni testuali comprensibili, consentendo agli utenti di esplorare e comprendere in modo approfondito le informazioni racchiuse in forme grafiche.

In particolare, sono state svolte ricerche e sperimentazioni su diverse tecniche di Natural Language Understanding (rule-based e neurali) per valutarne l'accuratezza e la robustezza. Sul piano ingegneristico è stata progettata un'architettura modulare che integra pipeline di elaborazione e retrieval di dati, garantendo sia la scalabilità sia la flessibilità del sistema.

Parole chiave

NLU mediante classificazione, data annotation, data augmentation, data retrieval, NLG basata su LLM, software engineering

Indice

1	Introduzione	1
1.1	Contesto	1
1.2	Motivazioni e obiettivi della tesi	1
1.3	Struttura del documento	3
2	Natural Language Understanding	5
2.1	Come AIML gestisce la comprensione	5
2.1.1	Struttura di un chatbot AIML	5
2.1.2	Criticità e limiti di AIML	9
2.2	Classificazione con LLM	10
2.2.1	Dataset di training	10
2.2.2	Etichettatura automatica del dataset	12
2.2.3	Nuove classi e etichettatura manuale	15
2.2.4	Data Augmentation	18
2.2.5	Fine-tuning	20
2.2.6	BERT	21
2.2.7	Implementazione	22
2.2.8	Valutazione e performance	29
2.3	Riconoscimento delle entità	35
2.3.1	Approcci e metodologie nel NER	36
2.3.2	Slot Filling	37
2.3.3	Annotazione dei dati con Docciano	38
2.3.4	Implementazione con spaCy	39
2.3.5	Valutazione e performance	42
2.4	Conclusioni	43
3	Retrieval-Augmented Generation	45
3.1	Data Retrieval	45
3.1.1	Basi di conoscenza strutturate	46
3.1.2	Corpora non testuali	48
3.1.3	API e servizi esterni	49
3.2	Generazione di risposte tramite LLM	50
3.2.1	Parafrasi	51
3.2.2	Prompting	52
3.3	Qualità delle risposte	55
3.3.1	Selezione dei modelli	55
3.3.2	Raccolta delle domande	56
3.3.3	Generazione delle risposte	56
3.3.4	Annotazione manuale	57
3.3.5	Annotazione automatica	59
3.3.6	Risultati	59
3.3.7	Conclusioni	64
4	Ingegnerizzazione	67
4.1	Panoramica del sistema	68
4.2	Compilatore	69
4.2.1	Pipeline	69
4.3	Runner	73
4.3.1	Resource Dependency Discovery	73
4.3.2	Flow	74
4.4	Osservazioni e sviluppi futuri	77
	Bibliografia	79

1 Introduzione

1.1 Contesto

Quando si pensa alla preistoria, viene facile immaginare un mondo ostile e primordiale, in cui la lotta per la sopravvivenza era una sfida quotidiana. È poco diffusa la conoscenza che invece, proprio in quell'epoca lontanissima, sono nati i primi gesti di **mutuo soccorso** [1].

Anche le tracce archeologiche più antiche, dai resti di individui guariti da gravi fratture alle sepolture rituali, raccontano di una comunità in cui chi non poteva più procacciarsi il cibo o difendersi dai pericoli non veniva abbandonato, ma curato e sostenuto dagli altri membri del gruppo.

Questa solidarietà “preistorica” non era una semplice parentesi, ma ha costituito un seme che, millennio dopo millennio, ha continuato a germogliare fino ai giorni nostri.

Il fatto che i nostri antenati prestassero soccorso a chi era ferito o portatore di disabilità è un **segno distintivo dell'umanità** [2]. Con il passare del tempo, quella che poteva essere un'assistenza spontanea e basata sull'istinto si è trasformata in strutture sociali sempre più complesse, in cui il concetto di “prendersi cura” è diventato uno degli elementi chiave per la sopravvivenza della comunità. Da semplici gesti pratici si è passati a forme di medicina primitiva, fino a sviluppare ruoli specifici, come il “guaritore” o lo sciamano, che si prendevano cura dei membri più vulnerabili.

Volgendo lo sguardo al mondo d'oggi, ci troviamo in un'epoca in cui la tecnologia ha completamente rivoluzionato il modo di fornire sostegno a chi ne ha bisogno. Pensiamo, ad esempio, a quanto sono diventati comuni ausili come le *protesi robotiche*, i *sensori intelligenti*, gli **screenreader** per chi ha difficoltà visive o i software di **riconoscimento vocale** avanzati. Questa evoluzione tecnologica ha aperto la strada a una concezione dell'assistenza sempre più personalizzata e, soprattutto, in grado di ridurre drasticamente le barriere tra chi è affetto da una disabilità e il resto della società.

Quando parliamo di aiuto alle persone portatrici di disabilità, non ci limitiamo più a un'ottica di “cura” o “supporto”: il vero obiettivo, adesso, è l'**inclusione a tutto tondo**. Le innovazioni tecnologiche mirano a rendere accessibili aree fondamentali della vita quotidiana e professionale: dall'educazione alla partecipazione attiva nella comunità, fino all'accesso a contenuti culturali e artistici. È un salto di qualità che mette al centro il concetto di pari opportunità, in cui la tecnologia non è un semplice strumento di compensazione, ma un mezzo per esprimere pienamente il proprio potenziale, per assicurare **a ogni individuo la propria autonomia**.

1.2 Motivazioni e obiettivi della tesi

In questo contesto di grande fermento e continua ricerca si inserisce il progetto NoVAGraphS [3], [4]. L'idea di base è tanto semplice quanto ambiziosa: sviluppare **sistemi di dialogo** che permettano alle persone con disabilità visive di comprendere e manipolare contenuti che di solito sono **fortemente visivi**, come diagrammi, grafi, schemi e mappe concettuali. In altri termini, si vuole “tradurre” questo genere di contenuti complessi in conversazioni strutturate, in modo che chi non può vedere possa comunque esplorare e navigare in modo autonomo all'interno essi.

Oggi i dispositivi di sintesi vocale (TTS, Text-To-Speech) e gli screenreader sono fondamentali per rendere accessibile il contenuto testuale alle persone con disabilità visive. Se un testo è codificato in maniera compatibile (per esempio, in formati come HTML accessibile o PDF taggati), questi sistemi possono “leggerlo” e trasformarlo in audio.

La situazione cambia drasticamente quando il contenuto è rappresentato da un’illustrazione o un’immagine: una mappa, un diagramma, un fumetto, un’infografica, o addirittura una semplice foto con informazioni incorporate. In questi casi, i tradizionali sistemi TTS, per quanto evoluti, non sono in grado di interpretare la struttura o il significato di un elemento puramente visivo e di tradurlo in un output che abbia senso per chi non vede. Si limiteranno invece a leggere una descrizione testuale associata all’immagine, che può essere generica o addirittura (molto spesso) assente.

È evidente, dunque, che l’accessibilità “di base” offerta da queste tecnologie deve essere arricchita da soluzioni che sappiano descrivere e narrare i contenuti grafici, permettendo non soltanto di “sentire” una descrizione generica dell’immagine, ma anche di esplorarla in modo approfondito. È proprio in questa direzione che si muove il progetto NoVAGraphS, attraverso l’idea di creare un dialogo interattivo in cui l’utente possa fare domande, focalizzare l’attenzione su certi elementi dell’immagine e chiedere chiarimenti, superando così il limite puramente testuale dei sistemi TTS tradizionali.

Nel progetto, largo spazio è dedicato allo sviluppo di interfacce testuali o vocali, dove un “assistente virtuale” dialoga con l’utente, fornendo descrizioni, chiarimenti e spiegazioni passo dopo passo. Si tratta di un ambito in cui convergono competenze di Intelligenza Artificiale, Elaborazione del Linguaggio Naturale (NLP) e design di interfacce accessibili. La sfida è proprio quella di realizzare una tecnologia che sappia interpretare sia le esigenze dell’utente, sia la complessità del contenuto grafico da descrivere.

Uno dei cardini di NoVAGraphS è la capacità di “smontare” un diagramma in tutte le sue componenti fondamentali (linee, nodi, connessioni, strutture gerarchiche) per poi renderle accessibili tramite un sistema di dialogo.

Quando si parla di “sistema di dialogo” (o “chatbot”) ci si riferisce a un software progettato per interagire con le persone attraverso uno scambio di messaggi, solitamente in linguaggio naturale. A differenza di un semplice motore di ricerca, che recupera documenti contenenti determinate parole chiave, un chatbot è in grado di comprendere (fino a un certo punto) l’intento dell’utente e restituire una risposta mirata, che può essere testuale o, usando sistemi di Text To Speech, vocale. Grazie ai progressi nell’elaborazione del linguaggio naturale (NLP) e nell’intelligenza artificiale, i chatbot oggi sono in grado di sostenere conversazioni più o meno complesse, simulando la sensazione di dialogare con un assistente umano. Ciò li rende strumenti particolarmente interessanti in ambito assistivo, dove l’interazione discorsiva può semplificare l’accesso a informazioni e contenuti che, altrimenti, sarebbero difficili o addirittura impossibili da fruire per persone con disabilità visive.

In questo modo, se una persona cieca o ipovedente chiedesse “Quali sono gli elementi principali di questo diagramma?”, il sistema è in grado di rispondere elencandoli e, se necessario, spiegando come sono collegati fra loro. L’obiettivo non è fornire una descrizione generica, ma

consentire una vera e propria interazione, così come avviene quando si osserva un’immagine e ci si concentra via via su parti diverse.

1.3 Struttura del documento

All’interno dello scenario presentato, la mia tesi si propone di descrivere il percorso di analisi, progettazione e realizzazione di un sistema utile agli scopi del progetto NoVAGraphS. In particolare, illustrerò come abbiamo affrontato la sfida di sviluppare un sistema di dialogo in grado di sostenere conversazioni più naturali e precise, affinché l’utente possa davvero “navigare” nelle informazioni. Verranno illustrate sia le soluzioni tecniche che quelle di design, mostrando quali tecnologie e librerie sono state utilizzate, e come sono state integrate per garantire accessibilità e usabilità.

Questa introduzione costituisce la Sezione 1, dove abbiamo presentato l’idea centrale e il contesto storico e tecnologico in cui si inserisce la ricerca. Nelle sezioni successive sarà passata dapprima in rassegna la letteratura scientifica, con un focus particolare su come l’elaborazione del linguaggio naturale possa fare da ponte tra il mondo visivo e le persone con disabilità. Verranno poi esaminate le principali sfide di carattere tecnico, dalle architetture di intelligenza artificiale fino alle problematiche di accessibilità legate alle interfacce conversazionali.

Nella Sezione 2 entreremo nel merito della Natural Language Understanding (NLU). Verrà dapprima analizzato il funzionamento dei chatbot rule-based, con particolare attenzione ad AIML (Sezione 2.1). Questa parte permetterà di evidenziare gli aspetti positivi e i limiti di un approccio basato sulla definizione di regole statiche, motivando la scelta di progettare un nuovo sistema di dialogo.

Successivamente, il discorso passerà alla classificazione degli intenti mediante modelli di tipo neurale (LLM), illustrando come tali modelli possano essere addestrati su dataset etichettati o tramite tecniche di data augmentation (Sezione 2.2). In ultimo, si discute il riconoscimento delle entità (Named Entity Recognition, NER) e la sua importanza per estrarre informazioni chiave dai messaggi degli utenti (Sezione 2.3).

La Sezione 3 è interamente dedicata alla cosiddetta **Retrieval-Augmented Generation**, un approccio grazie al quale i modelli linguistici possono integrare informazioni provenienti da fonti esterne (basi di conoscenza, corpora o API) e fornire così risposte più aggiornate e contestualizzate. Il capitolo illustra come strutturare il recupero dei dati (Data Retrieval) e come utilizzare le capacità di generazione dei LLM per produrre output più accurati e naturali. Viene inoltre dedicato largo spazio all’analisi della qualità delle risposte e a quali metriche o strategie impiegare per valutarne l’efficacia.

La Sezione 4 conclude il lavoro, passando una prospettiva di ingegneria del software: sarà infatti offerta una panoramica dell’architettura complessiva del sistema, spiegando le scelte progettuali e la logica di funzionamento dei componenti chiave. Qui vengono anche esaminate le dipendenze tra i vari moduli, le pipeline di elaborazione e saranno analizzati alcune possibilità di estendere o affinare ulteriormente la piattaforma in vista di futuri sviluppi.

2 Natural Language Understanding

L'implementazione di chatbot basati su AIML (Artificial Intelligence Markup Language) ha rappresentato un primo passo nella formalizzazione delle *interazioni uomo-macchina*, fornendo una **struttura rule-based** che permette di rispondere a input testuali tramite *pattern di corrispondenza*. Questo approccio, sebbene efficace in una grande varietà di contesti, mostra diversi limiti quando si tratta di gestire variabilità linguistica, contesto e scalabilità delle regole.

In questo capitolo, analizzeremo innanzitutto il *funzionamento di AIML*, illustrandone la sintassi e le proprietà attraverso esempi pratici. Questo ci permetterà di evidenziare le principali criticità del paradigma rule-based, che si riveleranno essere la **rigidità nella definizione delle regole** e la **necessità di una manutenzione manuale della conoscenza**.

Alla luce di queste limitazioni, ci sposteremo verso un approccio più flessibile e adattabile, basato su sistemi neurali per la classificazione degli intenti. In particolare, esploreremo come tali modelli possano essere strutturati in modo da *emulare* un comportamento simile a un **albero decisionale**, capace di generalizzare le richieste degli utenti senza la necessità di specificare esplicitamente ogni possibile variazione.

Infine, introdurremo brevemente anche il task della **Named Entity Recognition (NER)** come componente fondamentale per migliorare la comprensione dei messaggi, permettendo di **estrarre informazioni strutturate** dagli input e affinare ulteriormente il processo decisionale del chatbot.

2.1 Come AIML gestisce la comprensione

Negli anni '90 iniziò a guadagnare popolarità il *Loebner Prize* [5], una competizione ispirata al Test di Turing [6].

Nella competizione, chatbot e sistemi conversazionali cercavano di “ingannare” giudici umani, facendo credere loro di essere persone reali. Molti sistemi presentati alla competizione erano basati su pattern matching e rule-based, a volte integrando euristiche per la gestione di sinonimi o correzione ortografica.

Tra questi, uno dei più celebri è *ALICE* (Artificial Linguistic Internet Computer Entity), sviluppato da Richard Wallace utilizzando il linguaggio di markup AIML (Artificial Intelligence Markup Language) da lui introdotto [7], [8].

ALICE vinse per la prima volta il Loebner Prize nel 2000, e in seguito vinse altre due edizioni, nel 2001 e 2004.

2.1.1 Struttura di un chatbot AIML

Basato sull'XML [7], di base l'AIML fornisce una struttura formale per definire regole di conversazione attraverso **categorie** di *pattern* e *template*:

- **<pattern>** : la frase (o le frasi) attese in input a cui il chatbot deve reagire;
- **<template>** : la risposta (testuale o con elementi dinamici) che il chatbot fornisce quando si verifica il match del pattern.

La forma più semplice di categoria è visibile nello Snippet 1.

```

<category>
  <pattern>CIAO</pattern>
  <template>Ciao! Come posso aiutarti oggi?</template>
</category>

```

Snippet 1: Esempio basilare di una categoria AIML.

In questo caso, se l'utente scrive "Ciao"¹, il sistema restituisce la risposta associata nella sezione del `<template>`.

Naturalmente questa è una regola basilare: AIML permette di definire pattern molto più complessi. Un primo passo verso la creazione di regole più flessibili è l'uso di **wildcard** (Snippet 2): associando simboli quali `*` e `-` a elementi di personalizzazione (`<star/>`), il motore che esegue la configurazione AIML può gestire un certo grado di variabilità linguistica.

In particolare, il simbolo `*` corrisponde a una wildcard che cattura qualsiasi sequenza di parole in input tra i due pattern specificati.

In questo caso, se l'utente digita "Mi chiamo Andrea", il sistema sostituisce `<star/>` con "Andrea", e risponde di conseguenza.

```

<category>
  <pattern>MI CHIAMO *</pattern>
  <template>
    Ciao <star/>, piacere di conoscerti!
  </template>
</category>

```

Snippet 2: Esempio di utilizzo di wildcard in AIML.

Spesso è necessario memorizzare informazioni fornite dall'utente per utilizzarle successivamente. A questo scopo, AIML offre i tag `<set>` e `<get>` che, rispettivamente, memorizzano e recuperano valori da variabili di contesto.

```

<category>
  <pattern>IL MIO COLORE PREFERITO È *</pattern>
  <template>
    <think>
      <set name="colore"><star/></set>
    </think>
    Ok, ricorderò che il tuo colore preferito è <star/>.
  </template>
</category>

<category>
  <pattern>QUAL È IL MIO COLORE PREFERITO</pattern>
  <template>
    Il tuo colore preferito è <get name="colore"/>.
  </template>
</category>

```

Snippet 3: Esempio di utilizzo dei tag `<set>` e `<get>` in AIML.

¹Caratteri maiuscoli e minuscoli sono considerati uguali dal motore di riconoscimento.

Nello Snippet 3, il tag `<think>` della prima `<category>` fa sì che l'operazione di memorizzazione non produca output testuale per l'utente, ma aggiorni internamente la variabile `colore`. Nel secondo blocco, si utilizza `<get name="colore"/>` per restituire all'utente il valore memorizzato.

Il tag `<condition>` permette di definire regole condizionali in base a variabili di contesto.

Nello Snippet 4, se la variabile `stagione` (presumibilmente impostata altrove con un `<set>`) ha valore `inverno`, verrà restituito "Fa piuttosto freddo...". Un risultato simile si ottiene per `estate`, mentre per altri valori o mancanza di valore si restituisce l'ultimo *list item*.

```
<category>
  <pattern>CHE TEMPO FA</pattern>
  <template>
    <condition name="stagione">
      <li value="inverno">Fa piuttosto freddo, in questa stagione.</li>
      <li value="estate">Fa molto caldo, bevi tanta acqua!</li>
      <li>Non saprei, forse è primavera o autunno?</li>
    </condition>
  </template>
</category>
```

Snippet 4: Esempio di utilizzo del tag `<condition>` in AIML.

Il tag `<topic>` permette di raggruppare categorie che appartengono a un medesimo ambito di conversazione, per *facilitare la lettura* delle regole. Un esempio è visibile nello Snippet 5.

```
<topic name="saluti">
  <category>
    <pattern>CIAO</pattern>
    <template>
      Ciao, piacere di vederti!
    </template>
  </category>

  <category>
    <pattern>COME STAI</pattern>
    <template>
      Sto bene, grazie! E tu come stai?
    </template>
  </category>
</topic>
```

Snippet 5: Esempio di utilizzo del tag `<topic>` in AIML.

In questo modo le regole legate ai saluti sono tutte contenute all'interno di un blocco `<topic>` chiamato `saluti`.

Il tag `<srai>`² permette di reindirizzare l'input ad un'altra regola, che verrà processata come se fosse stata digitata dall'utente. È molto utile per riutilizzare risposte o logiche già definite.

²Stimulus-Response Artificial Intelligence [7]

```

<topic name="saluti">
  <category>
    <pattern>SALUTA */</pattern>
    <template>
      <srai>CIAO</srai>
    </template>
  </category>
</topic>

```

Snippet 6: Esempio di utilizzo del tag `<srai>` in AIML.

Consideriamo lo Snippet 6: se l'utente scrive "Saluta Andrea", la regola cattura "SALUTA *" e reindirizza il contenuto (in questo caso "CIAO") a un'altra categoria. Se esiste una categoria che gestisce il pattern "CIAO", verrà attivata la relativa risposta.

Esiste anche una versione contratta di `<srai>` chiamata `<sr>`, che è stata prevista come scorciatoia quando è necessario matchare un solo pattern. Secondo la documentazione, il tag corrisponde a `<srai><star/></srai>`.

Abbiamo già visto `<think>` in azione per evitare che il contenuto venga mostrato all'utente nello Snippet 3. In generale, `<think>` è utile quando vogliamo impostare o manipolare variabili senza generare output visibile, come nello Snippet 7.

```

<category>
  <pattern>ADESSO È */</pattern>
  <template>
    <think><set name="stagione"><star/></set></think>
    Grazie, ora so che la stagione attuale è <star/>!
  </template>
</category>

```

Snippet 7: Esempio di utilizzo del tag `<think>` in AIML.

Il tag `<that>` (Snippet 8) permette di scrivere pattern che dipendono dalla risposta precedentemente fornita dal chatbot. È particolarmente utile per gestire contesti conversazionali più complessi.

```

<category>
  <pattern>SI</pattern>
  <that>VA TUTTO BENE</that>
  <template>Felice di averti aiutato!</template>
</category>

```

Snippet 8: Esempio di utilizzo del tag `<that>` in AIML.

In questo caso la regola sarà attivata se la risposta precedente del bot era "VA TUTTO BENE" e l'utente risponde in modo affermativo.

Per rendere la conversazione più naturale, AIML 2.0 fornisce `<random>`, che permette di restituire una risposta fra più alternative, come illustrato nello Snippet 9.


```

<category>
  <pattern>COME VA</pattern>
  <template>
    <random>
      <li>Benissimo, grazie!</li>
      <li>Abbastanza bene, e tu?</li>
      <li>Non c'è male, e tu come stai?</li>
    </random>
  </template>
</category>

```

Snippet 9: Esempio di utilizzo del tag `<random>` in AIML.

Ogni volta che l'utente scrive "Come va", il bot sceglierà casualmente una delle tre risposte elencate.

Alcuni interpreti di AIML supportano `<learn>`, che consente al bot di aggiungere nuove categorie "al volo" durante l'esecuzione. Un esempio di utilizzo è presentato nello Snippet 10.

```

<category>
  <pattern>TI INSEGNO *</pattern>
  <template>
    <think>
      <learn>
        <![CDATA[
          <category>
            <pattern><star/></pattern>
            <template>Ho imparato a rispondere a "<star/>"!</template>
          </category>
        ]]>
      </learn>
    </think>
    Ho imparato una nuova regola!
  </template>
</category>

```

Snippet 10: Esempio di utilizzo del tag `<learn>` in AIML.

2.1.2 Criticità e limiti di AIML

Grazie ai tag previsti dallo schema, AIML riesce a gestire conversazioni piuttosto complesse. Ciononostante, presenta comunque alcune limitazioni:

- Le strategie di wildcard e pattern matching restano **prevalentemente letterali**, con limitata capacità di interpretare *varianti linguistiche non codificate nelle regole*. Se una frase si discosta dal pattern previsto, il sistema fallisce il matching. Sono disponibili comunque alcune funzionalità per la gestione di sinonimi, semplificazione delle locuzioni e correzione ortografica (da comporre e aggiornare manualmente) che possono mitigare alcuni di questi problemi.
- La gestione del contesto (via `<that>`, `<topic>`, `<star>`, ecc.) è rudimentale, soprattutto se paragonata a sistemi moderni di NLU con modelli neurali che apprendono contesti ampi e riescono a tenere traccia di dettagli dal passato della conversazione.
- L'integrazione con basi di conoscenza esterne (KB, database, API) richiede estensioni o script sviluppati ad-hoc, poiché AIML di per sé non offre costrutti semantici o query integrate, e non permette di integrare script internamente alle regole [7].

- Le risposte generate sono statiche e predefinite, e non possono essere generate dinamicamente in base a dati esterni o a contesti più ampi in modo automatico (come invece avviene con LLM e modelli di generazione di linguaggio).

Nonostante questi limiti, AIML ha rappresentato un passo importante nell'evoluzione dei chatbot, offrendo un **framework standardizzato** e relativamente **user-friendly** per la creazione di agenti rule-based [8].

In alcuni ambiti ristretti (FAQ, conversazioni scriptate, assistenti vocali), costituisce ancora una soluzione valida e immediata. In domini più complessi, in cui la varietà del linguaggio e l'integrazione con dati dinamici sono essenziali, diventa indispensabile affiancare o sostituire AIML con tecniche di Natural Language Understanding basate su machine learning e deep learning.

Nelle sezioni successive sarà mostrato il percorso seguito per cercare di migliorare la comprensione degli input dell'utente, integrando tecniche di NLU basate su modelli di linguaggio neurali, e valutando le performance ottenute rispetto ad AIML.

2.2 Classificazione con LLM

Come detto poco sopra, uno dei limiti di AIML è la **gestione limitata di varianti linguistiche** e contesti conversazionali.

Per permettere all'AIML di generalizzare sulle richieste degli utenti, il botmaster³ deve dichiarare delle **generalizzazioni esplicite**, ad esempio utilizzando wildcard o pattern che catturano più varianti di una stessa richiesta. Questo processo richiede **tempo e competenze linguistiche**, oltre ad una grande attenzione per evitare ambiguità o sovrapposizioni tra regole.

Durante il mio percorso di ricerca ho deciso di seguire una strada simile a quella di AIML, ma facendo un passo indietro e ponendomi la domanda:

“Invece che cercare dei pattern nelle possibili richieste degli utenti, perchè non trovare un modello che possa generalizzare su queste richieste in modo automatico?”

Il percorso per arrivare al modello di classificazione di intenti ha richiesto i suoi tempi, ma alla fine ho ottenuto dei risultati che ritengo soddisfacenti.

I problemi principali da risolvere per poter classificare gli intenti sono due: la **raccolta di dati** etichettati e la **scelta del modello** di classificazione.

2.2.1 Dataset di training

Di base, nel mondo dell'apprendimento automatico supervisionato, per addestrare un modello di classificazione è necessario un dataset di **esempi etichettati**, cioè coppie di input e output su cui il modello deve imparare a generalizzare.

Per la classificazione di intenti, i dataset più comuni sono quelli di chatbot e assistenti vocali, che contengono domande e richieste etichettate con l'intento che l'utente vuole esprimere.

Il dataset originario fornitomi [9] è stato composto in seguito a una campagna di raccolta dati manuale, in cui diversi collaboratori hanno interagito con un prototipo di chatbot AIML, ponendo domande e richieste di vario tipo nel contesto degli FSA [10].

³Lo sviluppatore delle regole AIML per un certo progetto.

Il dataset è una collezione di circa 700 singole interazioni “*botta e risposta*” prodotte dagli utenti durante la prima fase di sperimentazione. Metà sono domande, l’altra metà coincide con ciò che il chatbot ha risposto. Sono anche presenti ulteriori metriche e valutazioni qualitative delle interazioni, che però non sono state utilizzate per l’addestramento del modello di classificazione.

Estrazione dei dati

Dovendo addestrare un modello di classificazione, ho provveduto innanzitutto ad estrarre i dati effettivamente a noi necessari. Lo Script 1, scritto in python adoperando la libreria `pandas` [11] è stato sufficiente.

```
import pandas as pd
from dotenv import load_dotenv

load_dotenv()

df_o = pd.read_excel('corpus/interaction-corpus.xlsx')

# Filter only the rows that have "Participant" as 'U'
df = df_o[df_o['Participant'] == 'U']
df = df[['Text']]
df = df.drop_duplicates()
df = df[df['Text'].apply(lambda x: isinstance(x, str))]
df['Text'] = df['Text'].str.strip() # Remove trailing whitespace
texts = df['Text'].dropna()

df.to_csv("./filtered_data.csv")
```

Script 1: Estrazione dei dati dal dataset di interazione.

Estrate le domande, ho potuto procedere con l’etichettatura.

In un primo step, ho considerato la possibilità di lasciare il compito di etichettatura delle domande ad un sistema che svolgesse il compito in automatico.

Questo permetterebbe di avere un dataset decorato, senza dover ricorrere a un’etichettatura manuale che sarebbe stata molto **dispendiosa in termini di tempo e risorse**, specialmente in ottica di un **incremento dei dati** del dataset in seguito a nuove interazioni con il chatbot.

Per fare ciò, ho rivolto la mia attenzione ai modelli di linguaggio neurale, in particolare ai **Large Language Models** (LLM), dal momento che sono in grado di generalizzare su una vasta gamma di task linguistici, inclusa la classificazione di intenti.

Con l’**enorme disponibilità** attuale di modelli pre-addestrati e API che permettono di interagire con essi, ho potuto sperimentare diverse soluzioni per l’etichettatura automatica delle domande.

In particolare, ho deciso di sperimentare con modelli di LLM open-source, dal momento che sono eseguibili localmente e permettono di mantenere i dati sensibili all’interno dell’ambiente di lavoro, senza doverli condividere con servizi esterni.

Per utilizzarli, si sono rivelate fondamentali le API fornite da Ollama [12], un sistema per hostare localmente modelli di LLM **open source** (e in certi casi anche *open-weights* [13]).

2.2.2 Etichettatura automatica del dataset

Per poter automatizzare l'etichettatura usando una LLM, prima di tutto ho identificato l'insieme delle possibili etichette, elencate nello Snippet 11.

```
LABELS: dict[str, str] = {
    "START": "Initial greetings or meta-questions, such as 'hi' or 'hello'.",
    "GEN_INFO": "General questions about the automaton that don't focus on specific components or functionalities.",
    "STATE_COUNT": "Questions asking about the number of states in the automaton.",
    "FINAL_STATE": "Questions about final states of the automaton.",
    "STATE_ID": "Questions about the identity of a particular state.",
    "TRANS_DETAIL": "General questions about the transitions within the automaton.",
    "SPEC_TRANS": "Specific questions about particular transitions or arcs between states.",
    "TRANS_BETWEEN": "Specific question about a transition between two states",
    "LOOPS": "Questions about loops or self-referencing transitions within the automaton.",
    "GRAMMAR": "Questions about the language or grammar recognized by the automaton.",
    "INPUT_QUERY": "Questions about the input or simulation of the automaton.",
    "OUTPUT_QUERY": "Questions specifically asking about the output of the automaton.",
    "IO_EXAMPLES": "Questions asking for examples of inputs and outputs.",
    "SHAPE_AUT": "Questions about the spatial or graphical representation of the automaton.",
    "OTHER": "Questions not related to the automaton or off-topic questions.",
    "ERROR_STATE": "Questions related to error states or failure conditions within the automaton.",
    "START_END_STATE": "Questions about the initial or final states of the automaton.",
    "PATTERN_RECOG": "Questions that aim to identify patterns in the automaton's structure or behavior.",
    "REPETITIVE_PAT": "Questions focusing on repetitive patterns, especially in transitions.",
    "OPT_REP": "Questions about the optimal spatial or minimal representation of the automaton.",
    "EFFICIENCY": "Questions about the efficiency or minimal representation of the automaton."
}
```

Snippet 11: Etichette possibili per le domande del dataset.

In questa mappa, ad ogni etichetta è associata una descrizione che indica alla LLM un contesto in cui collocarla, con lo scopo di assistere la LLM ad etichettare correttamente le domande togliendo il più possibile le ambiguità.

Questo genere di task è del tipo **zero shot**, in cui il modello non ha mai visto i dati di training e deve etichettare le domande esclusivamente in base a un contesto fornito.

Con lo scopo di assicurare un'etichettatura corretta e affidabile, ho deciso di utilizzare due modelli di LLM differenti, in modo da poter effettuare un **majority voting** tra le etichette prodotte dai due modelli:

- *Gemma 2*, sviluppato da Google Deep Mind [14];
- *llama 3.1*, sviluppato da Meta AI [15].

I modelli sono stati utilizzati nelle loro varianti da 9 miliardi di parametri per Gemma 2 (dimensione intermedia) e 8 miliardi per llama 3.1 (il più piccolo dei modelli forniti), basandomi sulle sperimentazioni che hanno mostrato un buon compromesso tra performance (intese come qualità dei risultati prodotti in seguito al prompting) e tempo di esecuzione [14], [15].

Un ulteriore modello, Qwen [16], prodotto da Alibaba, è stato utilizzato durante le sperimentazioni, ma i risultati non sono stati sufficientemente soddisfacenti da permettere un utilizzo all'interno del progetto.

Ho effettuato il prompting delle domande con i modelli di LLM utilizzando le risorse dell'hardware a mia disposizione, composto da:

- CPU AMD Ryzen 7 5800x (4.7GHz, 8 core, 16 thread, 32MB L3 cache)
- 64GB RAM DDR4 @3200MHz
- GPU Nvidia RTX 3070 Ti (8GB GDDR6, 6144 CUDA cores @1.77GHz)

Ad ogni modello è richiesto di etichettare ogni domanda. Il prompt utilizzato è stato progettato in modo da fornire un **contesto chiaro e preciso**, in modo da guidare la LLM verso l'etichetta corretta.

In particolare, ne sono stati utilizzati **due per ogni modello**, in modo da fornire un contesto più vario e permettere ai modelli di generalizzare meglio sulle domande. Ogni prompt risulta diverso dal punto di vista della composizione della richiesta, ma l'intento finale a livello semantico è lo stesso.

I prompt dello Snippet 12 sono stati scelti in modo da fornire informazioni utili ai modelli per etichettare le domande, insieme ad un contesto che effettivamente faccia comprendere alla LLM quale sia l'argomento della domanda.

```
prompts = [  
    # First prompt  
    """You are going to be provided a series of interactions from a user regarding questions  
    about finite state automaton.  
    Each message has to be labelled, according to the following labels:  
  
    {labels}  
  
    You only need to answer with the corresponding label you've identified.  
    Do not explain the reasoning, do not use different terms from the labels you've received  
    now.  
    Interaction:  
    {text}  
    Label:  
    """,  
  
    # Second prompt  
    """You are an AI assistant trained to classify questions into the following categories:  
  
    {labels}  
  
    Please classify the following question:  
    {text}  
    Category:  
    """,  
]
```

Snippet 12: Prompt utilizzati per l'etichettatura delle domande.

Si notino le differenze tra i due prompt: il primo è *più dettagliato* e fornisce una spiegazione più approfondita delle etichette, mentre il secondo è *più conciso e diretto*.

I tag tra parentesi graffe vengono sostituiti con i valori attualmente in uso, in modo da rendere il prompt generico e riutilizzabile.

Segue un estratto di codice python che mostra come è stato effettuato il prompting. Viene importata una classe `Chat`, da me sviluppata, che permette di interagire con i modelli di LLM in modo più semplice, astruendo le API di ollama.

```

from tqdm import tqdm
from chat_helper import Chat
import pandas as pd

# ollama_models = ["llama3.1:8b", "gemma:7b", "qwen:7b"]
ollama_models = ["gemma2:9b", "llama3.1:8b"]

# We are initializing a new dataframe with the same index as the original one
res_df = pd.DataFrame(index=df.index)

for model in ollama_models:
    chat = Chat(model=model)
    dataset_size = len(df)

    for p_i, prompt_version in enumerate(prompts):
        progress_bar = tqdm(
            total=dataset_size,
            desc=f"Asking {model} with prompt {p_i}", unit="rows"
        )

        for r_i, row in df.iterrows():
            text = row["Text"]
            prompt = prompts[0].replace("{text}", text)
            inferred_label = chat.interact(
                prompt,
                stream=True,
                print_output=False,
                use_in_context=False
            )
            inferred_label = inferred_label.strip().replace("'", "")

            res_df.at[r_i, f"{model} {p_i}"] = inferred_label
            progress_bar.update()

        print(progress_bar.format_dict["elapsed"])
        progress_bar.close()

```

Script 2: Prompting delle domande con i modelli di LLM.

ID	gemma2:9b	gemma2:9b	llama3.1:8b	llama3.1:8b
0	START	START	START	START
1	GEN_INFO	GEN_INFO	GEN_INFO	GEN_INFO
2	SPEC_TRANS	SPEC_TRANS	TRANS_BETWEEN	TRANS_BETWEEN
3	SPEC_TRANS	SPEC_TRANS	TRANS_BETWEEN	TRANS_BETWEEN
4	Please provide the interaction. : START	START	START	START
...
285	OPT_REP	OPT_REP	OPT_REP	OPT_REP
286	GRAMMAR	GRAMMAR	GRAMMAR	GRAMMAR
287	REPETITIVE_PAT	REPETITIVE_PAT	REPETITIVE_PAT	REPETITIVE_PAT
288	TRANS_DETAIL	TRANS_DETAIL	TRANS_DETAIL	GEN_INFO
289	GRAMMAR	GRAMMAR	FINAL_STATE	FINAL_STATE

Tabella 1: Esempio di etichettatura delle domande del bronze dataset.

Nella Tabella 1 è mostrato un esempio dei risultati dell’etichettatura del **bronze dataset**, in seguito al prompting con i modelli di LLM.

Come è possibile notare, i modelli hanno etichettato le domande in modo coerente tra di loro, ma non sempre con le etichette corrette.

In certi casi, le etichette sono state completamente sbagliate, e in altre occorrenze sono state prodotte risposte che o non sono presenti nel set di etichette fornito, o hanno ignorato il prompt fornito, fornendo risposte completamente estranee.

Come accennato, è stato adoperato un sistema di **majority voting** (Snippet 13) per combinare i risultati delle due LLM, in modo da ottenere un’etichettatura più affidabile.

```
from collections import Counter

def majority_vote(row: pd.Series):
    label_counts = Counter(row)
    majority_label = label_counts.most_common(1)[0][0]
    return majority_label
```

Snippet 13: Funzione di majority voting per combinare le etichette.

Tuttavia, in seguito ad una prima fase di fine tuning, ho verificato che nonostante un’etichettatura valida, le classi identificate erano **troppo sbilanciate**, con alcune classi che contenevano un numero troppo esiguo di esempi, portando a una classificazione poco affidabile. In più, ho realizzato che le classi scelte erano **troppo generiche**: questo problema non avrebbe permesso di identificare con precisione l’argomento della domanda.

Per questo motivo ho proceduto con una revisione delle etichette, e una successiva etichettatura manuale delle domande.

2.2.3 Nuove classi e etichettatura manuale

Prima di proseguire con l’etichettatura, ho provveduto a **ripulire il dataset** da domande non pertinenti o duplicate. Una volta fatto, ho deciso di **ridurre il numero di classi**, in modo da poter avere un dataset più bilanciato e con classi più specifiche.

Avendone ridotto il numero, per ottenere un livello di *granularità maggiore*, ho deciso di utilizzare un **sistema di etichettatura gerarchico**, in modo da poter identificare con maggiore precisione l’argomento della domanda. Il risultato è stato un dataset con **due livelli di classi**: le *classi principali* e le *classi secondarie*, che ci permetteranno di classificare le domande come se ci trovassimo in un albero decisionale [17].

Più nel dettaglio:

- Le *classi principali* (o *question intent*, si veda la Tabella 2), che rappresentano l’argomento generale della domanda, per un totale di 7 classi;
- Le *classi secondarie* (Tabella 3, Tabella 4, Tabella 5, Tabella 6), che rappresentano l’argomento specifico della domanda, dipendono dalla classe principale e sono 33 in totale. A seconda della classe principale, il numero di classi secondarie varia.

Il numero ristretto di classi di domande ha permesso di creare una suddivisione più bilanciata tra le classi, e di ottenere un dataset generalmente più equilibrato.

Classe	Scopo	Numero di Esempi
transition	Domande che riguardano le transizioni tra gli stati	77
automaton	Domande che riguardano l'automa in generale	48
state	Domande che riguardano gli stati dell'automa	48
grammar	Domande che riguardano la grammatica riconosciuta dall'automa	33
theory	Domande di teoria generale sugli automi	15
start	Domande che avviano l'interazione con il sistema	6
off_topic	Domande non pertinenti al dominio che il sistema deve saper gestire	2

Tabella 2: Classi principali del dataset.

Come è possibile notare (Tabella 3, Tabella 4, Tabella 5, Tabella 6) , alcune classi secondarie contengono un numero esiguo di esempi, non sufficiente per una classificazione affidabile.

Sottoclassi	Scopo	Numero di Esempi
description	Descrizioni generali sull'automa	14
description_brief	Descrizione generale (breve) sull'automa	10
directionality	Domande riguardanti la direzionalità o meno dell'intero automa	1
list	Informazioni generali su nodi e archi	1
pattern	Presenza di pattern particolari nell'automa	9
representation	Rappresentazione spaziale dell'automa	13

Tabella 3: Le 6 classi secondarie del dataset per la classe primaria dell'**automa**.

Sottoclassi	Scopo	Numero di Esempi
count	Numero di transizioni	10
cycles	Domande riguardo anelli tra nodi	4
description	Descrizioni generali sugli archi	2
existence_between	Esistenza di un arco tra due nodi	12
existence_directed	Esistenza di un arco da un nodo a un altro	9
existence_from	Esistenza di un arco uscente da un nodo	18
existence_into	Esistenza di un arco entrante in un nodo	1
input	Ricezione di un input da parte di un nodo	1
label	Indicazione di quali archi hanno una certa etichetta	4
list	Elenco generico degli archi	15
self_loop	Esistenza di self-cycles	1

Tabella 4: Le 11 classi secondarie del dataset per la classe primaria delle **transizioni**.

Sottoclassi	Scopo	Numero di Esempi
count	Numero di stati	19
details	Dettagli specifici su uno stato	1
list	Elenco generale degli stati	1
start	Qual è lo stato iniziale	8
final	Esistenza di uno stato finale	7
final_count	Numero di stati finali	2
final_list	Elenco degli stati finali	3
transitions	Connessioni tra gli stati	8

Tabella 5: Le 8 classi secondarie del dataset per la classe primaria degli **stati**.

Sottoclassi	Scopo	Numero di Esempi
accepted	Grammatica accettata dall'automa	14
example_input	Input di esempio accettato dall'automa	4
regex	Regular expression corrispondente all'automa	2
simulation	Simulazione dell'automa con input dell'utente	8
symbols	Simboli accettati dalla grammatica	7
validity	Validità di un input fornito	2
variation	Richiesta di simulazione su un automa modificato	2

Tabella 6: Le 7 classi secondarie del dataset per la classe primaria della **grammatica**.

2.2.4 Data Augmentation

Come evidenziato nella sezione precedente, diverse classi secondarie contengono un numero esiguo di esempi, non sufficiente per una buona classificazione in seguito al fine-tuning.

Avendo solo 229 esempi, ho **arricchito i dati** con ulteriori domande scritte manualmente e anche generate artificialmente.

Le domande artificiali sono state prodotte in grandi quantità adoperando diversi modelli disponibili online e locali, tra cui:

- ChatGPT 4o , o1 e o3-mini [18];
- Llama3.1 [15];
- DeepSeek R1 [19], [20].

Ad ogni modello è stato presentato un insieme di domande con lo stesso topic principale o secondario, assieme al contesto in cui vengono poste e ad una richiesta di produzione di ulteriori domande simili semanticamente. Per maggiore convenienza, è stato richiesto ai modelli di rispondere fornendo le nuove domande formattate in markdown [21].

Dato il grosso volume di risposte, per verificare l'adesione dei modelli alle richieste è stato effettuato un *controllo a campione*, che non ha evidenziato particolari problematiche nella precisione di nessuno dei modelli.

In totale sono stati aggiunti 851 nuovi quesiti, con la distribuzione mostrata nel Grafico 1.




Grafico 1: Distribuzione delle domande originali e generate artificialmente per ogni classe principale.

Le domande off-topic aggiuntive sono state estratte dal dataset SQUAD⁴ v2 [22], [23], per avere una sufficiente varietà di domande non pertinenti.

Anche le classi secondarie hanno ricevuto alcune migliorie alla distribuzione, che rimane comunque ancora sbilanciata, com'è possibile vedere nel Grafico 2.

⁴Stanford Question Answering Dataset

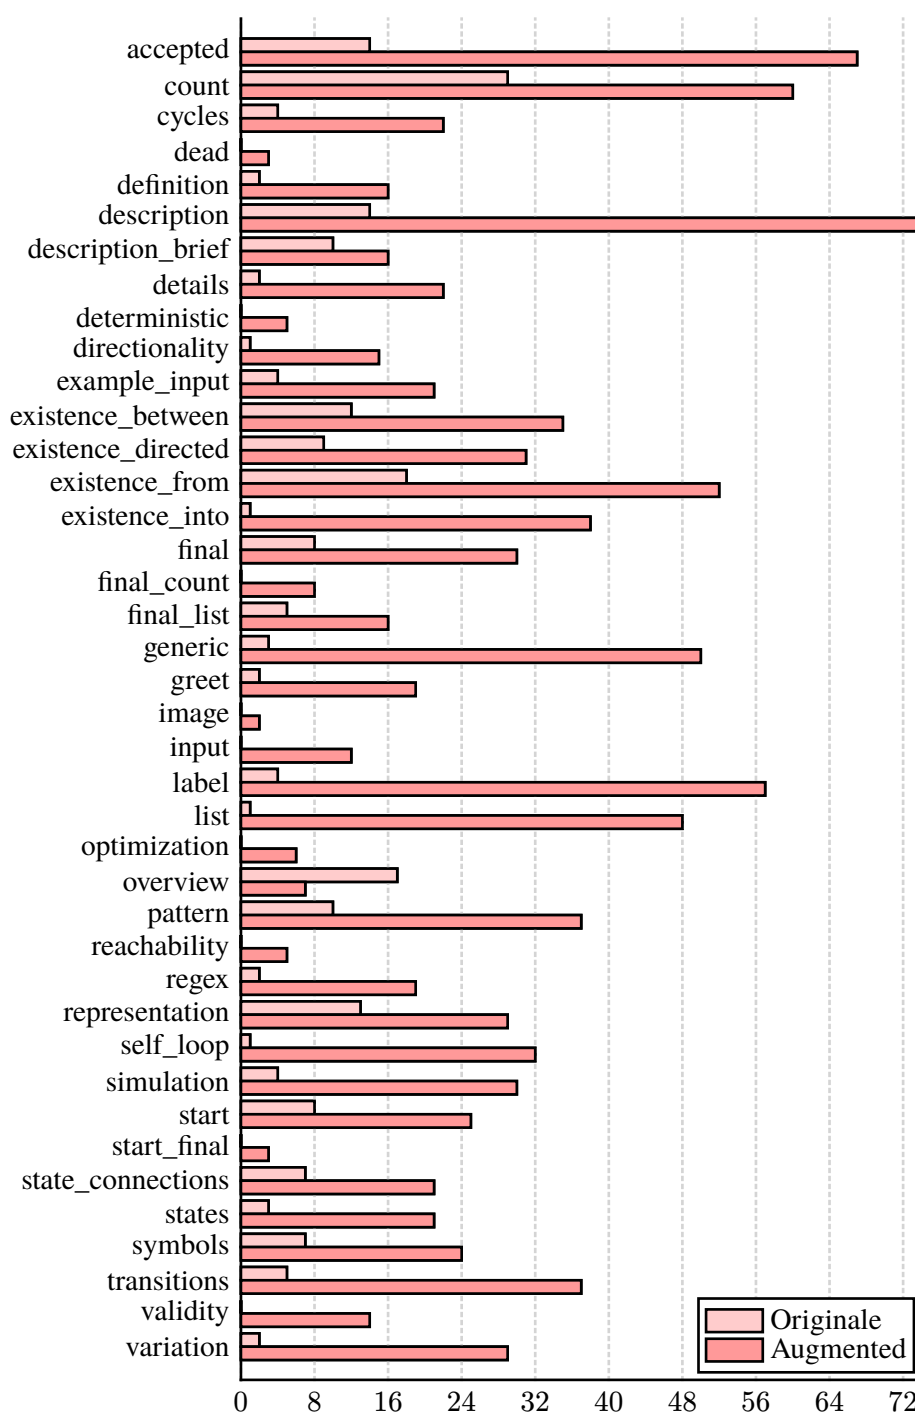


Grafico 2: Distribuzione delle domande originali e generate artificialmente per ogni classe secondaria.

Nonostante lo sbilanciamento, è stato possibile ottenere dei buoni risultati in seguito al fine-tuning.

L'utilizzo del dataset SQUAD ha anche introdotto un'ulteriore incremento delle performance, portando a una diminuzione dell'erronea classificazione di esempi off-topic come domande lecite. In particolare, le metriche di entropia e confidenza durante il fine tuning sono migliorate rispettivamente del 17% e del 7%.

2.2.5 Fine-tuning

Per poter utilizzare i Large Language Models (LLM) per la classificazione di intenti, ho dovuto seguire un processo di **fine-tuning**.

Il fine-tuning (schematizzato nella Figura 1) avviene verso la fine della preparazione di un modello di machine learning. In particolare, è la fase in cui si prende un modello *pre-addestrato su un compito generale* (o su una grande quantità di dati non etichettati) e lo si **specializza** su un compito specifico, come la *classificazione di intenti*, *l'analisi del sentiment* o il *riconoscimento di entità nominate*.

Si parte quindi da un modello che possiede già una **buona conoscenza linguistica di base** (perché allenato, ad esempio, su quantità imponenti di testo come Wikipedia, libri o pubblicazioni) e lo si addestra ulteriormente su un dataset mirato, così da fargli apprendere le **particolarità e le sfumature** del nuovo scenario applicativo, senza dover ripartire da zero.

Sul piano tecnico, il processo di fine-tuning si fonda sugli stessi principi del *learning by example*: si forniscono al modello coppie di input e output (nel caso di una classificazione, l'output è la classe corretta), e si calcola la loss (ad esempio la cross-entropy tra le probabilità previste dal modello e quelle desiderate).

Tramite la *backpropagation* dell'errore, i pesi del modello vengono aggiornati iterativamente, così da allineare le predizioni alle etichette reali. Il risultato è che, dopo un numero sufficiente di iterazioni (o epoche), il modello impara a predire con buona approssimazione la classe corretta anche per esempi non ancora visti.

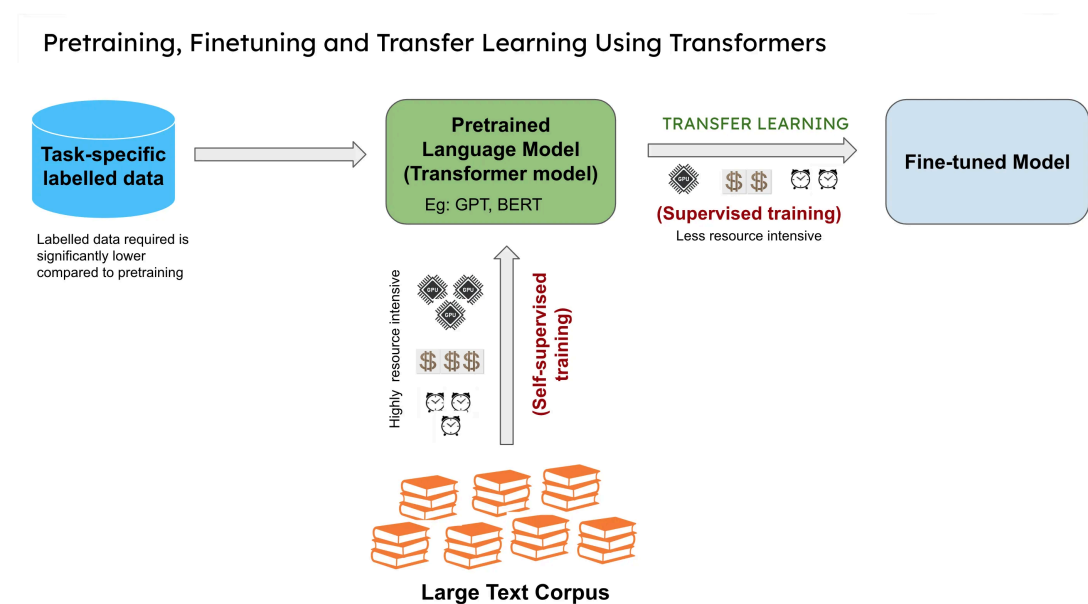


Figura 1: Processo di fine-tuning di un modello di LLM.

Fonte: AIML.com

L'elemento distintivo del fine-tuning rispetto a un addestramento "da zero" (o from scratch) sta nel fatto che la maggior parte dei pesi del modello non parte da valori iniziali casuali, bensì da un punto in cui il modello ha già "appreso" molte regole e pattern del linguaggio. Se nel pre-addestramento ha appreso, ad esempio, la nozione di contesto, la correlazione fra parole vicine e la loro valenza semantica, durante il fine-tuning deve semplicemente specializzarsi

nel riconoscere come queste informazioni si combinano per risolvere il compito target. Questo riduce drasticamente la quantità di dati e di risorse computazionali necessarie a raggiungere buone prestazioni.

Nel caso di una classificazione testuale multi-classe, si aggiunge in genere un piccolo **strato di output** (o head) in cima al modello pre-addestrato, come illustrato nella Figura 2.

La testa è una semplice rete feed-forward, spesso costituita da uno o due livelli di neuroni, che produce un vettore di dimensione pari al numero di possibili etichette. Il resto del modello **rimane pressoché invariato**: l'architettura interna, come i vari encoder o layer del Transformer, resta la stessa, ma i loro pesi continuano ad aggiornarsi durante il training, almeno in un contesto standard (è anche possibile, in alcuni scenari, “congelare” i primi strati e addestrare solo quelli finali, in base a considerazioni di efficienza e dimensione del dataset).




Figura 2: Struttura di un modello di classificazione basato su LLM.

Fonte: Cameron Wolfe [24]

2.2.6 BERT

Prima di illustrare più nel dettaglio il fine-tuning, è utile introdurre BERT⁵ [25], progenitore della famiglia di modelli da me utilizzati per la sperimentazione, nonché uno dei modelli più noti e influenti degli ultimi anni nell'ambito del Natural Language Processing.

BERT è stato proposto nel 2018 da J. Devlin, M.-W. Chang, K. Lee, e K. Toutanova [25] come un sistema capace di apprendere rappresentazioni contestuali del testo in modo bidirezionale, basandosi sull'architettura Transformer introdotta in precedenza da A. Vaswani *et al.* [26].

L'idea portante di BERT è quella di addestrare un modello neurale a predire, data una sequenza testuale, le parole mascherate (ovvero rimosse o sostituite) e la relazione tra frasi adiacenti. Queste due tecniche di pre-addestramento vengono rispettivamente chiamate *Masked Language Modeling* e *Next Sentence Prediction*.

⁵Bidirectional Encoder Representations from Transformers

Nel Masked Language Modeling, BERT maschera casualmente alcune parole del testo in input e chiede al modello di indovinare quali fossero, costringendolo così a sviluppare una comprensione profonda del contesto circostante.

Nel Next Sentence Prediction, invece, il modello riceve in ingresso due frasi (A e B) e impara a classificare se B segue effettivamente A o se le due frasi appartengono a contesti disgiunti. Addestrando in parallelo su questi due compiti, BERT acquisisce rappresentazioni interne che colgono sfumature sintattiche, semantiche e relazionali del linguaggio [25].

Una volta pre-addestrato su grandi corpora di testo (come Wikipedia ed estrazioni di libri), BERT può essere facilmente specializzato per vari task supervisionati, tra cui la classificazione di testi, l'analisi del sentiment, il question answering e, in generale, tutto ciò che riguarda la comprensione del linguaggio naturale, essendo un modello encoder. La peculiarità di BERT è che, essendo già addestrato a livello linguistico di base, necessita di meno esempi per ottenere risultati spesso notevoli su compiti altamente specializzati.

Esistono diverse varianti del modello, in termini di dimensioni e capacità. Le versioni più comuni sono `BERT-base` e `BERT-large`, differenziate per numero di livelli (encoder) e di parametri totali.

In generale, la versione `base` è più rapida e ha requisiti meno elevati in termini di memoria, mentre la versione `large` offre performance maggiori a fronte di tempi di calcolo e requisiti hardware superiori.

Nella libreria di Huggingface `transformers` [27], BERT è messo a disposizione come un modello pretrained, pronto per essere caricato e ulteriormente addestrato. In un contesto di classificazione di intenti, ad esempio, si può utilizzare `AutoModelForSequenceClassification` specificando il checkpoint “bert-base-uncased”.

```
from transformers import AutoModelForSequenceClassification, AutoTokenizer

model_name = "bert-base-uncased"
tokenizer = AutoTokenizer.from_pretrained(model_name)
model = AutoModelForSequenceClassification.from_pretrained(model_name, num_labels=num_classes)
```

Snippet 14: Inizializzazione di un modello BERT per la classificazione di intenti.

`model` (Snippet 14) è in grado di elaborare sequenze di token generate dal tokenizer e, una volta fine-tuned, produce come output le probabilità di appartenere alle varie classi (o intenti) da classificare. Questa è la base su cui mi sono appoggiato per la classificazione delle domande del dataset.

2.2.7 Implementazione

In questa sezione sarà presentata la procedura di fine-tuning che ho implementato per addestrare un modello di classificazione di intenti basato su architetture Transformer.

L'intero processo sfrutta principalmente la libreria `transformers` di Huggingface [27], in combinazione con altri strumenti sempre dell'ecosistema FOSS⁶ di Huggingface, come `datasets`.

⁶Free and Open Source Software, cioè Software **Libero** e Open Source [28], [29]

L'utilizzo di queste librerie permette di semplificare notevolmente il processo di fine-tuning, fornendo **API intuitive** e **funzionalità di alto livello** per la gestione dei dati, la creazione dei modelli e la valutazione delle performance. In questo modo è possibile addestrare un modello di classificazione di intenti in poche righe di codice, senza dover scrivere manualmente i loop di training e validation, o implementare da zero la logica di salvataggio e caricamento dei modelli, nonostante questa via sia sempre possibile.

L'obiettivo è utilizzare un **modello pre-addestrato** (ad esempio BERT, DistilBERT o qualsiasi altro compatibile con `AutoModelForSequenceClassification`) con lo scopo di specializzarlo nel riconoscimento di specifiche categorie di intenti, e successivamente salvarlo per l'uso nel chatbot.

Preparazione dei dati

Un primo punto cruciale è la preparazione del dataset, gestita dalla Funzione 1, `prepare_dataset`. Qui effettua una **suddivisione stratificata** tra train e validation, **tokenizza** i testi tramite un `AutoTokenizer` e converto le etichette da stringhe a interi, in accordo con la mappatura definita nella classe `LabelInfo`.

```
def prepare_dataset(df: DataFrame,
                   tokenizer: PreTrainedTokenizer,
                   label_info: LabelInfo,
                   examples_column: str,
                   labels_column: str) -> tuple[Dataset, Dataset]:
    """
    Prepares the dataset for training and evaluation by tokenizing the text
    and encoding the labels.
    """
    def tokenize_and_label(example: dict) -> BatchEncoding:
        question = example[examples_column]
        encodings = tokenizer(question, padding="max_length", truncation=True, max_length=128)
        label = label_info.get_id(example[labels_column])
        encodings.update({'labels': label})
        return encodings

    split = StratifiedShuffleSplit(n_splits=1, test_size=0.2, random_state=42)
    train_index, val_index = next(split.split(df, df[labels_column]))
    strat_train_set = df.iloc[train_index].reset_index(drop=True)
    strat_val_set = df.iloc[val_index].reset_index(drop=True)

    train_dataset = Dataset.from_pandas(strat_train_set)
    eval_dataset = Dataset.from_pandas(strat_val_set)

    train_dataset =
    train_dataset.map(tokenize_and_label, remove_columns=train_dataset.column_names)
    eval_dataset =
    eval_dataset.map(tokenize_and_label, remove_columns=eval_dataset.column_names)

    return train_dataset, eval_dataset
```

Funzione 1: Funzione per la preparazione del dataset.

In questo modo, ottengo due oggetti di tipo `Dataset` che rappresentano il training set e il validation set. Ciascun esempio è stato trasformato in una struttura pronta per essere gestita dal `Trainer` di Huggingface, con un campo `labels` che indica la classe corretta da apprendere.

Una volta create e preparate queste componenti (funzione di metriche, funzioni di training, dataset tokenizzato), eseguo il fine-tuning chiamando `run_fine_tuning` (presentata poco più avanti).

Metriche di valutazione

Per prima cosa, ho definito una funzione in grado di calcolare le metriche di valutazione, che permetteranno di valutare le performance del modello in fase di fine-tuning in modo automatico.

Ho scelto di considerare **accuratezza**, **precision**, **recall** e **F1** come indicatori classici di performance; in aggiunta, calcolo anche l'**entropia media** e la **confidenza media**, allo scopo di misurare rispettivamente il grado di incertezza delle previsioni e la probabilità media associata alla classe predetta. La Funzione 2, `compute_metrics`, svolge il compito appena descritto.

```
def compute_metrics(eval_pred):
    """
    Compute evaluation metrics for the model predictions.
    """
    predictions, labels = eval_pred
    probabilities = np.exp(predictions) / np.sum(np.exp(predictions), axis=1, keepdims=True)
    preds = np.argmax(probabilities, axis=1)

    acc = accuracy_score(labels, preds)
    precision, recall, f1, _ = precision_recall_fscore_support(labels, preds,
                                                                average='weighted', zero_division=0)

    entropies = entropy(probabilities.T)
    avg_entropy = np.mean(entropies)
    avg_confidence = np.mean(np.max(probabilities, axis=1))

    metrics = {
        'accuracy': acc,
        'precision': precision,
        'recall': recall,
        'f1': f1,
        'avg_entropy': avg_entropy,
        'avg_confidence': avg_confidence,
    }
    return metrics
```

Funzione 2: Funzione per il calcolo delle metriche di valutazione.

Può essere utile soffermarci un momento a spiegare le metriche scelte:

L'**accuratezza**, o tasso di classificazione corretta, misura la proporzione di esempi classificati correttamente, senza distinzione tra le varie classi.

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N \{\hat{y}_i = y_i\} \quad (1)$$

dove $\{\hat{y}_i = y_i\}$ vale 1 se la previsione è corretta, 0 altrimenti. Più il valore è vicino a 1, migliore è la performance complessiva del modello.

Quando si lavora con problemi di classificazione con etichette binarie, o si valuta ciascuna classe indipendentemente, esistono alcuni conteggi che possono essere utili per valutare la qualità delle previsioni:

- i **true positives** (TP) indicano i casi in cui il modello ha predetto correttamente la classe positiva;
- i **false positives** (FP) indicano i casi previsti come positivi dal modello, ma che in realtà sono negativi;
- i **false negatives** (FN) i casi previsti negativi ma in realtà positivi.

Sulla base di queste definizioni, si introducono due metriche fondamentali:

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (2)$$

che indica la percentuale di esempi classificati come positivi che erano effettivamente positivi.

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (3)$$

stima la quota di esempi positivi che sono stati effettivamente riconosciuti come tali dal modello.

L'**F1-score** [30] fornisce una media armonica fra Precision e Recall, combinando entrambe le metriche in un singolo indice:

$$\text{F1} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (4)$$

Un F1 score alto richiede che entrambe le metriche siano elevate; se una delle due è bassa, il valore di F1 tende drasticamente a ridursi. Questo lo rende particolarmente utile in casi di class imbalance o quando è importante non trascurare né la precisione né la capacità di recuperare tutti i positivi.

L'**entropia** è una misura della disordine o incertezza di un sistema, in questo caso delle previsioni del modello.

Per un singolo esempio, se il modello produce una distribuzione di probabilità $\mathbf{p}_i = (p_{i,1}, \dots, p_{i,k})$ sulle k classi, è possibile calcolare l'entropia dell'esempio come

$$H(\mathbf{p}_i) = - \sum_{j=1}^k p_{i,j} \log(p_{i,j}) \quad (5)$$

Tale quantità esprime **quanto “incerte” sono le previsioni del modello**: se il modello assegna un'alta probabilità a una sola classe e bassa probabilità alle altre, l'entropia tende a essere prossima a zero (predizione più “sicura”); se distribuisce le probabilità in modo pressoché uniforme, l'entropia aumenta (maggiore incertezza).

L'entropia media su tutto il set di validazione di dimensione N è:

$$\text{Average Entropy} = \frac{1}{N} \sum_{i=1}^N H(\mathbf{p}_i) \quad (6)$$

Un valore basso di entropia media indica che, in media, le previsioni del modello sono piuttosto concentrate su una specifica classe; un valore più alto suggerisce che il modello sia spesso incerto.

Sempre definita a partire dalla distribuzione p_i , la **confidenza** per il singolo esempio i può essere definita come la probabilità associata alla classe di output che ha la confidenza massima:

$$C(p_i) = \max_j p_{i,j} \quad (7)$$

Maggiore è il valore di $C(p_i)$, più il modello risulta “sicuro” di quella predizione. Analogamente, la confidenza media sul dataset si calcola come:

$$\text{Average Confidence} = \frac{1}{N} \sum_{i=1}^N \max_j p_{i,j} \quad (8)$$

Un valore prossimo a 1 indica che, spesso, il modello prende decisioni molto nette; un valore più basso può rivelare maggiore cautela o incertezza.

Usata congiuntamente all’entropia media, la confidenza media può fornire indicazioni interessanti su come il modello pesa le varie classi e quanto tende a “sbilanciarsi” sulle previsioni.

Addestramento

Per effettuare l’addestramento vero e proprio, ho definito anche la funzione `run_fine_tuning`, che si fa carico di gestire i parametri di training (come numero di epoche, learning rate, batch size), di configurare gli strumenti di logging e salvataggio, e di lanciare effettivamente il training tramite la classe `Trainer` della libreria `transformers`.

La classe `Trainer` semplifica notevolmente la gestione di molteplici aspetti, come la schedulazione del learning rate o la stratificazione della validazione.

Il metodo espone diversi parametri significativi:

- `load_best_model_at_end=True` consente di caricare automaticamente al termine dell’addestramento i pesi del modello con il miglior valore di F1 (impostato in `metric_for_best_model='f1'`);
- `warmup_ratio=0.1` configura un periodo iniziale di warm-up, durante il quale il learning rate cresce gradualmente prima di stabilizzarsi nella fase successiva. Questo contribuisce a rendere l’ottimizzazione più stabile ed evitare picchi di aggiornamento eccessivi nelle primissime iterazioni.

La configurazione del warmup, assieme alla learning rate sono state scelte basandomi sull’utilissimo paper di M. Mosbach, M. Andriushchenko, e D. Klakow [31] che fornisce una guida pratica per il fine-tuning di BERT.

- `metric_for_best_model='f1'` indica che il modello migliore sarà scelto in base al valore di F1, calcolato dalla funzione `compute_metrics`. F1 torna utile in quanto è in grado di bilanciare le due metriche di precision e recall, fornendo un’indicazione complessiva delle performance del modello.

Un’ultima considerazione molto importante riguarda il parametro `report_to`, che consente di specificare a quali servizi di logging inviare i risultati del training.

Nel mio caso, ho scelto di fare affidamento a **Weights and Biases**⁷ in modalità online, in modo da poter monitorare in tempo reale le performance del modello durante il fine-tuning.

⁷Weights and Biases, abbreviato `Wandb`, è un servizio di monitoraggio e logging per l’addestramento di modelli di machine learning

```

def run_fine_tuning(model: AutoModelForSequenceClassification,
                  tokenizer: AutoTokenizer,
                  train_dataset: Dataset,
                  eval_dataset: Dataset,
                  wandb_mode: str,
                  num_train_epochs=20) -> Trainer:
    """
    Fine-tunes a pre-trained model on the provided training dataset and evaluates it
    on the evaluation dataset.
    """
    report_to = ["wandb"] if wandb_mode == "online" else None

    training_args = TrainingArguments(
        output_dir='./temp', # Directory to save the model and other outputs
        num_train_epochs=num_train_epochs, # Number of training epochs
        learning_rate=2e-5, # Learning rate for the optimizer
        warmup_ratio=0.1, # Warmup for the first 10% of steps
        lr_scheduler_type='linear', # Linear scheduler
        per_device_train_batch_size=16, # Batch size for training
        per_device_eval_batch_size=16, # Batch size for evaluation
        save_strategy='epoch', # Save the model at the end of each epoch
        logging_strategy='epoch', # Log metrics at the end of each epoch
        eval_strategy='epoch', # Evaluate the model at the end of each epoch
        logging_dir='./temp/logs', # Directory to save the logs
        load_best_model_at_end=True, # Load the best model at the end by evaluation metric
        metric_for_best_model='f1', # Use subtopic F1-score to determine the best model
        greater_is_better=True, # Higher metric indicates a better model
        save_total_limit=1, # Limit the total number of saved models
        save_only_model=True, # Save only the model weights
        report_to=report_to, # Report logs to Wandb if mode is "online"
    )

    trainer = Trainer(
        model=model, # The model to be trained
        args=training_args, # Training arguments
        train_dataset=train_dataset, # Training dataset
        eval_dataset=eval_dataset, # Evaluation dataset
        processing_class=tokenizer, # Tokenizer for processing the data
        compute_metrics=compute_metrics # Function to compute evaluation metrics
    )

    print(f"Trainer is using device: {trainer.args.device}")

    trainer.train() # Start the training process

    return trainer

```

Funzione 3: Funzione per l'addestramento del modello.

La quasi totalità dei dati mostrati in questo documento sono stati raccolti tramite Wandb, riducendo enormemente il tempo necessario per l'analisi e la visualizzazione dei risultati: il salvataggio automatico ad ogni run e la possibilità di confrontare run diversi in un'unica dashboard sono state funzionalità fondamentali per la mia sperimentazione.

Modelli e architettura utilizzati

Tutti i modelli che ho utilizzato per la sperimentazione sono basati su BERT, o ELECTRA [32], entrambi fondati sull'architettura encoder [25].

In particolare, dal repository di Huggingface dedicato ai modelli di classificazione ho deciso di utilizzare:

- `google-bert/bert-base-uncased` , versione da 110 milioni di parametri [33]. Si tratta del modello originale di BERT ideato da Google [25];
- `distilbert/distilbert-base-uncased` [34], versione distillata [35] di BERT, con circa il 40% in meno di parametri [36]. Il modello è il risultato di una operazione dove si addestra un modello più piccolo ad imitare al meglio l'originale;
- `google/mobilebert-uncased` [37], versione di BERT ingegnerizzata con lo scopo di essere eseguibile su dispositivi mobili. Ha un totale di 25 milioni di parametri [38];
- `google/electra-small-discriminator` [39], da 14 milioni di parametri. Questo modello è stato addestrato utilizzando tecniche simili a quelle utilizzate per addestrare le GAN⁸ [32], [40].

Tutti i modelli utilizzati sono direttamente adoperabili per i nostri scopi essendo modelli encoder: dato un certo input produrranno una **rappresentazione vettoriale o matriciale**. Il risultato è successivamente classificabile da una **rete feed-forward** (Figura 2), restituendo così come risultato la classe più probabile.

Sono state effettuate anche delle sperimentazioni con una variante della normale architettura, dove su un unico encoder vengono addestrati **due modelli separati di classificazione**, per riconoscere con un'unica esecuzione del modello entrambe le classi della domanda presentata.

L'idea, già utilizzata anche in altri ambiti per il Transfer Learning [41] o direttamente su BERT [42], [43] può permettere di **ridurre notevolmente il costo e i tempi di addestramento**, oltre ai requisiti di memoria. Infatti, avendo la quasi totalità dei pesi concentrati nei layer del transformer, lo strato finale di classificazione risulta molto “sottile”, e richiede una percentuale minima rispetto al resto del modello.

Nel mio caso sfortunatamente l'architettura a doppia testa di classificazione non si è rivelato migliore, con **performance in media inferiori del 20%** rispetto al miglior modello addestrato finora. Nonostante le performance peggiori, l'utilizzo di un modello del genere può essere considerato in contesti soggetti da **stringenti limiti hardware**, come su dispositivi mobili, edge o low-end.

L'intera implementazione fa nuovamente fondamento sull'enorme flessibilità della libreria `transformers`. È stato sufficiente infatti soltanto aggiungere le due classification heads ed estendere il metodo `forward` che si occupa della predizione, come mostrato nella Classe 1.

⁸Generative Adversarial Networks, modelli addestrati in coppia, dove uno impara a svolgere un certo compito generativo, e l'altro a riconoscere se un certo esempio presentato è generato o meno.

```

from torch import nn as nn
from transformers import BertPreTrainedModel, BertModel

class BertForHierarchicalClassification(BertPreTrainedModel):
    def __init__(self, config, num_main_topics, num_subtopics):
        super().__init__(config)
        self.bert = BertModel(config)
        self.classifier_main = nn.Linear(config.hidden_size, num_main_topics)
        self.classifier_sub = nn.Linear(config.hidden_size, num_subtopics)
        self.init_weights()

    def forward(self, input_ids, attention_mask, labels_main=None, labels_sub=None):
        outputs = self.bert(input_ids=input_ids, attention_mask=attention_mask)
        pooled_output = outputs.pooler_output
        logits_main = self.classifier_main(pooled_output)
        logits_sub = self.classifier_sub(pooled_output)

        loss = None
        if labels_main is not None and labels_sub is not None:
            loss_fct = nn.CrossEntropyLoss()
            loss_main = loss_fct(logits_main, labels_main)
            loss_sub = loss_fct(logits_sub, labels_sub)
            loss = loss_main + loss_sub # Adjust weighting if needed

        return {'loss': loss, 'logits_main': logits_main, 'logits_sub': logits_sub}

```

Classe 1: Estensione di un modello BERT per la classificazione gerarchica in-model.

2.2.8 Valutazione e performance

Come spiegato a pag. 24, per compiere l'addestramento dei modelli è stato essenziale sfruttare metriche di valutazione adeguate, in grado di fornire un quadro completo delle performance del modello.

Iniziamo quindi valutando i risultati dell'addestramento sulla classe principale del dataset.




Grafico 3: Confronto delle performance di F1 tra i modelli addestrati.

Nel Grafico 3 possiamo vedere come le performance crescono man mano che procediamo con il processo di fine tuning, ma si stabilizzano dopo aver visto circa i tre quarti del dataset. I modelli `bert` e `distilbert` terminano l'addestramento con performance pressochè identiche (la

differenza è dello 0.01%), mentre i modelli `mobilebert` e `electra` differiscono di circa l'8% rispetto a `bert`.

Le differenze di performance sono sempre da confrontare considerando anche il **tempo di addestramento** (Grafico 4) e la complessità del modello: `electra` ad esempio, pur avendo performance leggermente inferiori, è stato addestrato in meno della metà del tempo rispetto a `bert`.

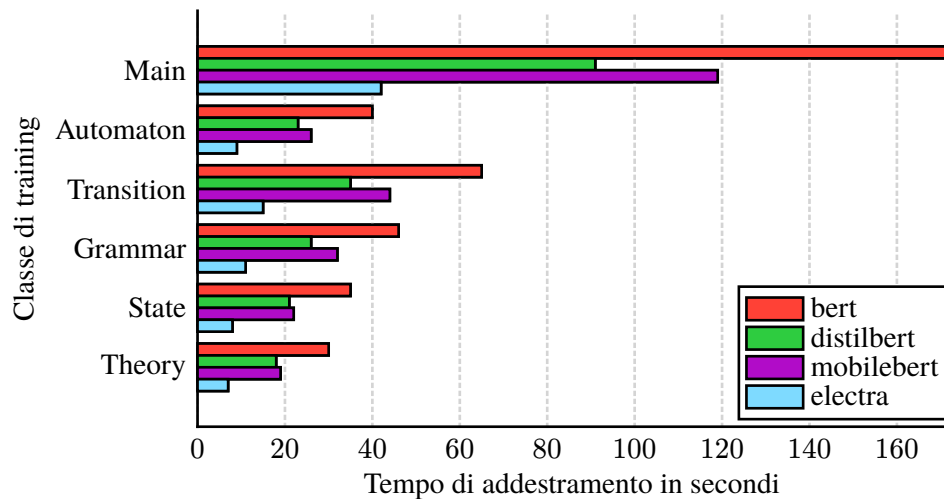


Grafico 4: Confronto dei tempi di addestramento per ciascuna classe di training.

Questo salto nei tempi di addestramento così brusco in realtà porta dei peggioramenti: le sue performance sul test set mostra risultati peggiori ridotte rispetto agli altri modelli, come possiamo constatare nel Grafico 5. Questo ci ricorda come la scelta del modello non debba essere fatta solo in base alle performance ottenute durante l'addestramento, ma che queste devono essere sempre **confermate** verificando con un dati separati da quelli di training.




Grafico 5: Confronto delle performance di F1 tra i modelli addestrati.

È anche mostrato il valore di F1 per la classe principale ottenuto durante il fine-tuning dei modelli.

Tutte le valutazioni sono effettuate utilizzando un ulteriore dataset di test, separato dal dataset di training e di validazione, per evitare overfitting e garantire una valutazione imparziale. È

composto da 468 ulteriori domande, distribuite in modo da assicurare una verifica sufficiente su tutte le classi di intenti secondarie, cruciali per la corretta classificazione e per fornire effettivamente risposte utili agli utenti.

Utilizzeremo le performance di AIML come *baseline* di riferimento per il confronto con gli altri modelli neurali. In seguito alla comparazione delle performance mediante la metrica F1 tra i vari modelli vista nel Grafico 5, d'ora in avanti ci concentreremo sulle metriche ottenute con `bert-base-uncased`, il modello più performante tra quelli addestrati.

Per poterlo fare, sfrutteremo le **matrici di confusione** (Diagramma 1, Diagramma 2) per valutare le performance dei modelli, in particolare per osservare come si comportano in presenza di classi sbilanciate o di domande ambigue.⁹ Siamo interessati a capire se il modello riesce a classificare correttamente domande mai viste; con la matrice di confusione ci aspetteremo di vedere una diagonale principale molto più marcata rispetto agli altri elementi, indicando che il modello è in grado di classificare correttamente la maggior parte delle domande.

Saranno anche presentate le tabelle di valutazione per ciascuna classe, in modo da poter osservare le performance di ciascun modello in modo più dettagliato.

Le metriche presentate nelle tabelle seguenti sono state prodotte utilizzando la funzione `classification_report` della libreria `scikit-learn` [44], che calcola precision, recall e F1 score per ciascuna classe, oltre all'accuracy complessiva.

Il modello AIML, nonostante sia costituito da un numero non indifferente di regole e pattern (103), ha performance mediamente basse, con un F1 score medio del 33% rispetto al 92% di BERT (Tabella 7).

	Performance AIML			Performance BERT			Esempi
	Precision	Recall	F1-score	Precision	Recall	F1-score	
Automaton	0.52	0.19	0.27	0.93	0.93	0.93	75
Grammar	0.90	0.13	0.23	0.78	0.83	0.81	70
Off-Topic	0.26	0.82	0.39	1.00	0.96	0.98	100
Start	1.00	0.53	0.69	1.00	0.90	0.95	40
State	0.17	0.19	0.18	0.96	1.00	0.98	43
Theory	0.00	0.00	0.00	0.57	0.57	0.57	30
Transition	0.67	0.28	0.40	0.97	0.99	0.98	110
Accuracy	0.35			0.92			468
Macro avg	0.44	0.27	0.27	0.89	0.88	0.88	468
Weighted avg	0.53	0.35	0.33	0.92	0.92	0.92	468

Tabella 7: Risultati delle metriche principali di valutazione per la classificazione del main intent, sia con AIML che con BERT.

⁹Una matrice di confusione è una tabella che mostra il numero di predizioni corrette e incorrette fatte dal modello, confrontando le predizioni con le etichette reali.

Possiamo anche vedere come, dove questo non sia in grado di classificare una certa domanda, finisca col classificarla come off-topic, indicando una certa difficoltà nel riconoscere domande in realtà valide per il nostro dominio (Diagramma 1).




Diagramma 1: Matrici di confusione per la classe principale classificata con AIML (sopra) e BERT (sotto). Seguendo una certa riga (classe) possiamo vedere per ogni colonna (classe predetta) quanti esempi sono stati classificati correttamente e quanti no. La diagonale invece indica il numero di esempi classificati senza errori.

Le stesse osservazioni sono applicabili anche alle classi di intenti secondarie (Tabella 8), dove AIML mostra un F1 score medio del 20%, rispetto all'86% di BERT.

Le matrici di confusione confermano le tendenze già presentate dai due modelli per la classe principale, con BERT che mostra una diagonale principale molto marcata (Diagramma 2). AIML effettivamente riesce a classificare correttamente pochi elementi delle varie classi, mentre BERT mostra una maggiore capacità di generalizzazione.

	Performance AIML			Performance BERT			Esempi
	Precision	Recall	F1	Precision	Recall	F1	
ACCEPTED	0.40	0.40	0.40	0.83	1.00	0.91	10
COUNT	0.75	0.15	0.25	0.95	1.00	0.98	20
CYCLES	0.00	0.00	0.00	1.00	1.00	1.00	10
DEFINITION	0.00	0.00	0.00	0.00	0.00	0.00	4
DESCRIPTION	0.18	0.09	0.12	0.51	0.78	0.62	23
DESCRIPTION_BRIEF	0.00	0.00	0.00	0.60	0.25	0.35	12
DETAILS	0.00	0.00	0.00	1.00	1.00	1.00	10
DIRECTIONALITY	0.00	0.00	0.00	1.00	0.80	0.89	10
EXAMPLE_INPUT	0.00	0.00	0.00	1.00	1.00	1.00	10
EXISTENCE_BETWEEN	0.19	0.80	0.30	0.67	0.60	0.63	10
EXISTENCE_DIRECTED	0.00	0.00	0.00	0.75	0.60	0.67	10
EXISTENCE_FROM	0.00	0.00	0.00	0.80	0.80	0.80	10
EXISTENCE_INTO	0.00	0.00	0.00	0.82	1.00	0.90	9
FINAL	0.00	0.00	0.00	1.00	0.83	0.91	6
FINAL_LIST	0.00	0.00	0.00	0.75	0.86	0.80	7
GENERIC	0.00	0.00	0.00	0.00	0.00	0.00	2
LABEL	0.00	0.00	0.00	0.00	0.00	0.00	9
LIST	0.00	0.00	0.00	1.00	1.00	1.00	10
OFF_TOPIC	0.26	0.82	0.39	1.00	0.96	0.98	100
OVERVIEW	0.00	0.00	0.00	0.50	0.67	0.57	3
PATTERN	0.75	0.90	0.82	1.00	1.00	1.00	10
REGEX	0.00	0.00	0.00	1.00	1.00	1.00	10
REPRESENTATION	0.33	0.10	0.15	1.00	0.70	0.82	10
SELF_LOOP	0.00	0.00	0.00	0.90	1.00	0.95	9
SIMULATION	0.00	0.00	0.00	0.91	1.00	0.95	10
START	1.00	0.42	0.59	0.98	0.92	0.95	50
STATES	0.00	0.00	0.00	0.00	0.00	0.00	1
STATE_CONNECTIONS	0.00	0.00	0.00	1.00	1.00	1.00	30
SYMBOLS	0.00	0.00	0.00	0.70	0.70	0.70	10
THEORY	0.00	0.00	0.00	0.57	0.57	0.57	30
TRANSITIONS	0.00	0.00	0.00	0.00	0.00	0.00	3
VARIATION	0.00	0.00	0.00	0.91	1.00	0.95	10
Accuracy			0.28			0.86	468
Macro avg	0.11	0.11	0.09	0.73	0.73	0.72	468
Weighted avg	0.24	0.28	0.20	0.87	0.86	0.86	468

Tabella 8: Risultati delle metriche di valutazione per la classificazione delle classi secondarie con AIML e BERT.





Diagramma 2: Matrici di confusione per le classi secondarie classificate con AIML (sopra) e BERT (sotto).

Per finire, nella Tabella 9 vediamo anche alcuni esempi del test set etichettati da AIML e Bert. Questi esempi sono stati scelti in modo da mostrare come i due modelli si comportano in un'ipotetica situazione reale.

Domanda	Ground Truth		AIML		BERT	
	Main	Sub	Main	Sub	Main	Sub
Would you display a full list of all components, including nodes and transitions, in the finite state automaton?	AUT	LST	OT	OT	AUT	LST
Could you summarize the automaton for me?	AUT	DB	OT	OT	AUT	DB
Could you give me a brief summary of the automaton?	AUT	DB	OT	OT	AUT	DB
Can you point out the start state in this automaton?	STT	STRT	OT	OT	STT	STRT
Is a systematic pattern evident in the automata arcs?	AUT	PTT	AUT	PTT	AUT	PTT
Can you point out a repetitive pattern among the arcs?	AUT	PTT	AUT	PTT	AUT	PTT
I'd like to hear an explanation of how this automaton's states are formed and related.	AUT	DESC	OT	OT	AUT	REP
Would you mind describing the automaton's configuration and links?	AUT	DESC	OT	OT	AUT	REP

Tabella 9: Alcuni esempi utili per confrontare i risultati di classificazione di BERT e AIML.

In generale, i risultati ottenuti con BERT sono molto soddisfacenti, con performance nettamente superiori rispetto ad AIML. Questo **conferma** l'efficacia dei modelli neurali per la classificazione di intenti in un contesto di chatbot, e dimostra come l'uso di modelli pre-addestrati come BERT possa portare a risultati molto migliori rispetto a soluzioni rule-based.

Non mancano tuttavia degli esempi in cui BERT non riesce a classificare correttamente la domanda, ma in generale il modello mostra una capacità di generalizzazione molto più elevata rispetto ad AIML. Per migliorare le prestazioni, una buona strategia potrebbe essere quella di raccogliere più dati etichettati, in modo da poter addestrare il modello su un dataset più ampio e variegato, cercando di incrementare la copertura delle classi meno frequenti.

2.3 Riconoscimento delle entità

Negli anni Novanta, parallelamente agli studi sull'Intelligenza Artificiale per la realizzazione di sistemi conversazionali rule-based come AIML, si sviluppavano anche nuovi compiti di Natural Language Processing (NLP) orientati all'estrazione di informazioni dal testo in modo più strutturato. Uno dei compiti chiave in questo processo è il **Named Entity Recognition (NER)**, o *riconoscimento delle entità nominate*.

Nato inizialmente nell'ambito di competizioni e conferenze come le **Message Understanding Conferences** [45], il NER si propone come task cruciale per identificare all'interno di un testo i riferimenti a persone, organizzazioni, luoghi, date e altre categorie, assegnando a ciascuna

entità un'etichetta appropriata. Se AIML, per certi versi, si concentra su *che cosa l'utente vuole* (**intent classification**), il NER si focalizza su *chi o che cosa è menzionato* all'interno di un messaggio o di un documento.

Un semplice esempio può essere la frase “Mario Rossi ieri è stato a Roma per un incontro con Telecom Italia.”. Un sistema NER ideale dovrebbe riconoscere:

- Mario Rossi come una **persona** (PERSON);
- Roma come un **luogo** (LOC);
- Telecom Italia come un' **organizzazione** (ORG).

In un chatbot avanzato, questa funzionalità è particolarmente importante perché consente di trasformare testi destrutturati (come messaggi, email o query di ricerca) in informazioni utilizzabili da moduli di analisi successivi.

Consideriamo la possibilità che l'utente chieda a un chatbot che si occupa di automi a stati finiti “Qual è la differenza tra un **automa deterministico** e un **automa non deterministico**?”: la NER dovrebbe individuare correttamente “automa deterministico” e “automa non deterministico” come entità rilevanti (anche se meno “classiche” rispetto a persona/luogo/organizzazione).

In questo modo, il chatbot sa di dover recuperare informazioni specifiche su queste due tipologie di automi, assegnandole poi al modulo incaricato di rispondere alla domanda.

2.3.1 Approcci e metodologie nel NER

La ricerca sul riconoscimento delle entità (Named Entity Recognition) ha attraversato diverse fasi, ognuna caratterizzata da metodologie specifiche e da un livello di “intelligenza” sempre crescente [46]. Inizialmente, i sistemi si basavano su regole statiche o elenchi di entità predefiniti, mentre negli ultimi anni si è passati a tecniche di machine learning via via più complesse, fino ad arrivare ai più recenti modelli neurali basati su architetture di tipo Transformer.

Metodi rule-based o a dizionario

Nella prima fase, molti sistemi NER si affidavano a liste di entità note (chiamate *gazetteer*) e a regole linguistiche (pattern o espressioni regolari) per individuare nomi di persone, luoghi, organizzazioni e così via. L'idea di fondo era piuttosto semplice: se una parola compariva in un elenco di nomi propri oppure coincideva con un pattern di stringa (ad esempio iniziale maiuscola, presenza di determinati suffissi), allora veniva etichettata come entità.

Questi approcci erano relativamente facili da implementare e sufficientemente efficaci in un contesto ben definito, purché gli elenchi fossero tenuti *costantemente aggiornati*. Tuttavia, mostravano rapidamente i loro limiti nel momento in cui si presentavano nomi o entità nuove non inclusi nei dizionari, oppure quando si operava in un dominio estremamente vasto (es. social media) o molto specialistico. In tali casi, l'aggiornamento continuo dei gazetteer e la gestione manuale delle regole si rivelavano **complessi e poco scalabili**.

Metodi statistici (CRF, HMM, SVM)

Successivamente, con la diffusione del machine learning, si sono affermati approcci statistici in grado di automatizzare gran parte del processo di individuazione e classificazione delle entità. Tra i metodi più noti, spiccano i Conditional Random Fields [47], gli Hidden Markov Models [48] e le Support Vector Machines [49]. Questi algoritmi imparano a riconoscere le entità

partendo da un dataset annotato, ossia un corpus di testi in cui ogni parola è già etichettata come “entità” o “non entità” (con eventuali sotto-categorie quali PERSON, LOCATION, ORGANIZATION, ecc.).

Il vantaggio principale di questo approccio è che i modelli statistici non dipendono più soltanto da elenchi o regole scritte dall'uomo: essi apprendono le **regolarità linguistiche** e i **pattern lessicali** (per esempio, la probabilità che un termine che inizia con la maiuscola sia un nome proprio di persona) direttamente dai dati. Per molti anni, questi metodi hanno rappresentato lo stato dell'arte del NER, garantendo performance elevate a fronte di un'adeguata disponibilità di dati annotati.

Modelli neurali

Negli ultimi anni, la scena del NER è stata rivoluzionata dall'avvento di reti neurali, inizialmente di tipo ricorrente (come RNN [50] o LSTM [51], [52]) e, più di recente, di tipo Transformer [26] (ad es. BERT [25], RoBERTa, GPT). L'adozione di embedding per le parole e di meccanismi di attenzione (self-attention) ha permesso di superare molte limitazioni dei metodi precedenti, poiché queste architetture sono in grado di:

- gestire contesti testuali più lunghi in modo efficace;
- catturare la struttura sintattica e il significato semantico delle frasi;
- fornire rappresentazioni linguistiche approfondite in grado di distinguere omonimi e contesti diversi.

In questo modo, anche in domini molto specifici (come quello degli automi a stati finiti, in cui esistono entità specialistiche come “automa deterministico” o “automa non deterministico”), i modelli neurali si sono dimostrati capaci di riconoscere e catalogare con maggiore accuratezza le entità rilevanti [53]. Questa evoluzione ha portato a un vero e proprio salto di qualità nelle prestazioni del NER, consentendo al sistema di operare su testi complessi e ricchi di sfumature senza richiedere il continuo intervento di programmatori o linguisti per aggiornare le regole manuali.

2.3.2 Slot Filling

Mentre il NER si concentra su dove compaiono le entità nel testo e su che tipo di entità si tratti (persona, luogo, organizzazione, ecc.), lo slot-filling rappresenta un'operazione più specifica e spesso orientata al dominio [54], [55]. In altre parole:

- Il NER produce una segmentazione e un'etichettatura generica:
Mario Rossi → PERSON , Roma → LOC , Telecom Italia → ORG .
- Lo slot-filling prende queste entità (o altre componenti di testo) e le associa a ruoli predefiniti, tipici di una determinata applicazione. Ad esempio, per un chatbot di viaggi potremmo avere:
 - città_di_partenza = “Milano”
 - città_di_arrivo = “Roma”
 - data_viaggio = “2025-03-07”

In alcuni sistemi, il compito di “trovare gli slot” e “riempirli” è integrato in un singolo modello (*joint model di intent classification e slot-filling* [56]). In altri casi, come in pipeline più

complesse, si preferisce separare il passaggio di NER dal passaggio di mapping di dominio (slot-filling).

Facciamo un esempio di conversazione per un assistente virtuale di prenotazione ristoranti:

1. L'utente scrive: "Voglio prenotare un tavolo per stasera da Gianni".
2. Il NER riconosce nel testo:
 - "Gianni" come entità di tipo `PER` (potrebbe essere ambiguo, ma in contesto gastronomico potrebbe anche essere un `L0C` se "Da Gianni" è il nome del ristorante).
 - "stasera" come `TIME`.
3. Lo slot-filling contestualizza:
 - `nome_ristorante` = "Da Gianni"
 - `data_prenotazione` = 2025-03-02 20:00 (se "stasera" è mappato a una data specifica e magari un orario predefinito)
 - `richiesta_utente` = "prenotazione"

Da un punto di vista implementativo, potremmo anche definire uno slot "ristorante" e uno slot "orario", che vengono riempiti con i valori estratti. Il NER fornisce la base per capire dove si trovano le informazioni nel testo, mentre lo slot-filling si assicura di collocarle correttamente nei campi del database o nei parametri del servizio di prenotazione.

2.3.3 Annotazione dei dati con Doccano

Prima di procedere all'addestramento del modello di Named Entity Recognition, è stato necessario produrre un dataset adeguatamente etichettato. A questo scopo, ho impiegato Doccano [57], uno strumento web open-source pensato per facilitare il processo di annotazione di testi. L'interfaccia di Doccano consente di selezionare frammenti di testo (ad esempio, termini rilevanti in un dominio specifico) e assegnare loro delle etichette, generando in output un file JSONL pronto per la fase di training.

```
[{
  "id": 632,
  "text": "What is the output when the automaton processes '1010'?",
  "label": [[49,53,"input"]]
},
{
  "id": 634,
  "text": "Does the automaton accept strings where the number of '0's equals the number of '1's?",
  "label": [[55,56,"input"], [81,82,"input"]]
},
{
  "id": 635,
  "text": "What is the effect on the accepted language if we remove state q1?",
  "label": [[63,65,"node"]]
}]
```

Snippet 15: Esempio di record JSONL prodotto da Doccano per l'annotazione dei dati di NER.

Nello Snippet 15 vediamo che:

- Il campo `text` contiene la stringa completa del messaggio o della domanda.
- Il campo `label` indica le etichette come tuple, ciascuna composta da:
 1. La posizione iniziale del frammento etichettato (inclusa).
 2. La posizione finale del frammento etichettato (esclusa).

3. L'etichetta stessa (ad esempio, `input` o `node`).

La fase di annotazione è stata svolta manualmente, con particolare attenzione alla **coerenza** e alla **completezza delle etichette**. Doccano ha permesso di semplificare il lavoro, consentendo di visualizzare i testi e le etichette in modo chiaro e di aggiungere nuove annotazioni con pochi clic, senza la necessità di scrivere codice o utilizzare strumenti esterni.

In seguito all'etichettatura sono risultate tre classi di entità:

- `input` : per i frammenti di testo che contengono input o sequenze di simboli. Ad esempio, nella frase “Does it only accept 1s and 0s?” ci aspetteremmo di individuare due entità di tipo `input` : `[20,21,"input"]`, `[27,28,"input"]` ;
- `node` : per i frammenti di testo che contengono nodi o stati dell'automa. Ad esempio, nella frase “Is there a transition between q2 and q0?” ci aspetteremmo di individuare due entità di tipo `node` : `[30,32,"node"]`, `[37,39,"node"]` .
- `language` : per i frammenti di testo che contengono informazioni sulla lingua accettata dall'automa. Ad esempio, nella frase “Does the automaton accept strings over the alphabet {0,1}?” ci aspetteremmo di individuare un'entità di tipo `language` : `[53,58,"language"]` .

2.3.4 Implementazione con spaCy

spaCy è una libreria open-source in Python progettata per l'elaborazione del linguaggio naturale. Offre una serie di strumenti avanzati per l'analisi e la comprensione di testi, tra cui tokenizzazione, lemmatizzazione, part-of-speech tagging e, essenziale per il nostro progetto, la Named Entity Recognition, per la quale ha un motore altamente performante.

Un tipico flusso di lavoro con spaCy prevede la creazione di un “modello” (o il caricamento di un modello pre-addestrato) corrispondente a una determinata lingua, il passaggio di testo a questo modello per il processamento (tokenizzazione, tagging, ecc.) e, se necessario, la personalizzazione o l'addestramento ulteriore delle varie componenti. Proprio quest'ultimo aspetto - l'addestramento di un modello di Named Entity Recognition - è al centro di questa sezione.

Caricamento dati in formato Doccano JSONL

La prima componente fondamentale è la classe `NERData` , che si occupa di caricare e rappresentare i dati etichettati in formato Doccano JSONL. Doccano produce un file in cui ogni riga corrisponde a un esempio di testo con le relative annotazioni (indici di inizio/fine e nome dell'etichetta). Bisogna notare come il file non sia un vero e proprio JSON, ma una sequenza di righe JSON, ciascuna contenente un singolo esempio.

Per questo motivo al momento dell'importazione è essenziale leggere il file riga per riga e caricare ogni esempio separatamente, come effettuato dal metodo di inizializzazione della Classe 2, `NERData` .

```

class NERData:
    """
    A class to represent NER data in Doccano JSONL format.
    """

    def __init__(self, line: str):
        data = json.loads(line.strip())

        self.text: str = data['text']
        self.labels: list[SpacyEntity] = data.get('label', []) # (start, end, label)
        self.entity_labels = list({label for (_, _, label) in self.labels})

    @staticmethod
    def load_jsonl_data(file_path: Path) -> list['NERData']:
        """
        Convert Doccano JSONL format to spaCy training data format.
        """
        with file_path.open('r', encoding='utf-8') as f:
            return [NERData(line) for line in f]

    def make_example(self, nlp):
        doc = nlp.make_doc(self.text)
        annotations = {"entities": self.labels}
        return Example.from_dict(doc, annotations)

```

Classe 2: La classe `NERData` permette di gestire in modo semplice i dati etichettati in formato Doccano JSONL.

L'idea alla base segue design pattern comuni per la gestione dei dati:

- La classe si occupa di rappresentare un singolo esempio, con il testo e le relative annotazioni;
- Il metodo `load_jsonl_data` si occupa di caricare tutti gli esempi da un file JSONL e restituirli come una lista di oggetti `NERData`. Per poterlo fare, viene sfruttato il costruttore della classe in modo da rendere il codice più modulare e manutenibile possibile;
- Il metodo d'istanza `make_example` converte un esempio in un formato compatibile con spaCy [58], [59], in modo da poter essere utilizzato per l'addestramento del modello.

Pre-elaborazione dei dati

Una volta caricati i dati, il passo successivo consiste nell'analisi delle etichette e nella suddivisione in train set e validation set. Per questo scopo, si utilizzano due funzioni.

```

def prepare_multilabel_data(entities: list[NERData]) -> tuple[ndarray, list[str]]:
    """
    Prepare multilabel data for NER entities, converting them into
    a binary matrix format using MultiLabelBinarizer.
    """
    binarizer = MultiLabelBinarizer()
    all_labels = [e.entity_labels for e in entities]
    binarizer.fit(all_labels)

    label_matrix = binarizer.transform(all_labels)
    return label_matrix, binarizer.classes_

```

Funzione 4: La funzione `prepare_multilabel_data` si occupa di preparare i dati etichettati per l'addestramento del modello NER.

La Funzione 4 sfrutta un `MultiLabelBinarizer` dal modulo `sklearn.preprocessing` per convertire le etichette multiclasse in un formato binario, in modo da poterle utilizzare per

l'addestramento di un modello di classificazione. Questo passaggio è essenziale per poter addestrare un modello di NER, che deve essere in grado di riconoscere più entità contemporaneamente.

```
def stratified_split(entities: list[NERData],
                    label_matrix,
                    val_size=0.2,
                    random_state=42) -> tuple[list[NERData], list[NERData]]:
    """
    Perform a stratified split on multilabel data using
    MultilabelStratifiedShuffleSplit.
    """
    msss = MultilabelStratifiedShuffleSplit(n_splits=1,
                                           test_size=val_size,
                                           random_state=random_state)

    train_indices, test_indices = next(msss.split(np.zeros(len(label_matrix)),
                                                label_matrix))

    train_data = [entities[i] for i in train_indices]
    test_data = [entities[i] for i in test_indices]

    return train_data, test_data
```

Funzione 5: La funzione `stratified_split` si occupa di dividere i dati in training set e validation set in modo stratificato.

Invece, grazie a `MultilabelStratifiedShuffleSplit` dal modulo di estensione di scikit-learn `iterstrat.ml_stratifiers`, la Funzione 5 divide i dati in modo stratificato, garantendo che le proporzioni delle etichette siano mantenute sia nel training set che nel validation set. Questo è particolarmente importante quando si lavora con dataset multiclasse, in cui alcune etichette possono essere sottorappresentate e rischierebbero di non essere presenti in uno dei due set.

Addestramento del modello

Vediamo ora a step come la funzione `train_spacy` è implementata. Questa funzione si occupa di addestrare un modello di Named Entity Recognition con spaCy, partendo dai dati preparati e suddivisi in precedenza.

1. Creazione del modello spaCy a partire da zero: definiamo una nuova pipeline vuota, a cui viene aggiunto esclusivamente il componente per la NER. Registriamo anche tutte le etichette possibili nella pipeline:

```
nlp = spacy.blank(language)
ner = nlp.add_pipe('ner', last=True)

for label in label_list:
    ner.add_label(label)
```

Normalmente, nel caso in cui si dovesse addestrare una pipeline più complessa, spaCy offre la possibilità di descriverla in un file di configurazione. Dal momento che la NER sarà preparata per un sistema più grande, è preferibile cercare di ridurre al minimo i file intermedi di configurazione proprio per permettere un controllo più centralizzato.

2. Training loop. Per ogni iterazione:

1. Si mescola il training set che viene poi diviso in piccoli batch:

```
random.shuffle(train_data)
batches = minibatch(items=train_data, size=compounding(4.0, 32.0, 1.001))
```

Il parametro del compounding permette di incrementare gradualmente la dimensione dei batch, partendo da un valore minimo fino a un valore massimo, in modo da bilanciare la varianza e la stabilità dell'addestramento

2. Si itera sui batch e si aggiorna il modello. Usando la funzione `make_example` definita in precedenza, si convertono gli esempi in un formato compatibile con spaCy e si aggiornano i pesi del modello tramite la funzione `update` (che userà internamente la discesa del gradiente):

```
for batch in batches:
    examples = [el.make_example(nlp) for el in batch]
    nlp.update(examples, drop=0.5, sgd=optimizer, losses=losses)
```

3. Valutazione. Alla fine di ogni epoca, si valuta il modello sul validation set e si calcolano le metriche di interesse (precision, recall, F1 score):

```
with nlp.use_params(optimizer.averages):
    examples = [el.make_example(nlp) for el in val_data]
    scores = nlp.evaluate(examples)
```

Come si può notare, l'addestramento di un modello di NER con spaCy richiede poche righe di codice, grazie alla semplicità e alla flessibilità della libreria. Inoltre, la modularità delle componenti (tra cui `NERData`, `prepare_multilabel_data`, `stratified_split`) permette di mantenere il codice pulito e facilmente estendibile, adattandolo a nuovi dataset o a nuove esigenze.

2.3.5 Valutazione e performance




Grafico 6: Performance di F1 del modello di NER durante l'addestramento.

Anche nel caso della Named Entity Recognition la metrica di riferimento è l’F1 score, che tiene conto sia della precisione che del recall del modello. Nel Grafico 6 possiamo vedere come l’F1 score del modello si stabilisca quasi fin dall’inizio oltre il 90%, confermando la bontà del training set e la capacità del modello di generalizzare correttamente le entità riconosciute.

Prese singolarmente, le tre tipologie di entità del training set (`input` , `node` , `language`) mostrano performance molto simili, con un F1 score medio intorno al 92%. Questo indica che il modello è in grado di riconoscere con precisione e recall elevati le entità di interesse, indipendentemente dalla loro categoria.

2.4 Conclusioni

Nel corso di questa sezione si è evidenziata l’evoluzione dei sistemi di comprensione del linguaggio naturale (NLU) partendo da soluzioni rule-based, come AIML, fino ad arrivare a modelli neurali di classificazione degli intenti e riconoscimento delle entità. Da un lato, AIML ha dimostrato di essere un valido framework per realizzare rapidamente chatbot rule-based, con una curva di apprendimento relativamente bassa e un buon controllo sulle risposte generate. Dall’altro però, la sua rigidità strutturale e la limitata capacità di gestire varianti linguistiche, contesto conversazionale esteso e dati dinamici ne hanno evidenziato i limiti in scenari più complessi.

In risposta a queste criticità, l’**integrazione di modelli neurali** —prime fra tutte le architetture Transformer pre-addestrate— ha consentito di ottenere **prestazioni significativamente superiori** nella classificazione di intenti, come dimostrato dai risultati sperimentali.

L’uso di dataset etichettati, arricchiti anche tramite tecniche di data augmentation, ha mostrato l’efficacia dell’approccio supervisionato, evidenziando notevoli **miglioramenti** rispetto alle soluzioni puramente rule-based. Inoltre, l’introduzione di un componente di Named Entity Recognition, addestrato con strumenti come spaCy, ha permesso di gestire le informazioni all’interno del testo (input dell’automa, nodi, linguaggio accettato, ecc.), facilitando l’**estrazione di conoscenza strutturata** con lo scopo di potenziare la comprensione e la risposta del chatbot.

Le sperimentazioni descritte mettono in luce come l’unione di classificazione di intenti e riconoscimento delle entità possa fornire un **notevole salto di qualità** rispetto ai paradigmi conversazionali tradizionali. Nella prossima sezione, essendoci ora soffermati sull’*understanding*, affronteremo invece la generazione di risposte fluide e coerenti, esplorando le potenzialità dei modelli di generazione del linguaggio e le sfide legate alla creazione di conversazioni più umane e naturali.

3 Retrieval-Augmented Generation

Nel contesto di un sistema di dialogo, la generazione del linguaggio naturale (NLG) è una delle componenti fondamentali affinché il sistema possa effettivamente comunicare con gli utilizzatori in modo efficace.

Una volta che abbiamo compreso l'intenzione dell'utente, dobbiamo generare una risposta che sia **coerente con la richiesta** e che **fornisca un qualche valore** all'interlocutore, senza scordare che quest'ultima deve essere comprensibile. Il processo può essere svolto in diversi modi, a seconda delle esigenze e delle capacità del sistema stesso.

La Sezione 3 punterà ad illustrare le tecniche di generazione del linguaggio naturale studiate per lo sviluppo del sistema, mentre la Sezione 4 si occuperà di mostrare più nel dettaglio come queste siano rese disponibili per i botmaster nell'implementazione vera e propria.

Il paradigma della Retrieval-Augmented Generation rappresenta un'evoluzione naturale rispetto agli approcci tradizionali di generazione del linguaggio naturale. In questo contesto, il sistema non si limita a “inventare” la risposta basandosi esclusivamente sul modello linguistico, ma integra un modulo di recupero che seleziona informazioni aggiornate e pertinenti da fonti esterne, garantendo così una maggiore accuratezza e contestualizzazione.

Nelle sezioni seguenti vedremo che il processo è divisibile in due fasi principali:

1. **Il recupero dei dati:** senza informazioni, il sistema non può generare risposte significative. In questa fase, un componente dedicato interroga basi di conoscenza (database, archivi testuali o contenuti web) per estrarre informazioni rilevanti in relazione alla richiesta dell'utente. Tale processo assicura che il sistema disponga di dati aggiornati e specifici, superando i limiti di conoscenza statica tipici di alcuni modelli NLG tradizionali. In questo modo, minimizziamo i rischi che il passaggio successivo generi risposte incoerenti o non pertinenti;
2. **La generazione delle risposte:** una volta che il sistema ha a disposizione i dati necessari, può procedere con la generazione del testo che verrà presentato all'utente. Successivamente, il modulo generativo elabora le informazioni recuperate, combinandole con la propria capacità linguistica per produrre risposte coerenti e mirate. L'integrazione delle informazioni esterne permette di ottenere contenuti non solo grammaticalmente corretti, ma anche ricchi di valore informativo e contestualizzati alle necessità dell'interlocutore.

3.1 Data Retrieval

Vi possono essere casi in cui il sistema non ha bisogno di recuperare dati o dettagli per poter rispondere; in questi casi, la risposta può essere generata direttamente dal sistema stesso, senza bisogno di informazioni aggiuntive. Questa situazione è tipica quando il sistema deve rispondere a domande prestabilite o statiche, come ad esempio quelle relative a informazioni generali o a domande di cortesia.

Possiamo pensare ad esempio a interazioni basilari da inizio conversazione, le cui risposte sono fisse e non necessitano di alcun tipo di elaborazione, come:

- Semplici saluti: “Ciao!”, “Potresti aiutarmi?”;
- Informazioni generali: “Qual è il tuo nome?”, “Come posso contattare il servizio clienti?”;

- Interazioni di cortesia: “Grazie!”, “A presto!”.

In questi casi, è evidente che il sistema non abbia bisogno di recuperare ulteriori dati o dettagli **potenzialmente variabili a seconda del contesto** per poter rispondere, ma che possa generare la risposta direttamente.

Se invece il sistema deve fornire informazioni specifiche o personalizzate, allora è necessario che sia in grado di recuperare i dati necessari per generare la risposta. Questo processo può avvenire in diversi modi, a seconda delle esigenze del sistema, della complessità delle informazioni richieste e del modo in cui queste sono strutturate e salvate.

3.1.1 Basi di conoscenza strutturate

Le basi di conoscenza costituiscono una delle fonti più affidabili da cui un sistema di dialogo può attingere informazioni. La loro natura ordinata, con tabelle, relazioni e campi ben definiti, assicura una gestione dei dati che riduce la possibilità di incongruenze o duplicazioni. Allo stesso tempo, la costruzione e la manutenzione di uno schema ben progettato richiedono un certo impegno iniziale, poiché bisogna prevedere in anticipo quali tipi di informazioni saranno necessari all’interno del sistema.

In uno scenario di dialogo, il processo di risposta idealmente seguirebbe due passi. Consideriamo ad esempio la domanda “Vorrei informazioni sul mio ordine numero 25565”:

1. Prima di tutto il sistema riconoscerebbe il genere di richiesta posta dall’utente. Ipotizzando una classificazione simile a quella discussa nella Sezione 2.2 (quindi con uno o più livelli di classificazione dell’intent), riusciremmo a comprendere che la richiesta è legata al recupero di informazioni su un ordine.
2. Una volta identificato l’intent, mediante un modello di NER, il sistema estrarrebbe il valore di `orderId` dalla frase dell’utente, per poi interrogare una base di dati, tramite un prepared statement SQL [60], per recuperare i dettagli dell’ordine richiesto. Un esempio di query per il recupero di dettagli di un ordine in un sistema e-commerce potrebbe essere come quello presentato nella Query 1.

```
SELECT customer_name, order_date, total_amount
FROM orders
WHERE order_id = :orderId
# Aggiungiamo un vincolo per evitare accessi non autorizzati
AND customer_id = :customerId;
```

Query 1: Esempio di query SQL per il recupero di dettagli di un ordine in un sistema e-commerce.

L’esecuzione dell’interrogazione restituisce al modulo di generazione del linguaggio naturale i dettagli necessari a comporre una risposta personalizzata; un ulteriore vantaggio di questo approccio risiede nella possibilità di definire in anticipo diversi vincoli e relazioni che facilitano la coerenza dei dati.

In alternativa alla struttura difficilmente variabile (una sfida comunque superabile!¹⁰) in produzione di un database relazionale, un database NoSQL può risultare altrettanto efficace.

¹⁰<https://softwareengineering.stackexchange.com/questions/235785/how-to-handle-unexpected-schema-changes-to-production-database>

Nel dominio della *Knowledge Representation* sono stati definiti alcuni linguaggi il cui scopo è permettere di rappresentare conoscenze strutturate e complesse, dalle quali è anche possibile inferire nuove informazioni.

Alla base vi è RDF (Resource Description Framework), un modello di dati che permette di rappresentare informazioni in forma di triple `<soggetto, predicato, oggetto>`, e il suo linguaggio di interrogazione SPARQL [61].

Le annotazioni in formato Turtle (Snippet 16) ad esempio ci permettono di rappresentare un Grafo RDF testualmente, rendendolo facilmente comprensibile da un lettore.

```
BASE <http://example.org/>
# Definiamo degli IRI, ovvero identificatori di risorse che abbreviano URL più lunghi
PREFIX rdf: <http://www.w3.org/1999/02/22-rdf-syntax-ns#>
PREFIX rdfs: <http://www.w3.org/2000/01/rdf-schema#>
PREFIX foaf: <http://xmlns.com/foaf/0.1/>
PREFIX rel: <http://www.perceive.net/schemas/relationship/>

<#green-goblin>
  rel:enemyOf <#spiderman> ;
  a foaf:Person ;
  foaf:name "Green Goblin", "Goblin"@it .

<#spiderman>
  rel:enemyOf <#green-goblin> ;
  a foaf:Person ;
  foaf:name "Spiderman", "Uomo Ragno"@it .
```

Snippet 16: Esempio di annotazione in formato Turtle per il film d'animazione *Gli Incredibili* e il suo regista.

Questo modello è alla base di molte knowledge base, come DBpedia [62] e Wikidata [63], che raccolgono informazioni strutturate su una vasta gamma di argomenti. Le basi di conoscenza sono normalmente codificate su file, in formati come RDF/XML [64] o Turtle [65].

Anche in questo caso, dovendo rispondere a una richiesta come “Chi ha diretto il film d'animazione *Gli Incredibili*?¹¹”, una volta determinato l'intent ed estratta la named entity del film, possiamo recuperare in modo preciso le informazioni necessarie con la Query 2.

```
PREFIX dbo: <http://dbpedia.org/ontology/>
PREFIX dbr: <http://dbpedia.org/resource/>

SELECT ?director
WHERE {
  dbr:The_Incredibles dbo:director ?director .
}
```

Query 2: Esempio di query SPARQL per il recupero del regista del film Inception.

Ricevuta la risposta (`dbr:Brad_Bird` ¹²), interagendo coi campi `dbp:name` e `dbo:thumbnail` dell'entità, il sistema potrà rapidamente comporre una risposta completa (se usassimo un template, ne risulterebbe “Il film *Gli Incredibili* è stato diretto da Brad Bird”) e arricchirla con un'immagine del regista.

¹¹http://dbpedia.org/resource/The_Incredibles

¹²https://dbpedia.org/page/Brad_Bird

3.1.2 Corpora non testuali

A differenza delle knowledgebase strutturate, i corpora testuali non strutturati offrono la possibilità di attingere a un bacino molto più ampio e flessibile di informazioni, ma richiedono tecniche di recupero dati più complesse per poter restituire risultati pertinenti. Questi corpora possono includere documenti di varia natura, come articoli, pagine web, FAQ, manuali e qualsiasi altro contenuto scritto che non segua uno schema predeterminato.

I metodi tradizionali di Information Retrieval si basano solitamente su indici inversi o modelli a spazio vettoriale, come TF-IDF¹³ [66] o BM25 [67], che confrontano la query dell'utente con i termini presenti nel corpus. Sebbene questi approcci siano ancora efficaci in molti scenari, con l'evoluzione dei modelli neurali è possibile sfruttare reti specializzate che codificano frasi e documenti in uno spazio di embedding semantico. Un esempio diffuso è l'utilizzo di Sentence-BERT [68], che permette di generare vettori numerici rappresentativi del significato di un testo e, di conseguenza, di calcolare la similarità fra query e documenti in modo più accurato rispetto alle semplici corrispondenze di parole chiave.

Per illustrare questo principio possiamo studiare lo Script 3 che adopera la libreria `sentence-transformers`. Dopo aver calcolato gli embeddings¹⁴ dei documenti del corpus e della query utente, calcoliamo la **cosine similarity** tra di essi e identifichiamo l'indice del documento più affine dal punto di vista semantico. La differenza sostanziale rispetto a metodi tradizionali consiste nel fatto che l'uso di embeddings semantici permette di riconoscere relazioni di significato **anche quando il lessico non coincide esattamente**.

```
from sentence_transformers import SentenceTransformer, util

# Carichiamo un modello pre-addestrato
model = SentenceTransformer('all-MiniLM-L6-v2')

# Supponiamo di avere un piccolo corpus di documenti
corpus = [
    "Questo è un documento sul funzionamento dei sistemi di dialogo.",
    "Ecco un articolo sui vantaggi dei knowledge graph.",
    "Una breve introduzione all'Information Retrieval."
]
corpus_embeddings = model.encode(corpus, convert_to_tensor=True)

# Definiamo la query dell'utente
query = "Cosa sono i sistemi di dialogo?"
query_embedding = model.encode(query, convert_to_tensor=True)

# Calcoliamo la similarità tra la query e i documenti
scores = util.pytorch_cos_sim(query_embedding, corpus_embeddings)[0]
best_score_idx = scores.argmax().item()

print("Testo più simile:", corpus[best_score_idx])
```

Script 3: Esempio di utilizzo di Sentence-BERT per trovare il documento più simile a una query.

Integrando un simile modulo di retrieval in un sistema di dialogo, è possibile estendere la copertura informativa ben oltre i limiti di una base di dati strutturata, sebbene ciò comporti

¹³Term Frequency-Inverse Document Frequency

¹⁴Strutture che codificano il testo numericamente per permettere di effettuare operazioni matematiche, come la **cosine similarity**

un aumento della complessità. Le performance dipendono, infatti, dalla qualità del modello neurale e dalla quantità di risorse computazionali disponibili per l'indicizzazione e la ricerca.

Il ricorso a corpora testuali non strutturati è particolarmente utile nei sistemi open-domain, dove l'utente potrebbe porre quesiti su una gamma di argomenti molto ampia. L'ampiezza della base informativa fornisce un potenziale enorme, a condizione di implementare strategie di filtraggio e ranking dei risultati che riducano il rischio di rumore o di risposte poco rilevanti. In tal senso, molte pipeline di retrieval prevedono una fase di re-ranking [69], nella quale uno o più modelli ricalcolano la pertinenza dei documenti più promettenti prima di fornire la risposta definitiva all'utente.

3.1.3 API e servizi esterni

L'accesso a dati provenienti da fonti esterne in tempo reale rappresenta un altro tassello fondamentale per i sistemi di dialogo moderni. Integrare **API e servizi di terze parti** permette, ad esempio, di fornire aggiornamenti meteorologici, visualizzare informazioni sul traffico, ottenere prezzi di mercato o eseguire prenotazioni, arricchendo notevolmente le capacità del sistema.

A differenza delle basi di dati documentali o dei corpora statici, le API espongono endpoint che possono variare da semplici chiamate REST, fino a interfacce più complesse che richiedono autenticazione e parametri di configurazione.

Tipicamente il motore di dialogo intercetta la domanda dell'utente e, riconoscendo la necessità di dati esterni, effettuerà una chiamata API verso il servizio più appropriato. Nel caso di servizi che restituiscono risposte JSON, si può utilizzare un linguaggio di query come JMESPath [70] per filtrare i risultati e isolare solo i campi più rilevanti.

JMESPath è un linguaggio espressivo e leggero, progettato per filtrare, cercare e trasformare dati in formato JSON. A differenza di query tradizionali con linguaggi come SQL, JMESPath è progettato per operare esclusivamente su strutture JSON e consente di navigare in maniera semplice all'interno di oggetti annidati, liste e chiavi complesse. Grazie alla sua sintassi intuitiva, risulta particolarmente utile quando si devono gestire risposte provenienti da API REST, servizi esterni o qualunque altra fonte che fornisca dati in formato JSON.

Supponendo di avere una struttura JSON come quella dello Snippet 17, potremo ad esempio filtrare solo gli articoli che trattano di tecnologia usando la Query 3, che:

1. Filtra la lista di articoli usando il predicato `?category == 'tech'` ;
2. Estrae solo il campo `title` di ciascun articolo.

```
"items": [  
  {"title": "Primo articolo", "category": "tech"},  
  {"title": "Secondo articolo", "category": "sport"},  
  {"title": "Terzo articolo", "category": "tech"}  
]
```

Snippet 17: Esempio di struttura JSON restituita da un'API di news.

```
items[?category == 'tech'].title
```

Query 3: Esempio di espressione JMESPath per estrarre i titoli degli articoli di tecnologia.

Il risultato è una lista che viene popolata in un solo passaggio con tutti i titoli degli articoli. Il sistema di dialogo può quindi usare queste informazioni per formulare una risposta, magari raggruppando i titoli più rilevanti o generando una breve sintesi.

Oltre a restituire dati in forma di testo, alcune API consentono di eseguire azioni che hanno un effetto sul mondo esterno, come prenotare un ristorante o inviare un ordine.

Ciò comporta un aumento delle responsabilità da parte del sistema, il quale deve gestire correttamente eventuali errori o limiti di utilizzo, come soglie massime di richieste al minuto o specifiche politiche di caching.

Al tempo stesso, la capacità di interagire dinamicamente con risorse esterne rende il sistema di dialogo molto più potente e utile, in particolare in contesti in cui la tempestività dell'informazione è fondamentale.

3.2 Generazione di risposte tramite LLM

L'adozione di Large Language Model (LLM) per la generazione di risposte all'interno dei sistemi di dialogo rappresenta uno dei progressi più significativi degli ultimi anni nel campo della Natural Language Generation. Se in passato la creazione di output testuale avveniva in modo per lo più rigido (ad esempio tramite template o frasi predefinite), le recenti architetture neurali basate su transformer—come GPT, T5 o BERT-family—hanno permesso di comporre risposte molto più variegate e contestuali, adattandosi con flessibilità alle esigenze dell'utente.

In un sistema di dialogo però, la sfida non si limita alla sola generazione di testo corretto dal punto di vista linguistico: è altresì fondamentale garantire che la risposta risulti coerente con la domanda, contestualmente appropriata e, soprattutto, informativa. Da un lato, si può pensare all'impiego di una LLM come componente centrale, in cui l'utente fornisce direttamente l'input (ad esempio una domanda) e il modello produce l'output (la risposta). Dall'altro, si può utilizzare lo stesso LLM per operazioni più specifiche, come la parafrasi di risposte già esistenti o l'introduzione di variazioni stilistiche. Una delle strategie più comuni e potenti per interfacciarsi con i LLM è il prompting, vale a dire l'idea di “istruire” il modello riguardo al contesto, al tono e al formato di output desiderato, mediante prompt testuali che forniscono esempi e regole su come generare il testo.

L'uso di LLM diventa ancor più significativo quando si parla di sistemi di dialogo data-driven. In questi casi, la generazione non può basarsi esclusivamente sulle conoscenze latenti del modello, ma deve attingere ai dati recuperati nei passaggi precedenti (tramite query, script o retrieval neurale). In tal modo, il modello produce risposte aggiornate e specifiche, riducendo il rischio di informazioni obsolete o imprecise.

Nelle sottosezioni seguenti verranno illustrati due aspetti fondamentali dell'uso dei LLM nella generazione di risposte. La **Parafrasi** offre la possibilità di riscrivere o variare un testo in modo più o meno profondo, fornendo un valido strumento per evitare ripetizioni pedissequae o allineare lo stile del sistema alle esigenze del contesto. Il **Prompting** rappresenta invece la chiave di volta per guidare la produzione linguistica del modello verso gli obiettivi del sistema di

dialogo, in termini sia di contenuto che di stile comunicativo. Vedremo quindi come un'efficace combinazione di tecniche di parafrasi e di prompt engineering possa sostenere la generazione di risposte coerenti, comprensibili e flessibili, migliorando sensibilmente l'esperienza dell'utente.

3.2.1 Parafrasi

La parafrasi svolge una funzione cruciale nei sistemi di dialogo data-driven: permette infatti di riformulare, con scelte lessicali e strutturali diverse, una risposta che attinge dagli stessi contenuti di base, che rimarranno inalterati.

In un sistema di dialogo che riceve domande simili in momenti diversi, rispondere sempre con la medesima formulazione testuale può trasmettere un senso di rigidità. L'utente potrebbe percepire il sistema come meccanico o "ripetitivo". Integrando un modulo di parafrasi basato su LLM si possono introdurre piccole ma significative variazioni stilistiche, pur mantenendo inalterate le informazioni fondamentali:

Domanda	
Quanto costa la spedizione per l'Italia?	
Risposta da GPT-4o	Risposta da GPT-4o
La spedizione in Italia costa 5 euro e in media impiega 3 giorni lavorativi.	La tariffa di spedizione per l'Italia è di 5 euro, con una consegna stimata in 3 giorni.

In alcuni contesti, la stessa informazione deve essere presentata con stili differenti: più formale o colloquiale, più conciso o descrittivo. Le LLM odierne consentono di riformulare un testo attraverso un prompt mirato, descrivibile come una tecnica **few-shots** (discussa nella Sezione 3.2.2):

Prompt A	Prompt B
Riscrivi il seguente paragrafo con uno stile tecnico, mantenendo i contenuti originali e senza introdurre variazioni nei dati: [...]	Modifica il seguente testo in modo che risulti più colloquiale e breve: [...]

Qualora il sistema debba attingere a documenti esterni, articoli o risorse protette, la parafrasi può prevenire problemi di copyright (purché sia garantita la corretta attribuzione delle fonti). Aniché inserire stringhe letteralmente copiate, il sistema riformula i concetti principali, ottimizzando il flusso del dialogo e riducendo i rischi legali o di duplicazione.

Per implementare la parafrasi, si può sfruttare una LLM appositamente addestrata o semplicemente vincolata attraverso un prompt. Il flusso di lavoro risultante sarà tipicamente diviso in tre fasi:

1. **Recupero dei dati:** il sistema ottiene i contenuti rilevanti dalla knowledge base o da un documento, come descritto nella Sezione 3.1;

2. **Formulazione del prompt:** invece di richiedere semplicemente “Genera una risposta che spieghi X”, si invia al modello una richiesta che include il testo da parafrasare e le specifiche sullo stile o la lunghezza desiderata;
3. **Generazione del testo:** la LLM produce una variante testuale dell’input, che può essere arricchita da sfumature stilistiche dipendenti dal contesto.

In base alle esigenze, la parafrasi può essere usata in modo selettivo soltanto in alcuni passaggi della conversazione, ad esempio per differenziare i saluti iniziali o per riformulare un concetto ripetuto. Nella fase di valutazione, come vedremo, è doveroso controllare la coerenza semantica tra testo di partenza e testo riformulato, utilizzando metriche come BLEU, ROUGE o similitudini di embedding.

3.2.2 Prompting

Come evidenziato da diversi lavori in letteratura (Z. Kasner e O. Dušek [71], S. Yuan e M. Faerber [72]), l’impiego di Large Language Model (LLM) per la generazione di risposte basate su dati si sta rivelando una strategia sempre più diffusa, ma al contempo complessa da controllare.

Da un lato, i modelli di grandi dimensioni forniscono una notevole fluidità e flessibilità testuale, dall’altro espongono il sistema al rischio di introdurre **allucinazioni**, omissioni o errori semantici.

Il termine *allucinazioni*, nel contesto delle LLM, si riferisce a risposte generate dal modello che non sono supportate dai dati forniti nel prompt o che sono incoerenti con il contesto della conversazione. Possono anche contenere informazioni “inventate” o totalmente errate. È una delle sfide principali nella generazione di testo con LLM, specialmente in contesti data-driven.

All’interno di questo generi di sistemi di dialogo, il prompting acquisisce ulteriore rilevanza, poiché occorre integrare nel prompt non solo il contesto della conversazione e l’intenzione dell’utente, ma anche i dati recuperati nella fase di retrieval.

Per costruire un prompt efficace, è buon uso considerare i seguenti aspetti:

- **Chiarezza dell’istruzione:** è importante esplicitare in modo chiaro cosa si vuole che il modello faccia. Richieste seguite da contesto e vincoli specifici possono orientare molto meglio la generazione rispetto a richieste vaghe o incomplete:

Prompt

Ecco i dati estratti dal database di e-commerce:

- Prezzo dell’articolo: 49,99 euro
- Tempi di spedizione: 2 giorni
- Colori disponibili: rosso, blu, verde

Genera una breve risposta da mostrare al cliente, evitando informazioni non pertinenti e senza inventare nulla.

Risposta da GPT-4o

L'articolo è disponibile nei colori rosso, blu e verde al prezzo di 49,99 euro. I tempi di spedizione sono di 2 giorni.

- **Contestualizzazione:** la LLM deve essere messa nella condizione di “vedere” i dati recuperati in precedenza, per non attingere soltanto a conoscenze latenti nel proprio addestramento. Fornire uno snippet del testo rilevante, una lista di fatti chiave, o delle triple di un knowledge graph aumenta la probabilità che il modello usi correttamente i dati.
- **Vincoli e stile:** se si desidera uno stile specifico (ad esempio formale, tecnico o più narrativo), si può precisare il *tone of voice* all'interno del prompt:

Aggiunta al Prompt

Spiega questi dati come se stessi illustrandoli a un bambino di 10 anni, utilizzando un linguaggio semplice e frasi brevi.

Anche la lunghezza desiderata della risposta, l'utilizzo di determinate parole chiave o la struttura desiderata possono essere indicati come vincolo:

Aggiunta al Prompt

Usa i dati forniti per creare una tabella in linguaggio Markdown con due colonne: 'Caratteristica' e 'Valore'. Non aggiungere ulteriori colonne.

- **Protezione dalle allucinazioni:** Per limitare la tendenza dei modelli a “inventare” fatti non inclusi nei dati, si possono inserire frasi di avvertenza, come:

Aggiunta al Prompt

Se non trovi nei dati un'informazione necessaria, dichiara che non è disponibile. Non introdurre informazioni che non siano presenti nell'elenco qui sotto.

In alcuni studi (A. Axelsson e G. Skantze [73]), questa strategia riduce il numero di imprecisioni, anche se non le elimina completamente.

Un esempio di prompt generico che segue le indicazioni presentate potrebbe essere il seguente:

Prompt

Ecco i dati rilevanti estratti dal database: [lista_json].
Tenendo conto di questi dati e della domanda dell'utente [domanda_utente], genera una risposta chiara e completa. Scrivi in modo formale e non superare i 100 token nella risposta.

È essenziale tuttavia valutare la complessità del compito, in quanto un'istruzione troppo dettagliata potrebbe confondere il modello, mentre una troppo vaga potrebbe portare a risposte poco soddisfacenti. Con questo fine, è possibile adottare diverse strategie di prompting:

- **Zero-shot:** si formula l’istruzione senza fornire esempi di input-output. Il modello, grazie alle conoscenze apprese durante il pre-addestramento, tenterà di interpretare correttamente la richiesta.
- **Few-shot:** si includono alcuni esempi di output desiderati all’interno del prompt, in modo da fornire una guida esplicita al modello su come rispondere o formulare un certo tipo di contenuto. Questa modalità risulta efficace per compiti specifici o con particolari regole di stile, e coincide con il task di parafrasi visto nella Sezione 3.2.1.
- **Dialogo multi-turno:** in un sistema di dialogo, ogni nuovo turno può arricchire il prompt con un estratto delle interazioni precedenti. In tal modo, la LLM “ricorda” i contesti precedenti e può mantenere la coerenza tematica nel corso della conversazione.

Prompt

Sei un assistente che fornisce informazioni su ordini online. Di seguito trovi una selezione parziale delle interazioni con l’utente:

Utente: “Qual è lo stato di avanzamento del mio ordine?”

Il sistema ha reperito i seguenti dati:

- Ordine n. 1357
- Stato: in spedizione
- Previsione di consegna: 10/04/2025

Ora, rispondi alla domanda dell’utente in modo chiaro e conciso, mantenendo la coerenza con le interazioni precedenti:

Risposta della LLM (GPT-4o)

Il tuo ordine n. 1357 è in spedizione e arriverà indicativamente il 10/04/2025.

Come mostrato da A. Axelsson e G. Skantze [73], un LLM come ChatGPT può generare testi in modo ragionevole anche zero-shot, ossia senza essere specificamente addestrato su un particolare set di dati. Tuttavia, gli autori mettono in luce come il modello possa omettere parte dei contenuti provenienti dalla base di conoscenza o, al contrario, inserire dati allucinati, soprattutto se il dominio è complesso o i dati non corrispondono a conoscenze di dominio già acquisite dal modello in fase di pretraining. Questi limiti emergono con maggiore evidenza quando i dati da trasformare in testo appartengono a domini poco noti al modello o, addirittura, sono controfattuali o fittizi, e quindi non rientrano nella conoscenza pregressa del LLM.

Un quadro simile è proposto anche da S. Yuan e M. Faerber [72], che hanno confrontato GPT-3 e ChatGPT su benchmark di generazione testuale a partire da knowledge graph. I risultati dimostrano che i modelli di generazione, se impiegati in modalità zero-shot, ottengono buone performance di scorrevolezza, ma faticano a mantenere l’accuratezza semantica, finendo con l’inserire dettagli inventati o non coerenti.

Inoltre, test su diverse LLM mostrano come il testo prodotto dai modelli conservi pattern facilmente riconoscibili [74]. Ciò rafforza l’idea che l’LLM, seppur potente, abbia bisogno di prompting e controlli specifici per non produrre contenuti fuorvianti o ripetitivi.

3.3 Qualità delle risposte

Durante la mia ricerca ho deciso di utilizzare diverse LLM per valutare le potenziali variazioni di output e la qualità delle risposte generate. Le valutazioni in questa sezione sono state effettuate su un numero ristretto di modelli e domande dal momento che la disponibilità di annotatori umani è stato un fattore limitante.

Il processo che ho seguito coincide con quello proposto da Z. Kasner e O. Dušek [71] (se non per l'introduzione di alcune metriche di valutazione aggiuntive), che possiamo riassumere nei seguenti passaggi.

3.3.1 Selezione dei modelli

Ho deciso di utilizzare 5 modelli di LLM, tra cui tre locali (`deepseek-r1:8b` , `gemma2:9b` , `llama3.1:8b`) e due modelli cloud (`gpt-4o` , `o3-mini`). La scelta è stata presa con lo scopo di confrontare modelli di diverse dimensioni e complessità, valutando le differenze di output e la qualità delle risposte tra modelli open source (e open weights) e modelli cloud-based ma closed-source.

La decisione non è casuale: la disponibilità di modelli fondazionali open source e open weights gioca un ruolo determinante su più livelli.

In primo luogo, essa consente una maggiore **trasparenza e accountability**: rendendo pubblici i pesi e la struttura dei modelli, si favorisce una comprensione approfondita dei meccanismi decisionali degli algoritmi, permettendo di identificare e correggere eventuali bias o anomalie. Questo livello di apertura è fondamentale non solo per garantire la sicurezza e l'affidabilità degli strumenti AI, ma anche per promuovere un utilizzo responsabile e conforme agli standard etici emergenti.

In secondo luogo, l'accesso libero ai modelli permette a ricercatori, accademici e sviluppatori di effettuare **verifiche indipendenti** e **test approfonditi**. Tale approccio, incentivando la replicabilità e la validazione esterna, diviene un importante strumento per valutare la robustezza e la resilienza dei modelli, contribuendo a mitigare rischi potenzialmente legati a vulnerabilità o comportamenti imprevisti. Ciò risulta particolarmente significativo in un panorama in cui la rapidità di sviluppo delle tecnologie AI richiede metodologie rigorose di controllo e verifica.

Inoltre, l'adozione di modelli open source stimola l'**innovazione** e la **competizione** nel settore: la loro disponibilità abbassa le barriere d'accesso, consentendo a startup e centri di ricerca di sperimentare e sviluppare nuove soluzioni senza dover necessariamente sostenere gli elevati costi associati a tecnologie proprietarie.

Si pensi anche solo a come, per questa tesi, sia stato possibile eseguire modelli di medie dimensioni come `llama3.1` o `Deepseek-r1` senza dover ricorrere a servizi cloud o a infrastrutture dedicate, o come oggi stiano nascendo innumerevoli progetti open source che sfruttano modelli locali per risolvere problemi di vario genere, dalla home automation [75] ai servizi di assistenza virtuale.

Tale dinamica favorisce la nascita di un ecosistema più variegato e dinamico, in cui il confronto tra approcci e metodologie diverse arricchisce il progresso tecnologico complessivo.

L'open source promuove l'inclusività e supporta la regolamentazione e la ricerca pubblica [29]. Un accesso ampio e democratico ai modelli AI permette agli enti regolatori e alla comunità

scientifica di monitorare l'evoluzione delle tecnologie, identificando tempestivamente criticità e proponendo interventi correttivi che possano tutelare gli utenti e garantire uno sviluppo sostenibile e responsabile [13], [76].

Da notare anche come, a seconda dei modelli utilizzati, vi possano essere pattern linguistici preferiti dai modelli stessi, che possono influenzare la qualità delle risposte, e che possono renderli facilmente identificabili da parte degli utenti, come evidenziato da M. Sun, Y. Yin, Z. Xu, J. Z. Kolter, e Z. Liu [74] all'inizio di quest'anno.

3.3.2 Raccolta delle domande

Ho selezionato un insieme di 15 domande provenienti dal validation set già presentato nella Sezione 2.2.8. Le domande sono state scelte in modo da includere quelle che ho ritenuto con le maggiori potenzialità di fornire risultati significativi per le analisi.

L'automa utilizzato per le domande è presentato nel Diagramma 3, proveniente dal Corpus prodotto durante la ricerca svolta da E. Di Nuovo, M. Sanguinetti, A. Mazzei, L. Anselma, C. Bernareggi, e P. F. Balestrucci [9] su NoVAGraphS.




Diagramma 3: Automa a stati finiti per la generazione delle domande. Una rappresentazione in formato Graphviz dell'automa è presente nello Snippet 19.

Le domande scelte sono le seguenti:

- *Would you say that the automaton is directed?*
- *Could you tell me whether the automaton is directed?*
- *Can you describe the automaton's input and output symbols?*
- *Could you identify the grammar or set of symbols that the automaton recognizes?*
- *Could you highlight the primary aspects of state q0?*
- *Can you provide more details about state q0?*
- *Which state or states are considered final?*
- *What are the final states in the automaton?*
- *Does a directed arc exist from q1 to q0?*
- *Is q0 directly connected to q1 by a transition?*
- *Can you spot any transition where the start and end state are identical?*
- *Is there a looping transition from a state back to the same state?*
- *What are the incoming and outgoing transition paths for q1?*
- *What links are present for state q2 in the automaton?*
- *What are the entry and exit transitions for state q2?*

3.3.3 Generazione delle risposte

Ho utilizzato i modelli per generare risposte in modo zero-shot, senza ulteriori addestramenti. Ogni domanda è stata inviata a ciascun modello, che ha prodotto una risposta testuale. Le

domande non sono state presentate senza alcuna informazione ai modelli, ma utilizzando il seguente prompt:

```
You are a helpful assistant expert in finite state automata.
Answer the question given by the user using the retrieved data, using plain text only.
Avoid referring to the data directly; there is no need to provide any additional
information.
Keep the answer concise and short, and avoid using any additional information not provided.

The system has retrieved the following data:
\ \ \
{data}
\ \ \

The user has asked the following question:
\ \ \
{question}
\ \ \
```

Snippet 18: Prompt utilizzato per la generazione delle risposte.

Mentre `{question}` è stata sostituita con la domanda corrente, `{data}` è popolato dalla rappresentazione in formato `Graphviz` dell'automa a stati finiti mostrato nel Diagramma 3, assieme alle informazioni necessarie per rispondere (assumendo che la classificazione sia accurata al 100% e non abbia commesso errori).

```
digraph FSA {
    rankdir=LR;
    node [shape = circle];
    q0 [shape = doublecircle];
    q1; q2; q3; q4;

    start [shape=none, label=""]; // Invisible start indicator
    start -> q0; // Start arrow pointing to starting state

    q0 -> q1 [label = "1"];
    q1 -> q2 [label = "1"];
    q2 -> q3 [label = "1"];
    q3 -> q4 [label = "0"];
    q4 -> q0 [label = "0"];
}
```

Snippet 19: Rappresentazione in formato `Graphviz` dell'automa a stati finiti utilizzato come input per le domande.

In questo modo, i modelli sono anche stati valutati verificando la capacità di estrarre informazioni rilevanti dai dati forniti. Nel contesto del sistema che verrà illustrato nella Sezione 4, il prompt sarà molto più specifico, offrendo alle LLM informazioni aggiuntive che possono ulteriormente guidare la generazione delle risposte. Consideriamo questa fase come baseline per valutare le capacità di generazione dei modelli.

3.3.4 Annotazione manuale

Il passaggio successivo è stato la valutazione delle risposte generate. Come sistema di valutazione, è stato utilizzato lo stesso di Z. Kasner e O. Dušek, che prevede la collaborazione di annotatori umani su un applicativo da loro sviluppato, Factgenie [77], [78].

Il software è una piattaforma web che permette di valutare la qualità delle risposte generate da modelli di LLM, fornendo un'interfaccia intuitiva per gli annotatori (Figura 3).

12345678910111213141516171819202122232425

What are the incoming and outgoing transition paths for q1?

Instructions

IncorrectNot checkableMisleadingOther

Drag your mouse over the text to highlight the span:

Incoming transition for q1 comes from q0 with label "1". Outgoing transition goes to q2 with label "1".
Incoming: q0 → q1 (label "1") Outgoing: q1 → q2 (label "1")

Please check if you agree with any of the following statements:

☒ The text 100% accurate and does not contain any errors.
☐ The text is missing or incomplete.
☐ The text is severely off-topic (seems completely unrelated to the data).

Answer Clearness (if it is understandable)

Completely clear

Answer length (if it was too short to be 100% clear or

Figura 3: Interfaccia di Factgenie per la valutazione delle risposte generate da LLM.

Gli annotatori, dopo aver ricevuto una breve formazione sull'uso dell'applicativo, sono liberi di evidenziare nelle risposte frammenti problematici semplicemente selezionandoli. Sono stati definiti quattro generi di errori:

- **INCORRECT^I**: la risposta contiene informazioni che contraddicono i dati forniti o che sono chiaramente sbagliate.
- **NOT_CHECKABLE^{NC}**: la risposta contiene informazioni che non possono essere verificate con i dati forniti.
- **MISLEADING^M**: la risposta contiene informazioni fuorvianti o che possono essere interpretate in modo errato.
- **OTHER^O**: la risposta contiene errori grammaticali, stilistici o di altro tipo.

Oltre ad evidenziare parti problematiche delle risposte, è stato richiesto agli annotatori anche di fornire delle valutazioni qualitative su alcune metriche:

- **Accuratezza della risposta**: da selezionare quando la risposta è corretta al 100% e non contiene errori sui dati;
- **Assenza o incompletezza di informazioni**: da selezionare quando la risposta non contiene tutte le informazioni rilevanti;
- **Totale incongruenza della risposta**: da selezionare quando la risposta appare completamente scorrelata o non pertinente alla domanda;
- **Chiarezza della risposta**: se è comprensibile e ben strutturata;

58

- **Lunghezza della risposta:** se la comprensione della risposta è facilitata dalla sua lunghezza (o brevità);
- **Utilità percepita della risposta:** se la risposta è utile e fornisce informazioni rilevanti;
- **Apprezzamento generale:** se la risposta è apprezzata o gradita.

In totale, 12 annotatori hanno partecipato alla valutazione delle risposte generate dai modelli. Ogni volontario ha valutato un sottoinsieme delle risposte, garantendo comunque un overlap sulle 75 risposte totali. Per identificarli in questa tesi è stato definito un ε_{hum} , che rappresenta le informazioni risultante dalle annotazioni umane.

3.3.5 Annotazione automatica

In modo simile alle annotazioni prodotte dai volontari, sono state adoperati due modelli di LLM commerciali per valutare in modo automatico la qualità delle risposte generate. Mi sono basato sulla peculiarità di questi modelli di essere facilmente personalizzabili per vari compiti senza particolari necessità di addestramento.

Ho utilizzato i successori di GPT-4, indicati come più aderenti alle specifiche fornite in un certo task (J. Wang *et al.* [79], A. Sottana, B. Liang, K. Zou, e Z. Yuan [80], T. Kocmi e C. Federmann [81]); in particolare, ho utilizzato GPT-o3-mini (indicato come particolarmente in grado di effettuare ragionamenti tramite chain-of-thought [82]) e GPT-4.5, successore attualmente in sviluppo di GPT-4.

In particolare, per la valutazione automatica sono stati definiti ε_{o3} e $\varepsilon_{4.5}$ (uno per modello), che in seguito alle istruzioni sulla task, hanno prodotto una serie di span da loro identificati come problematici. Nello specifico, è stato richiesto ai modelli di produrre una struttura dati JSON contenente le informazioni dello Snippet 20.

```
{
  "errors": [{
    "reason": [REASON],
    "text": [TEXT_SPAN],
    "type": [ERROR_CATEGORY]
  }]
}
```

Snippet 20: Struttura dati JSON prodotta dai modelli per la valutazione automatica delle risposte.

È di particolare importanza l'ordine con cui le proprietà degli oggetti che popolano la lista `errors` sono state riportate: è prima richiesto di generare la motivazione dell'errore in quanto risulta che i modelli tendano a produrre output di precisione più elevata [71].

3.3.6 Risultati

Iniziamo a verificare l'accuratezza dell'output dei vari modelli. Considereremo come baseline i modelli closed source di OpenAI.

Una prima valutazione, disponibile nella Tabella 10, ci rivela che, a seconda del modello, tra il 18.6% e l'83% delle risposte contengono almeno un errore, secondo ε_{hum} . $\varepsilon_{4.5}$ ha individuato almeno un errore nel 6.6-33% delle risposte, mentre ε_{o3} indica un errore nel 6-13% degli output. Considerati questi range, saranno presentati i risultati solo per ε_{hum} e $\varepsilon_{4.5}$, in quanto ε_{o3} ha fornito risultati simili a $\varepsilon_{4.5}$.

Deepseek-r1:8b e Gemma2:9b sono i modelli open che presentano il minor numero di errori, con una percentuale di risposte corrette rispettivamente del 26.7% e del 33.3%.

Modello	Incorrect		Not Checkable		Misleading		Other		Globale	
	ϵ_{hum}	$\epsilon_{4.5}$	ϵ_{hum}	$\epsilon_{4.5}$	ϵ_{hum}	$\epsilon_{4.5}$	ϵ_{hum}	$\epsilon_{4.5}$	ϵ_{hum}	$\epsilon_{4.5}$
Deepseek	20%	13.3%	6.67%	0%	26.7%	6.7%	66.7%	0%	83%	33.3%
Gemma2	26.7%	26.7%	0%	0%	33.3%	0%	20%	6.7%	30.6%	33.3%
Llama3.1	33.3%	33.3%	6.67%	0%	26.7%	6.7%	46.7%	0%	67.3%	53.3%
GPT-4o	20%	6.7%	13.3%	0%	20%	0%	40%	0%	36%	6.6%
GPT-o3-mini	0%	13.3%	0%	0%	13.3%	0%	20%	0%	18.6%	20%

Tabella 10: Percentuali di *risposte contenenti almeno un errore*, secondo le annotazioni umane (ϵ_{hum}) e le valutazioni automatiche ($\epsilon_{4.5}$). Più basso è il valore, migliore è la qualità delle risposte.

L'errore più comune è **OTHER⁹**, indicando che i modelli tendono a produrre risposte grammaticalmente scorrette, stilisticamente inadeguate o ripetitive. In particolare, Deepseek-r1 è il modello che produce più errori di questo tipo, con una percentuale del 66.6% secondo i valutatori umani.

Possiamo anche vedere nella Tabella 11 come, in media, tutti i modelli tendano a produrre meno di un errore **INCORRECT¹** a risposta. Le ottime performance di gpt-o3-mini potrebbero essere dovute sia al fatto che il modello abbia accesso ad ampie risorse di esecuzione, sia al fatto che si tratti di un modello chain-of-thought. Questo genere di modelli, dei quali fa parte anche Deepseek-r1, richiedono più tempo per eseguire, ma tendono a produrre output di maggiore qualità in seguito ad una fase di “ragionamento”.

Questa ipotesi è supportata dai dati: Deepseek-r1, nella sua versione da 8 miliardi di parametri utilizzata in questa valutazione, produce meno errori di GPT-4o (1.26 - 1.46), modello (stimato) da 200 miliardi di parametri [83].

Modello	Incorrect		Not Checkable		Misleading		Other		Globale	
	ϵ_{hum}	$\epsilon_{4.5}$	ϵ_{hum}	$\epsilon_{4.5}$	ϵ_{hum}	$\epsilon_{4.5}$	ϵ_{hum}	$\epsilon_{4.5}$	ϵ_{hum}	$\epsilon_{4.5}$
Deepseek-r1:8b	0.13	0.26	0.07	0	0.1	0.06	0.53	0	0.83	0.33
Gemma2:9b	0.16	0.26	0	0	0.06	0	0.07	0.06	0.31	0.33
Llama3.1:8b	0.29	0.47	0	0	0.07	0.07	0.31	0	0.67	0.53
GPT-4o	0.15	0.07	0.1	0	0.02	0	0.09	0	0.36	0.07
GPT-o3-mini	0	0.2	0	0	0.01	0	0.17	0	0.19	0.2

Tabella 11: Numero medio di *errori per output*, per ogni categoria di errore e in totale, secondo le annotazioni umane (ϵ_{hum}) e le valutazioni automatiche ($\epsilon_{4.5}$). Più basso è il valore (evidenziato per ogni colonna), migliore è la qualità delle risposte.

In termini di chiarezza (Tabella 12), cioè quanto la risposta risulti pienamente comprensibile, GPT-o3-mini produce la percentuale più alta di risposte completamente chiare (oltre il 90%), seguito a breve distanza da GPT-4o (86%). Viceversa, i modelli open source mostrano tassi di chiarezza inferiore: Deepseek-r1:8b e Llama3.1:8b spaziano tra il 60% e il 70%, mentre

Gemma2:9b si ferma al 56%, con il 16% di risposte ritenute non sufficientemente chiare. Questo indica che, per quanto riguarda la formulazione dei contenuti, i modelli GPT-o3-mini e GPT-4o riescono a generare frasi più fluide e comprensibili.

Modello	Completely Clear	Mostly Clear	Unclear
GPT-o3-mini	92.66%	7.33%	0%
GPT-4o	86%	8.66%	5.33%
Deepseek-r1:8b	69.33%	30%	0.66%
llama3.1:8b	63.33%	19.33%	17.33%
Gemma2:9b	56%	28%	16%

Tabella 12: Distribuzione della *chiarezza percepita nelle risposte* per ogni modello.

Un dato che appare strettamente collegato alla chiarezza è la lunghezza percepita delle risposte (Tabella 13). Anche qui GPT-o3-mini produce quasi sempre risposte lunghe il giusto secondo i valutatori (96% dei casi) e solo in rarissime occasioni troppo estese o troppo sintetiche. GPT-4o mantiene numeri simili (89,33%), mentre i modelli open source, in particolare Deepseek-r1:8b e Gemma2:9b, peccano rispettivamente di risposte talvolta troppo lunghe e troppo brevi.

Gemma2:9b produce risposte troppo brevi addirittura nel 50% circa delle interazioni. Andando a verificare la lunghezza effettiva, spesso le risposte di Gemma2:9b marcate come troppo brevi sono composte da una sola parola, che evidentemente non fornisce informazioni sufficientemente chiare agli annotatori.

Modello	Long Enough	Too Long	Too short
GPT-o3-mini	96%	2%	2%
GPT-4o	89.33%	8.66%	2%
llama3.1:8b	78%	8.66%	13.33%
Deepseek-r1:8b	71.33%	24.66%	4%
Gemma2:9b	49.33%	0%	50.66%

Tabella 13: Distribuzione della *lunghezza percepita delle risposte* per ogni modello.

Guardando all'utilità percepita dagli annotatori (Tabella 14), intesa come quanto una risposta sia ritenuta utile nel contesto della domanda associata, GPT-o3-mini si distingue nettamente: quasi il 98% delle sue risposte è ritenuta utile, con una minima quota di risposte "né utili né inutili" e nessuna considerata del tutto priva di valore. GPT-4o mantiene un livello molto alto di utilità (90%), pur avendo un 5% di risposte ritenute di utilità nulla. I modelli open source mostrano differenze notevoli: Deepseek-r1:8b produce un ottimo risultato con l'82% di risposte utili, Llama3.1:8b scende al 68%, mentre Gemma2:9b si ferma al 58.66%, con quasi un quarto delle risposte reputate come prive di utilità per la comprensione dell'automa.

Modello	Useful	Neither Useful nor Useless	Useless
GPT-o3-mini	98%	2%	0%
GPT-4o	90%	4.66%	5.33%
Deepseek-r1:8b	82%	12.66%	5.33%
llama3.1:8b	68%	12%	20%
Gemma2:9b	58.66%	17.33%	24%

Tabella 14: Distribuzione del' *utilità percepita delle risposte* per ogni modello.

Il gradimento generale conferma sostanzialmente queste tendenze Tabella 15. **GPT-o3-mini** è apprezzato in oltre il 95% delle risposte, **GPT-4o** nell'86.66%. I modelli open source registrano un calo, con **Deepseek-r1:8b** apprezzato nel 68% dei casi, **Llama3.1:8b** al 58% e **Gemma2:9b** sotto il 40%. Anche in questo caso, dunque, **GPT-o3-mini** e **GPT-4o** dimostrano di generare testi più convincenti e graditi dagli annotatori.

Modello	Not Appreciated	Appreciated
GPT-o3-mini	4.66%	95.33%
GPT-4o	13.33%	86.66%
Deepseek-r1:8b	32%	68%
llama3.1:8b	42%	57.99%
Gemma2:9b	63.33%	36.66%

Tabella 15: Distribuzione dell' *apprezzamento delle risposte* per ogni modello.

Infine, è interessante vedere (Tabella 16) il tasso di completezza e accuratezza delle risposte ("100% accurate", "informazioni mancanti", "totalmente off-topic"). **GPT-o3-mini** domina chiaramente, con quasi il 99% di risposte completamente corrette rispetto ai dati forniti, e solo lo 0,66% che omette dettagli essenziali. **GPT-4o** si attesta su un 90% di risposte precise, evidenziando però un minimo margine di errore maggiore.

Sul fronte open source, **Deepseek-r1:8b** e **Llama3.1:8b** viaggiano intorno al 70% di risposte pienamente accurate; **Gemma2:9b**, pur avendo una discreta fetta di risposte corrette (66%), nel 27% delle risposte tende ad omettere delle informazioni, evidenziando un problema di incompletezza più marcato.

Modello	100% Accurate	Missing Info	Completely Off Topic
Deepseek-r1:8b	70%	9.33%	0%
Gemma2:9b	66%	27.33%	2%
GPT-4o	90%	4.66%	1.33%
GPT-o3-mini	98.66%	0.66%	0%
llama3.1:8b	71.33%	10.66%	2%

Tabella 16: Distribuzione della *qualità delle risposte* per ogni modello.

Per le ultime osservazioni, può essere utile osservare la correlazione tra le varie metriche di valutazione delle risposte per ogni modello (Diagramma 4). Questo ci permette di capire se esistono relazioni significative tra le diverse dimensioni di valutazione, e se i modelli tendono a produrre output coerenti o meno.




Diagramma 4: Correlazione tra le metriche di valutazione delle risposte per ogni modello.

Dalla matrice di correlazione (calcolata col coefficiente di correlazione di Pearson) si nota innanzitutto che tutte le variabili sono positivamente correlate tra loro; ciò suggerisce che, all’aumentare di una determinata caratteristica (ad esempio la chiarezza percepita), tendono a crescere anche le altre (come l’utilità o il gradimento). Tuttavia, l’intensità di queste relazioni varia sensibilmente:

- **Usefulness e accuracy:** la correlazione più forte è fra utilità percepita e accuratezza (~0.77). In altre parole, le risposte ritenute corrette rispetto ai dati tendono anche a essere giudicate utili per l’utente. È possibile concludere che, se un contenuto è preciso, venga anche percepito come maggiormente informativo o prezioso.
- **Clearness e usefulness:** la seconda correlazione più elevata (~0.69) lega la chiarezza alla percezione d’utilità. Ciò indica che le risposte ben strutturate e comprensibili risultano, agli occhi dell’utente, più utili rispetto a risposte meno nitide. Non sorprende che la fruibilità dipenda molto da quanto il testo sia chiaro e diretto.
- **Clearness e accuracy:** esiste inoltre una correlazione moderata (~0.59) tra chiarezza e accuratezza. Anche se si tratta di due concetti distinti (una risposta può essere formalmente ineccepibile ma “opaca”, oppure chiara eppure carente di dettagli), nel complesso risposte chiare hanno spesso contenuti più precisi — e viceversa. In un sistema di dialogo, ciò può riflettere la tendenza di un buon modello a esprimere in modo ordinato e coerente i dati estratti, evitando di generare confusione (che si tradurrebbe in errori informativi).

- **Correlazioni con l'apprezzabilità:** la percezione positiva da parte dell'utente cresce in parallelo con quasi tutti i parametri, mostrando coefficienti medio-alti. È particolarmente interessante la correlazione con la usefulness (~0.63) e con la clearness (~0.57). Ciò non sorprende: è ragionevole immaginare che l'esperienza di un utente sia complessivamente migliore quando un sistema produce risposte utili, chiare e ragionevolmente precise.
- Da notare anche la correlazione con la **lunghezza** (~0.54): sembrerebbe che una risposta ritenuta “abbastanza lunga” (ma non eccessivamente prolissa) favorisca un giudizio positivo (possiamo immaginare perché fornisca il giusto livello di dettaglio senza risultare ridondante o generica).
- Ruolo della **lunghezza**: la lunghezza percepita delle risposte ha la correlazione più modesta con l'accuratezza (~0.26) e con l'utilità (~0.31), ma mostra un legame più consistente con il gradimento. Questo ci può far ipotizzare che, se da un lato un testo più lungo non necessariamente garantisca risposte più esatte o più utili, dall'altro esiste una tendenza per cui gli utenti apprezzano leggermente di più risposte che non siano troppo sintetiche. La lunghezza potrebbe dunque fungere da “cuscinetto” per includere informazioni e dimostrare padronanza dell'argomento, purché non diventi prolissa.

Sono state escluse dalla matrice di correlazione le metriche attribuite alle risposte parziali (“missing”) o completamente scorrelate (“off-topic”), in quanto non sono stati ottenuti abbastanza dati per poter stabilire relazioni significative.

3.3.7 Conclusioni

In questa sezione abbiamo visto come la generazione automatica di testo all'interno di un sistema di dialogo richieda l'integrazione di molteplici aspetti: dall'estrazione dei dati — tramite basi di conoscenza, corpora testuali o API esterne — alla costruzione di prompt ben progettati, fino alla valutazione qualitativa e quantitativa delle risposte generate. È emerso che l'impiego di modelli di grandi dimensioni (come GPT) consenta di ottenere risultati particolarmente convincenti in termini di chiarezza, utilità e accuratezza. In effetti, modelli come **GPT-o3-mini** hanno saputo mantenere alta la qualità delle risposte, dimostrandosi generalmente più “affidabili” e apprezzati dagli utenti rispetto a diverse alternative open source.

Ciononostante, gli esperimenti svolti evidenziano come anche i modelli open source — pur offrendo prestazioni mediamente inferiori — presentino importanti vantaggi che rendono la loro adozione strategica in numerosi contesti.

Un primo aspetto rilevante è la **privacy dei dati**: l'uso di un modello “locale” consente di elaborare internamente **informazioni sensibili** (ad esempio relative a ordini, utenti o contenuti proprietari), evitando che esse vengano esposte a servizi remoti¹⁵. A questo si lega la possibilità di **controllare e personalizzare il flusso di elaborazione**; chiunque disponga di conoscenze tecniche adeguate può **ispezionare, modificare o integrare** il codice sorgente e i pesi del modello, adattandolo a domini verticali o ottimizzandolo per esigenze specifiche (ad esempio effettuando operazioni di fine-tuning su un corpus interno).

¹⁵Specialmente considerando i rischi che comporta la condivisione di dati sensibili a terzi. È di vitale importanza considerare i rischi associati, e non dimenticare che ci sono casi di falsificazione dei risultati delle LLM [84], come mostrato in [85] R. Min, T. Pang, C. Du, Q. Liu, M. Cheng, e M. Lin, «Improving Your Model Ranking on Chatbot Arena by Vote Rigging», 2025. doi: [10.48550/arXiv.2501.17858](https://doi.org/10.48550/arXiv.2501.17858).

Un ulteriore vantaggio riguarda la **trasparenza e la replicabilità**: con i modelli open source è più facile realizzare un'audit trail dell'architettura e del comportamento di generazione, analizzando i meccanismi che portano a un certo output. Questo non solo facilita la verifica e la riduzione dei bias, ma incentiva anche una ricerca aperta e collaborativa che stimola l'innovazione e la creazione di community attive. In alcune applicazioni critiche, come quelle mediche o finanziarie, poter dimostrare con esattezza come il sistema produce le risposte è un requisito essenziale per adeguarsi a normative e standard di conformità.

Infine, dal punto di vista delle licenze e della sostenibilità nel lungo periodo, le soluzioni open offrono una maggiore flessibilità d'uso e spesso non impongono canoni basati sul volume di richieste. Ciò **abbatte potenzialmente i costi operativi**, permettendo di sperimentare e adottare la tecnologia su larga scala senza vincoli commerciali stringenti.

Considerati insieme, questi elementi fanno sì che, pur non potendo ancora competere con GPT in termini di prestazioni pure, i modelli open source incarnino un'opzione sempre più solida per chi cerca indipendenza, controllo e trasparenza, costituendo una componente essenziale dell'ecosistema NLG moderno.

Nella prossima sezione vedremo come tutte le componenti finora presentate sono state integrate in un sistema di dialogo completo.

4 Ingegnerizzazione

Al momento della sua concezione, questa tesi doveva vertere sulla sola ricerca e sviluppo di un «compilatore» che fosse in grado di assemblare una configurazione per un chatbot AIML, partendo dai dati di un automa a stati finiti.

L'idea era che, una volta sviluppate le basi, il compilatore per NoVAGraphS fosse adattabile con sufficiente facilità ad altri domini non collegati ai FSA.

Fin dalle prime sperimentazioni del prototipo di compilatore tuttavia ci accorgemmo di tre principali problematiche da risolvere, già discusse nella Sezione 2.1.2:

1. AIML non offre metodi al di fuori del **pattern matching** per identificare la regola di interazione che deve essere attivata. L'unica possibilità in questo caso sarebbe lo studio delle possibili variazioni linguistiche di una certa interazione per determinare una espressione regolare in grado di includere il maggior numero di variazioni possibili. È evidente tuttavia come questa opzione sia estremamente dispendiosa e complessa da un punto di vista attuativo e progettuale;
2. Le **risposte fornite** sono circoscritte all'insieme predisposto al momento della progettazione dell'chatbot. Dover prevedere ed elencare multiple forme della risposta, per ogni possibile dato richiesto, è un'operazione a dir poco monumentale, se non persino un po' folle e raffigurerebbe l'anti-pattern per eccellenza, condannando il file alla totale impossibilità di manutenzione;
3. **Codificare i dati** di una struttura informativa per poterli poi interrogare non è una funzionalità prevista da AIML. Questo è il motivo per cui la precedente problematica è di difficile risoluzione. Sfortunatamente AIML non predispone modi per interagire con dati esterni; averli permetterebbe di prevedere una sola risposta in grado di reperire i dati richiesti e restituirli all'utente, rimuovendo la necessità di duplicare molteplici volte le stesse risposte con la sola variazione dei dati in output.

Esiste la possibilità di integrare servizi esterni tramite il tag `<sraix>` [7]; questa opzione tuttavia non dovrebbe essere l'unico modo per poter riconoscere interazioni non previste, o interrogare dati esterni: usarlo per risolvere ogni nostro problema, effettuando chiamate ad API esterne, dimostra come non sia adeguato per gli obiettivi di NoVAGraphS.

A questo punto, una volta determinate le migliori apportabili, davanti a noi vi erano due vie percorribili:

- a. Estendere uno degli interpreti AIML, come `aiml-high` [86] (implementato in JavaScript ECMAScript 5 e non più mantenuto) o `python-aiml` [87] per aggiungere le funzionalità necessarie per NoVAGraphS;
- b. Sviluppare una nuova soluzione che alla base abbia le tre problematiche come punti saldi da supportare in primo luogo.

Considerando l'attuale stato del panorama di AIML open source [86], [87], e valutando i benefici che l'introduzione di nuove tecniche avrebbero potuto portare, ho deciso di progettare un nuovo sistema in grado di risolvere le problematiche sollevate. In questo modo:

1. Invece del pattern matching si può *anche* utilizzare un **classificatore neurale** per determinare la classe d'interazione dell'utente. Chiaramente anche in questo caso avremo da raccogliere un certo numero di domande per ogni classe di interazione per poterle

riconoscere con adeguata affidabilità. Il vantaggio risiede nel fatto che, una volta determinate le classi di interazione, sarà sufficiente utilizzare un algoritmo di addestramento (fine-tuning se si usa un Transformer) per ottenere un modello pronto all'uso.

Oltre alla ridotta necessità di lavoro umano al di fuori della classificazione iniziale, è sempre possibile introdurre nuove classi semplicemente usando una tecnica di transfer learning, di cui il fine-tuning fa parte [88];

2. Per le risposte, è possibile continuare ad utilizzare un insieme di frasi pre-costruite (template); alternativamente si può lasciare la composizione della risposta a una LLM usando dei prompt ad-hoc per ogni possibile interazione, così da massimizzare la qualità della risposta generata.
3. L'interazione coi dati (o API esterne) è lasciata a moduli di retrieval estensibili, in modo da poter personalizzare il sistema per soddisfare le necessità del dominio di applicazione.

4.1 Panoramica del sistema

L'intero sistema è diviso in due sezioni: il **compilatore** e il **runner**, che verranno approfonditi nelle sezioni successive. Possiamo definirli nel modo seguente:

Il **Compilatore** permette ai botmaster di progettare in modo dichiarativo i modelli necessari per poter interagire con l'utente nel dominio di applicazione.

Consideriamo come esempio il dominio degli automi a stati finiti: indicativamente dovremo saper rispondere a domande sugli stati dell'automa, e le transizioni che li collegano. Dovranno quindi essere raccolti degli esempi delle interazioni che saranno poi usati per addestrare un modello di classificazione, come discusso nella Sezione 2.2. Allo stesso modo la costruzione di un sistema di NER sarà delegata al compilatore.

In questo modo, le difficoltà maggiori nella preparazione dei modelli (che ho anche personalmente riscontrato durante la ricerca) sono astratte, e permettono ai botmaster di concentrarsi sul design del chatbot.

I dati utilizzati a runtime per i modelli e per il retrieval sono infine raggruppati tutti assieme per permettere un deploy più indolore possibile del **Runner**, che si occupa invece di utilizzare ciò che il compilatore ha preparato in anticipo per gestire le interazioni con gli utenti.

Il modo in cui un certo chatbot funzioni, quindi determinare ad esempio il flusso di decisione dell'interazione, è un compito lasciato al botmaster.

Da grandi poteri derivano grandi responsabilità, potremmo anche dire...

Se le funzionalità del compilatore o del runner non dovessero soddisfare qualche necessità particolare, è sempre lasciata totale libertà di aggiungerne di nuove partendo da quelle di base: per questo motivo, il linguaggio scelto per l'implementazione sarà Python, data la sua diffusione capillare [89] e la grande flessibilità e facilità d'uso.

Per mostrare le varie componenti del sistema, sarà utilizzata una *configurazione giocattolo*, composta da poche interazioni accettate dal chatbot, usando lo stesso automa visibile nel Diagramma 3 della Sezione 3.3.2 come dati. Questo ci permetterà di vedere al meglio tutte le funzionalità attualmente implementate.

4.2 Compilatore

Come già anticipato, il compilatore si occupa della preparazione di tutte le risorse che poi saranno necessarie a tempo di runtime: verifica dei dati di addestramento, costruzione dei modelli neurali e raggruppamento delle risorse locali, principalmente.

Potremmo pensare di lasciare i suddetti compiti direttamente al runner: questo comporterebbe tuttavia un tempo di avvio nettamente maggiore. Non scordiamo infatti che l'addestramento di un modello neurale può richiedere ore, se non giorni; il fine-tuning può ridurre i tempi di attesa, che non saranno comunque immediati (si veda come esempio il Grafico 4 della Sezione 2.2.8).

Questo andrebbe contro il bisogno di essere pronti a rispondere ad un utente il più rapidamente possibile: ad oggi ci si aspetta che i servizi web abbiano tempi di risposta pressoché immediati. Secondo le ricerche di F. Nah [90], il tempo di attesa accettato da un utente per il caricamento di una pagina web si aggira intorno ai 2 secondi. Possiamo prevedere aspettative simili anche per il nostro sistema.

4.2.1 Pipeline

Dovendoci occupare della preparazione potenzialmente di più modelli per un singolo chatbot, è utile poter formalizzare il processo che il compilatore dovrà seguire:

1. In primo luogo è necessario **caricare i dati per l'addestramento**: questo può richiedere anche la partizione dei dati in funzione del task. Per citare un esempio, la divisione è essenziale nel nostro caso d'uso d'esempio, dove abbiamo sia etichette per la classe principale, sia per la classe secondaria (Sezione 2.2.3).
2. Per ogni modello previsto da compilare, procediamo a effettuare il fine-tuning o il training (se NER).
3. Raggruppiamo tutti i dati in modo da renderli pronti per il Runner.




Diagramma 5: Flusso semplificato delle operazioni di compilazione.

Come è possibile prevedere, è comunque necessario un file di configurazione per poter istruire il sistema alla preparazione dei dataset. È stato scelto il formato YAML [91] che, grazie ad una

sintassi molto semplice, permette di codificare con grande potenza tutte le informazioni della nostra serie di pipeline:

```
models:
  - name: "global_subject_classifier"
    type: classification
    steps:
      - type: load_csv
        name: data
        path: "./multitask_training/data_cleaned_manual_combined.csv"
        label_columns: "Global Subject"
      - type: train_model
        name: training
        dataframe: data.dataframe
        pretrained_model: "google/electra-small-discriminator"
        examples_column: "Question"
        labels_column: "Global Subject"
        train_epochs: 20

  - name: "question_intent_classifiers"
    type: classification
    steps:
      - type: load_csv
        name: data
        path: "./multitask_training/data_cleaned_manual_combined.csv"
        label_columns: ["Global Subject", "Question Intent"]
      - type: split_data
        name: split
        dataframe: data.dataframe
        on_column: "Global Subject"
        for_each:
          - type: train_model
            name: training
            dataframe: split.dataframe
            pretrained_model: "google/electra-small-discriminator"
            examples_column: "Question"
            labels_column: "Question Intent"
            resulting_model_name: "question_intent_{on_column}"

  - name: "question_entities_recognition"
    type: ner
    steps:
      - type: ner_spacy
        name: ner_training
        language: "en"
        training_data_path: "./ner_training/corpus/ner_labels.jsonl"
        training_device: "gpu"
        resulting_model_name: "ner_trained_model"
```

Snippet 21: Estratto della configurazione che descrive come devono essere addestrati i modelli del chatbot.

Sotto la chiave `models` troviamo una lista di modelli, ciascuno con una **sequenza** di operazioni che devono essere svolte per poter preparare il proprio modello con successo. Nel Diagramma 6 è possibile vedere in dettaglio la struttura delle classi e delle proprietà utilizzate per la compilazione.

È essenziale notare come ogni `Model` contenga una lista di `Step`, una **classe astratta**. L'astrazione permette alla Classe 3 (`ModelPilepileCompiler`), che esegue gli `Step` di essere *implementation agnostic*, permettendo quindi l'introduzione di nuove classi riducendo al minimo l'accoppiamento delle funzionalità [92].




Diagramma 6: Class Diagram raffigurante le classi e proprietà utilizzate per la compilazione.

Osserviamo più nel dettaglio:

- Il modello `global_subject_classifier` richiede due operazioni: `load_csv` e `train_model`.
 1. `load_csv` carica i dati da un file CSV, specificando quali colonne contengono le etichette per poter effettuare delle operazioni di pre-processing volte a preparare i dati per l'addestramento.
 2. `train_model` effettua il fine-tuning di un modello pre-addestrato, specificando quali colonne del dataframe contengono gli esempi e le etichette da usare per l'addestramento, e quanti cicli di addestramento effettuare.
- Il modello `question_intent_classifiers` prevede tre operazioni: `load_csv`, `split_data` e `train_model`.
 1. `load_csv` è analogo a prima.
 2. `split_data` suddivide i dati in base ad una colonna specificata, e per ogni valore unico di quella colonna esegue una ulteriore sequenza di operazioni. In questo caso l'unica operazione prevista è la seguente;

3. `train_model` è analogo a prima, con l'aggiunta di un parametro `resulting_model_name` che permette di specificare il nome del modello addestrato tramite un template.
- Il modello `question_entities_recognition` ha una sola operazione: `ner_spacy`, che addestra un modello di NER usando il framework Spacy, specificando il percorso del corpus di addestramento e il dispositivo su cui addestrare il modello.

La peculiarità del sistema è la gestione degli step: ogni passaggio può avere un output che può essere usato come input per un altro step, in quello che è stato definito come un *contesto di esecuzione*. Questo permette di creare pipeline dalla grande potenza espressiva, conservando comunque la semplicità di una configurazione YAML.

Durante la compilazione, la classe `ModelPipelineCompiler` presentata nella Classe 3 segue tre passaggi essenziali:

1. Fa verificare allo step attuale che i suoi requisiti per poter portare a termine l'esecuzione siano soddisfatti (`step.resolve_requirements(context)`). In più, la verifica restituisce tutti gli elementi necessari per l'effettiva esecuzione. Un esempio del metodo di risoluzione è presentato nello Snippet 22;

```
def resolve_requirements(self, context: dict[str, dict[str, Any]]) -> dict[str, Any]:
    context = super().resolve_requirements(context)

    init_spacy_device(self.training_device)

    if not self.training_data_path.exists():
        raise StepExecutionError(f"Training data missing at '{self.training_data_path}'")

    return context
```

Snippet 22: Funzione di risoluzione dei requisiti, estratta dalla classe per l'addestramento con SpaCy

2. Esegue l'effettivo step (`step.execute(retrieved_inputs, context)`): se è un caricamento di dati, li inserisce nel `context`, se è un addestramento, esegue le rispettive funzioni di fine-tuning o training, ecc.
3. Ultimo passo, non meno importante, è la verifica dell'effettivo successo e conclusione dello step (`step.verify_execution(execution_results)`). Un *sanity check* è molto importante per assicurarci di aver prodotto dati che non possano invalidare l'intera pipeline.

Dopo l'esecuzione del passo 3, i risultati dello step sono salvati nel dizionario `context`, rendendoli così disponibili agli altri step se mai dovessero averne bisogno. Questo è il motivo per cui ogni step di un modello necessita di un nome univoco: il fine-tuning ad esempio, richiedendo un dataframe, potrà specificare di voler utilizzare i dati del passaggio di caricamento da CSV (`dataframe: data.dataframe` dell'esempio nello Snippet 21).


```

class ModelPipelineCompiler:
    def __init__(self, model: Model, config: CompilerConfigV2):
        """
        Initialize the runner with a validated pipeline configuration.
        """
        self.model = model
        self.config = config

    def run(self, config_path: Path, artifacts_dir: Path):
        """
        Run the pipeline, executing its steps in sequence.
        """

        if self.model.disabled:
            print(f"Skipping disabled model '{self.model.name}'")
            return

        print(f"Running pipeline '{self.model.name}'")

        # Shared context for intermediate outputs
        context: dict[str, dict[str, object]] = {
            'model_metadata': self.model.model_dump(exclude={'steps'}),
            'config': self.config.model_dump(exclude={'models'}),
            'config_path': config_path,
            'artifacts_dir': artifacts_dir,
            'compilation_start_time': datetime.now().strftime('%Y-%m-%d %H:%M:%S')
        }

        step: Step
        for step in self.model.steps:
            try:
                retrieved_inputs = step.resolve_requirements(context)
                execution_results = step.execute(retrieved_inputs, context)
                checked_outputs = step.verify_execution(execution_results)

                context[step.name] = checked_outputs
            except StepExecutionError as e:
                print(f"Error executing step '{step.name}': {e}")
                raise

```

Classe 3: La classe adibita alla gestione del context durante la compilazione di ogni modello.

4.3 Runner

Una volta che le preparazioni con la compilazione sono state completate, abbiamo tutto il necessario per effettivamente eseguire il chatbot. Compiler e Runner sono due applicativi separati, ma il file di configurazione resta lo stesso. Assieme al file specifico del chatbot, è fornito al Runner una seconda configurazione che indica dove individuare gli **Artefatti** della compilazione, quali acceleratori di calcolo (GPU) utilizzare, e le potenziali chiavi private per l'interazione con API esterne.

Nel file specifico del chatbot, sotto la chiave `flows` sono definiti i multipli flussi di interazione con l'utente. Al momento dell'avvio del Runner, tutti i flow vengono scanditi per identificare se vi sono errori (sezioni inaccessibili, loop, ecc.), e successivamente vengono anche identificate le risorse effettivamente necessarie per l'esecuzione del chatbot.

4.3.1 Resource Dependency Discovery

Questa serie di **preflight checks** sono essenziali per evitare problemi a runtime, cercando di minimizzare il rischio che l'esperienza dell'utente sia interrotta durante le interazioni.

Il processo di **Resource Dependency Discovery** si basa sull'implementazione da parte di ogni `RunnerStep` (che compongono i `flow`) di un `ResourceDiscoveryMixin` (Classe 4).

Un Mixin [93] è un pattern di programmazione orientata agli oggetti che consente di “mescolare” funzionalità comuni in diverse classi senza dover ricorrere all’ereditarietà classica. In pratica, un mixin è una classe o un modulo che contiene metodi e attributi pensati per essere riutilizzati da altre classi.

Immaginiamo di avere più classi che necessitano di comportamenti simili, ad esempio il logging o la validazione dei dati: invece di ripetere lo stesso codice in ciascuna classe o creare una gerarchia complessa che centralizza tali funzioni, si crea un mixin che implementa questa funzionalità e poi lo si “inserisce” nelle classi interessate. Questo approccio **favorisce la composizione rispetto all’ereditarietà tradizionale**, permettendo una maggiore flessibilità e una migliore riusabilità del codice. Molto spesso è suggerito nel contesto del motto “*prefer composition over inheritance*”¹⁶ [94], [95].

Va notato che l’utilizzo dei mixin richiede cautela: se non gestiti correttamente, possono generare conflitti (ad esempio, metodi con lo stesso nome provenienti da mixin diversi) e rendere il codice meno trasparente. In linguaggi come Python o Ruby, i mixin sono comunemente usati proprio grazie al supporto per l’ereditarietà multipla o ai moduli, che facilitano l’inclusione di funzionalità extra nelle classi.

In questo caso, il Mixin è una interfaccia che impone di implementare un metodo `discover_resources_to_load` che restituisce un dizionario con le risorse necessarie per l’esecuzione dello step.

```
class ResourceDiscoveryMixin(ABC):
    @abstractmethod
    def discover_resources_to_load(self) -> set[Resource]:
        """
        An abstract method to discover resources to load.
        Different classes can implement this method based on their specific logic.
        """
        pass
```

Classe 4: Mixin per la scoperta delle risorse necessarie per l’esecuzione di uno step.

Nelle risorse possono anche essere specificati file da caricare, modelli da inizializzare, e così via. Questo permette al Runner di caricare in memoria tutte le risorse necessarie per l’esecuzione del chatbot, e di poterle passare agli step in modo trasparente e immediato.

4.3.2 Flow

Un `Flow` è una sequenza di `RunnerStep` che rappresenta un percorso di interazione con l’utente. Possono essere utilizzati come analoghi dei `Topic` di AIML [7], o come sequenze di interazioni che l’utente può intraprendere con il chatbot.

Ogni `RunnerStep` rappresenta un’azione che il chatbot o l’utente deve intraprendere per poter procedere con l’interazione. Ad esempio, un `RunnerStep` potrebbe essere un’interazione con un modello di classificazione per determinare la classe di una domanda, o un’interazione con un modello di NER per estrarre le entità da una domanda.

¹⁶“preferire la composizione all’ereditarietà”

Nell'esempio del Diagramma 7, possiamo vedere come un **Flow** possa essere composto da più **RunnerStep**, ognuno con un compito specifico.

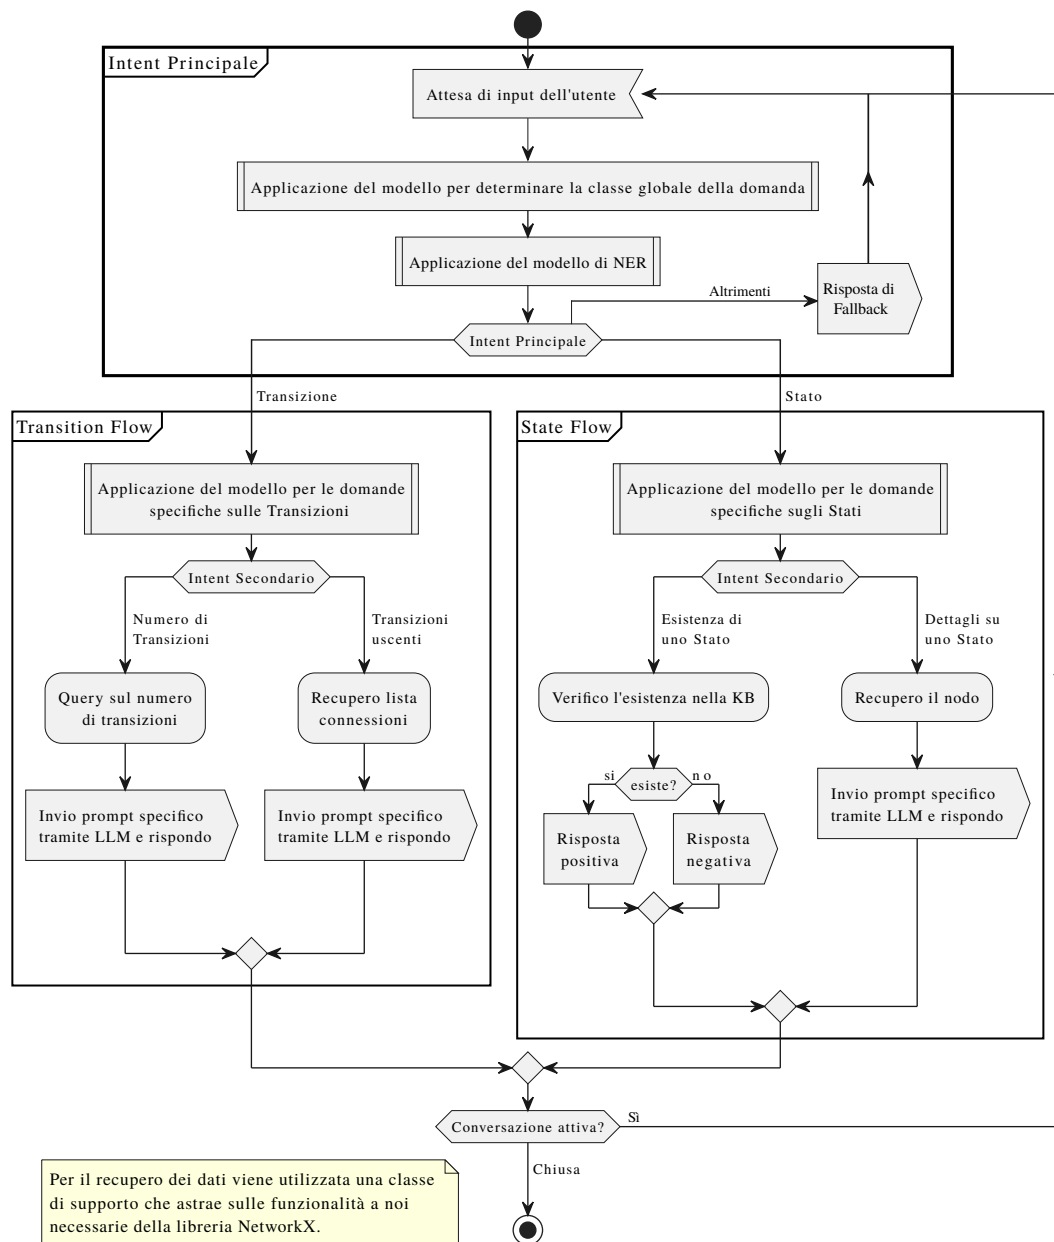


Diagramma 7: Diagramma semplificato di un chatbot in grado di fornire informazioni basilari riguardo un automa a stati finiti.

Come vediamo, sono presenti tre **Flow** distinti:

- Il primo, denominato “Intent Principale”, si occupa di:
 1. Lasciare il controllo all’utente che dovrà inviare un messaggio;
 2. Determinare la classe d’interazione generale dell messaggio utente;
 3. Estrarre le entità presenti nella domanda.

Una volta effettuate queste tre azioni, l'ultima decisione è un analogo allo `switch` dei linguaggi di programmazione, che permette di determinare quale `Flow` eseguire successivamente valutando una condizione o effettuando pattern matching. È anche predisposto un `Fallback Flow` che si occupa di gestire le interazioni non previste.

- Il secondo `Flow`, “Transition Flow”, si preoccupa prima di determinare la classe d'interazione specifica che l'utente ha inviato; successivamente instrada l'esecuzione verso una delle due query possibili, in base alla classe d'interazione. Le due query utilizzano uno `RunnerStep` personalizzato che permette di interrogare il grafo rappresentante l'automa sfruttando le API di NetworkX. Recupera le informazioni, il flow comporrà la risposta all'utente con un prompt dedicato; questo sarà inviato ad una LLM (locale o remota) e infine inoltrato all'utente.
- In modo simile al precedente `Flow`, “State Flow” si occupa di determinare la classe d'interazione specifica dell'utente, e di interrogare il grafo per recuperare le informazioni richieste riguardo gli stati dell'automa. La particolarità in questo caso è che nel caso della verifica dell'esistenza di uno stato: la risposta non sarà generata da una LLM ma verrà estratta da un insieme predefinito.

In ogni caso, alla fine di un flow, se non è specificato dove proseguire ulteriormente, il controllo viene restituito al flow iniziale. Ogni `Flow` deve specificare uno `start_step`, che rappresenta il primo step da eseguire all'avvio del flow.

Ogni step invece, può specificare uno `next_step` e uno `next_flow` che rappresentano rispettivamente il prossimo step da eseguire e il prossimo flow da eseguire. Queste due opzioni sono utili per implementare il controllo del flusso di esecuzione, e permettono di creare interazioni complesse con l'utente. Se non viene specificato il prossimo step, o il prossimo flow, il controllo viene restituito al flow iniziale. La logica di branching effettuata è mostrata nello Snippet 23.

```
starting_flow = flows.get("main")

current_flow = starting_flow
current_step = starting_flow.steps.get(current_flow.start_step)

context = {}

while current_step is not None:
    next_step, next_flow = current_step.execute(context)

    if next_flow is not None:
        current_flow = config.flows[next_flow]

        if next_step is not None:
            current_step = current_flow.steps[next_step]
        else:
            current_step = current_flow.steps.get(current_flow.start_step)
    else:
        if next_step is not None:
            current_step = current_flow.steps[next_step]
        else:
            current_step = current_flow.steps.get(current_flow.start_step)
```

Snippet 23: Ciclo di esecuzione dei `Flow` nel Runner.

Un ultimo punto da considerare è la gestione del contesto. Il contesto è contenuto in un dizionario che raccoglie tutte le informazioni necessarie per l'esecuzione del chatbot, e viene passato

ad ogni step durante l'esecuzione. Questo permette di mantenere lo stato dell'interazione con l'utente, e di condividere informazioni tra i vari step, che possono effettuare manipolazioni sui dati.

Per lasciare la massima libertà possibile, è stato deciso di utilizzare la libreria `Asteval` [96], che permette di eseguire codice Python fornito all'interno di stringhe. La libreria è estremamente flessibile e permette di eseguire codice Python in modo sicuro, evitando l'esecuzione di codice dannoso o erraneo.

Attraverso questa libreria, è possibile definire delle espressioni che verranno valutate a runtime, ad esempio per effettuare branching con la classificazione di una domanda, per interagire con i dati estratti da un modello di NER, o per interrogare una libreria esterna.

4.4 Osservazioni e sviluppi futuri

Nonostante il sistema sia stato progettato per essere il più flessibile possibile, permettendo l'implementazione di `Step` personalizzati, e astruendo allo stesso tempo le complessità maggiori quali l'utilizzo di modelli di classificazione, vi sono alcune limitazioni che il sistema comunque presenta, e che potranno essere oggetto di futuri sviluppi.

In primo luogo, l'utilizzo di `Asteval` per l'esecuzione di codice Python a runtime è molto potente, ma allo stesso tempo molto pericoloso. La libreria permette di eseguire qualsiasi codice Python fornito, e non fornisce alcun tipo di protezione contro codice dannoso o malevolo.

Una possibile soluzione potrebbe essere l'utilizzo di un sistema di sandboxing, che permetta di eseguire il codice in un ambiente controllato. `Asteval` supporta già diversi generi di controlli e limitazioni configurabili, ma in alcuni casi potrebbe essere necessario implementare verifiche più stringenti attualmente non presenti.

Bisogna anche aggiungere come, nonostante il formato YAML per la configurazione sia molto potente, durante lo sviluppo esso sia stato spinto al limite delle sue capacità. Per flow semplici, il formato è molto chiaro e leggibile, ma se si inizia a dover lavorare con espressioni python lunghe o con strutture complesse, il formato può diventare ostico e difficile da mantenere, rendendo problematica anche la comprensione del flusso di esecuzione.

Una possibile soluzione potrebbe essere l'utilizzo di un DSL (Domain Specific Language) che permetta di definire le configurazioni in modo più chiaro e conciso, e che permetta di eseguire controlli di validità in fase di scrittura. Questa opzione è stata considerata durante lo sviluppo, ma è stata scartata per motivi di complessità e ridondanza considerando altre alternative.

Un'opzione più favorevole sarebbe la conversione del sistema in una libreria Python pura, che permetta di definire le configurazioni direttamente in codice Python, sfruttando le capacità di introspezione e validazione del linguaggio. In questo modo sarebbe sufficiente implementare delle funzioni che rappresentano flow e step, abbassando la barriera all'ingresso per nuovi sviluppatori già esperti in Python.

D'altra parte, questa soluzione potrebbe rendere più complesso lo sviluppo per utenti non esperti, motivo per cui comunque il supporto al formato YAML potrebbe dover essere mante-

nuto. Bisogna tenere comunque a mente che già la scrittura di chatbot in AIML non richiede conoscenze indifferenti, anche se non si tratta direttamente di programmazione, ma comunque di una forma di scripting che implica la comprensione di concetti come la programmazione logica, la gestione di variabili e la sintassi di XML.

Una migrazione a Python puro renderebbe anche più veloce l'implementazione e, soprattutto, il testing di nuove integrazioni, aumentando la comodità per gli sviluppatori e riducendo il tempo complessivamente necessario per sviluppare nuove funzionalità.

Naturalmente la conversione del sistema in una libreria Python pura potrebbe risolvere anche il problema dell'utilizzo della libreria `ASTEVAL`, lasciando invece la libertà di fare fondamento sulle capacità di introspezione del linguaggio per eseguire controlli di validità sul codice fornito.

Inoltre, la vasta disponibilità di IDE avanzati con sistemi di completamento già largamente diffusi a livello professionale, come *PyCharm* di JetBrains o *Visual Studio Code* di Microsoft, permetterebbe di ridurre gli errori di sintassi e di semantica, e di velocizzare lo sviluppo di nuove funzionalità, senza dover implementare nuovi strumenti per la validazione delle configurazioni.

Bibliografia

- [1] TREY the Explainer, *Disabilities in Prehistory*. [Online Video]. Disponibile su: https://www.youtube.com/watch?v=t7J_oYbRfuc
- [2] J.-J. Hublin, «The prehistory of compassion», *Proceedings of the National Academy of Sciences*, vol. 106, fasc. 16, pp. 6429–6430, 2009, doi: [10.1073/pnas.0902614106](https://doi.org/10.1073/pnas.0902614106).
- [3] Michael Oliverio *et al.*, «NoVAGraphS: Towards an Accessible Educational-Oriented Dialogue System», in *Proceedings of the Second International Workshop on Artificial Intelligent Systems in Education co-located with 23rd International Conference of the Italian Association for Artificial Intelligence (AIXIA 2024)*, D. Taibi, D. Schicchi, M. Temperini, C. Limongelli, e G. Casalino, A c. di, in CEUR Workshop Proceedings, vol. 3879. CEUR-WS, 2024, pp. 1–12. [Online]. Disponibile su: <https://iris.unito.it/handle/2318/2041270>
- [4] P. F. Balestrucci, L. Anselma, C. Bernareggi, e A. Mazzei, «Building a Spoken Dialogue System for Supporting Blind People in Accessing Mathematical Expressions», in *Proceedings of the 9th Italian Conference on Computational Linguistics (CLiC-it 2023)*, F. Boschetti, G. E. Lebani, B. Magnini, e N. Novielli, A c. di, in CEUR Workshop Proceedings, vol. 3596. CEUR-WS, 2023, pp. 1–8. [Online]. Disponibile su: <https://iris.unito.it/handle/2318/1950755>
- [5] «The Loebner Prize». [Online]. Disponibile su: <https://www.ocf.berkeley.edu/~arihuang/academic/research/loebner.html>
- [6] A. M. TURING, «I.—COMPUTING MACHINERY AND INTELLIGENCE», *Mind*, vol. 59, fasc. 236, pp. 433–460, 1950, doi: [10.1093/mind/LIX.236.433](https://doi.org/10.1093/mind/LIX.236.433).
- [7] «Artificial Intelligence Markup Language». [Online]. Disponibile su: <http://www.aiml.foundation/doc.html>
- [8] R. Wallace, «The anatomy of A.L.I.C.E.», 2009, pp. 181–210. doi: [10.1007/978-1-4020-6710-5_13](https://doi.org/10.1007/978-1-4020-6710-5_13).
- [9] E. Di Nuovo, M. Sanguinetti, A. Mazzei, L. Anselma, C. Bernareggi, e P. F. Balestrucci, *NoVA-GraphS FSA User-Agent Corpus*. (marzo 2024). Zenodo. doi: [10.5281/zenodo.10822733](https://doi.org/10.5281/zenodo.10822733).
- [10] E. D. Nuovo, M. Sanguinetti, P. F. Balestrucci, L. Anselma, C. Bernareggi, e A. Mazzei, «Educational Dialogue Systems for Visually Impaired Students: Introducing a Task-Oriented User-Agent Corpus», in *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, N. Calzolari, M.-Y. Kan, V. Hoste, B. Lenci, S. Sakti, e N. Xue, A c. di, ELRA, ICCL, mag. 2024, pp. 5507–5519. [Online]. Disponibile su: <https://iris.unito.it/handle/2318/1977310>
- [11] *pandas - Python Data Analysis Library*. [Online]. Disponibile su: <https://pandas.pydata.org/>
- [12] *Ollama - LLM local runner*. [Online]. Disponibile su: <https://github.com/ollama/ollama>
- [13] «On Open-Weights Foundation Models». [Online]. Disponibile su: <https://www.ftc.gov/policy/advocacy-research/tech-at-ftc/2024/07/open-weights-foundation-models>
- [14] G. Team *et al.*, «Gemma 2: Improving Open Language Models at a Practical Size», 2024. doi: [10.48550/arXiv.2408.00118](https://doi.org/10.48550/arXiv.2408.00118).
- [15] A. Grattafiori *et al.*, «The Llama 3 Herd of Models», 2024. doi: [10.48550/arXiv.2407.21783](https://doi.org/10.48550/arXiv.2407.21783).
- [16] J. Bai *et al.*, «Qwen Technical Report», 2023. doi: [10.48550/arXiv.2309.16609](https://doi.org/10.48550/arXiv.2309.16609).
- [17] C. N. Silla e A. A. Freitas, «A survey of hierarchical classification across different application domains», *Data Mining and Knowledge Discovery*, vol. 22, fasc. 1, pp. 31–72, 2011, doi: [10.1007/s10618-010-0175-9](https://doi.org/10.1007/s10618-010-0175-9).

- [18] T. B. Brown *et al.*, «Language Models are Few-Shot Learners». 2020. doi: [10.48550/arXiv.2005.14165](https://arxiv.org/abs/2005.14165).
- [19] DeepSeek-AI *et al.*, «DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning». 2025. doi: [10.48550/arXiv.2501.12948](https://arxiv.org/abs/2501.12948).
- [20] DeepSeek-AI *et al.*, «DeepSeek-V3 Technical Report». 2025. doi: [10.48550/arXiv.2412.19437](https://arxiv.org/abs/2412.19437).
- [21] John Gruber, «Markdown». [Online]. Disponibile su: <https://daringfireball.net/projects/markdown/>
- [22] P. Rajpurkar, J. Zhang, K. Lopyrev, e P. Liang, «SQuAD: 100,000+ Questions for Machine Comprehension of Text», in *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, J. Su, K. Duh, e X. Carreras, A c. di, Association for Computational Linguistics, nov. 2016, pp. 2383–2392. doi: [10.18653/v1/D16-1264](https://arxiv.org/abs/18653/v1/D16-1264).
- [23] P. Rajpurkar, R. Jia, e P. Liang, «Know What You Don't Know: Unanswerable Questions for SQuAD», in *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, I. Gurevych e Y. Miyao, A c. di, Association for Computational Linguistics, lug. 2018, pp. 784–789. doi: [10.18653/v1/P18-2124](https://arxiv.org/abs/18653/v1/P18-2124).
- [24] Cameron Wolfe, «Decoder-Only Transformers: The Workhorse of Generative LLMs». [Online]. Disponibile su: <https://cameronrwolfe.substack.com/p/decoder-only-transformers-the-workhorse>
- [25] J. Devlin, M.-W. Chang, K. Lee, e K. Toutanova, «BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding». 2019. doi: [10.48550/arXiv.1810.04805](https://arxiv.org/abs/1810.04805).
- [26] A. Vaswani *et al.*, «Attention Is All You Need». 2023. doi: [10.48550/arXiv.1706.03762](https://arxiv.org/abs/1706.03762).
- [27] T. Wolf *et al.*, «HuggingFace's Transformers: State-of-the-art Natural Language Processing», 2020. doi: [10.48550/arXiv.1910.03771](https://arxiv.org/abs/1910.03771).
- [28] «GNU General Public License». [Online]. Disponibile su: <http://www.gnu.org/licenses/gpl.html>
- [29] R. Stallman, *Free software free society: selected essays of Richard M. Stallman*, 3rd ed. Free Software Foundation, 2015. [Online]. Disponibile su: <https://www.gnu.org/doc/fsfs3-hardcover.pdf>
- [30] J. Opitz, «A Closer Look at Classification Evaluation Metrics and a Critical Reflection of Common Evaluation Practice», *Transactions of the Association for Computational Linguistics*, vol. 12, pp. 820–836, 2024, doi: [10.1162/tac1_a_00675](https://arxiv.org/abs/10.1162/tac1_a_00675).
- [31] M. Mosbach, M. Andriushchenko, e D. Klakow, «On the Stability of Fine-tuning BERT: Misconceptions, Explanations, and Strong Baselines», 2021. doi: [10.48550/arXiv.2006.04884](https://arxiv.org/abs/2006.04884).
- [32] K. Clark, M.-T. Luong, Q. V. Le, e C. D. Manning, «ELECTRA: Pre-training text encoders as discriminators rather than generators». [Online]. Disponibile su: <https://openreview.net/pdf?id=r1xMH1BtvB>
- [33] *Bert uncased model by Google*. [Online]. Disponibile su: <https://huggingface.co/google-bert/bert-base-uncased>
- [34] *Distilbert base model*. [Online]. Disponibile su: <https://huggingface.co/distilbert/distilbert-base-uncased>
- [35] G. Hinton, O. Vinyals, e J. Dean, «Distilling the Knowledge in a Neural Network», 2015. doi: [10.48550/arXiv.1503.02531](https://arxiv.org/abs/1503.02531).
- [36] V. Sanh, L. Debut, J. Chaumond, e T. Wolf, «DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter», 2020. doi: [10.48550/arXiv.1910.01108](https://arxiv.org/abs/1910.01108).
- [37] *MobileBERT on Huggingface*. [Online]. Disponibile su: <https://huggingface.co/google/mobilebert-uncased>

- [38] Z. Sun, H. Yu, X. Song, R. Liu, Y. Yang, e D. Zhou, «MobileBERT: a Compact Task-Agnostic BERT for Resource-Limited Devices», 2020. doi: [10.48550/arXiv.2004.02984](https://doi.org/10.48550/arXiv.2004.02984).
- [39] *Electra on Huggingface*. [Online]. Disponibile su: <https://huggingface.co/google/electra-small-discriminator>
- [40] I. J. Goodfellow *et al.*, «Generative Adversarial Networks». 2014. doi: [10.48550/arXiv.1406.2661](https://doi.org/10.48550/arXiv.1406.2661).
- [41] R. Caruana, «Multitask Learning», *Machine Learning*, vol. 28, fasc. 1, pp. 41–75, 1997, doi: [10.1023/A:1007379606734](https://doi.org/10.1023/A:1007379606734).
- [42] Sanjaye Elayattu, «Multi-task Fine-tuning with BERT». [Online]. Disponibile su: <https://web.stanford.edu/class/archive/cs/cs224n/cs224n.1234/final-reports/final-report-169425270.pdf>
- [43] Jiacheng Hu e Jack Hung, «Multitasking with BERT». [Online]. Disponibile su: <https://web.stanford.edu/class/archive/cs/cs224n/cs224n.1234/final-reports/final-report-169989122.pdf>
- [44] F. Pedregosa *et al.*, «Scikit-learn: Machine Learning in Python», 2018. doi: [10.48550/arXiv.1201.0490](https://doi.org/10.48550/arXiv.1201.0490).
- [45] R. Grishman e B. Sundheim, «Message Understanding Conference-6: a brief history», in *Proceedings of the 16th Conference on Computational Linguistics - Volume 1*, in COLING '96. Association for Computational Linguistics, 1996, pp. 466–471. doi: [10.3115/992628.992709](https://doi.org/10.3115/992628.992709).
- [46] M. Munnangi, «A Brief History of Named Entity Recognition», 2024. doi: [10.48550/arXiv.2411.05057](https://doi.org/10.48550/arXiv.2411.05057).
- [47] J. D. Lafferty, A. McCallum, e F. C. N. Pereira, «Conditional Random Fields: Probabilistic Models for Segmenting and Labeling Sequence Data», in *Proceedings of the Eighteenth International Conference on Machine Learning*, in ICML '01. Morgan Kaufmann Publishers Inc., 2001, pp. 282–289. doi: [10.5555/645530.655813](https://doi.org/10.5555/645530.655813).
- [48] A. McCallum, D. Freitag, e F. C. N. Pereira, «Maximum Entropy Markov Models for Information Extraction and Segmentation», in *Proceedings of the Seventeenth International Conference on Machine Learning*, in ICML '00. Morgan Kaufmann Publishers Inc., 2000, pp. 591–598. doi: [10.5555/645529.658277](https://doi.org/10.5555/645529.658277).
- [49] C. Cortes e V. Vapnik, «Support-vector networks», *Machine Learning*, vol. 20, fasc. 3, pp. 273–297, set. 1995, doi: [10.1007/BF00994018](https://doi.org/10.1007/BF00994018).
- [50] R. M. Schmidt, «Recurrent Neural Networks (RNNs): A gentle Introduction and Overview». [Online]. Disponibile su: <https://arxiv.org/abs/1912.05911>
- [51] S. Hochreiter e J. Schmidhuber, «Long Short-Term Memory», *Neural Computation*, vol. 9, fasc. 8, pp. 1735–1780, 1997, doi: [10.1162/neco.1997.9.8.1735](https://doi.org/10.1162/neco.1997.9.8.1735).
- [52] Christopher Olah, «Understanding LSTM Networks». [Online]. Disponibile su: <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>
- [53] M. Polignano, M. de Gemmis, e G. Semeraro, «Comparing transformer-based NER approaches for analysing textual medical diagnoses», F. G., V. G. 6. P. University of Padova Department of Information Engineering, F. N., V. G. 6. P. University of Padova Department of Information Engineering, J. A., I. Z. 1. R. A. M. C. 5. University of Montpellier LIRMM, M. M., U. 1. C. University of Copenhagen Department of Computer Science, P. F., e F. 9.-1. V. Vienna University of Technology (TU) Institute of Information Systems Engineering, A c. di, CEUR-WS, 2021, pp. 818–833. [Online]. Disponibile su: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85113468144&partnerID=40&md5=415546a367cea8c30e30881072935304>

- [54] R. C. Schank e R. P. Abelson, «Scripts, plans, and knowledge», in *International Joint Conference on Artificial Intelligence*, 1975. [Online]. Disponibile su: <https://api.semanticscholar.org/CorpusID:264593435>
- [55] P. F. Brown *et al.*, «A statistical approach to machine translation», *Comput. Linguist.*, vol. 16, fasc. 2, pp. 79–85, giu. 1990, doi: [10.5555/92858.92860](https://doi.org/10.5555/92858.92860).
- [56] S. Louvan e B. Magnini, «Exploring Named Entity Recognition As an Auxiliary Task for Slot Filling in Conversational Language Understanding», in *Proceedings of the 2018 EMNLP Workshop SCAI: The 2nd International Workshop on Search-Oriented Conversational AI*, A. Chuklin, J. Dalton, J. Kiseleva, A. Borisov, e M. Burtsev, A c. di, Association for Computational Linguistics, ott. 2018, pp. 74–80. doi: [10.18653/v1/W18-5711](https://doi.org/10.18653/v1/W18-5711).
- [57] H. Nakayama, T. Kubo, J. Kamura, Y. Taniguchi, e X. Liang, «doccano: Text Annotation Tool for Human». [Online]. Disponibile su: <https://github.com/doccano/doccano>
- [58] M. Honnibal e I. Montani, «spaCy: Industrial-strength Natural Language Processing in Python». [Online]. Disponibile su: <https://spacy.io/>
- [59] M. Honnibal e I. Montani, «Introducing spaCy». [Online]. Disponibile su: <https://explosion.ai/blog/introducing-spacy>
- [60] «SQL Injection Prevention Cheat Sheet». [Online]. Disponibile su: https://cheatsheetseries.owasp.org/cheatsheets/SQL_Injection_Prevention_Cheat_Sheet.html
- [61] «SPARQL Query Language for RDF». [Online]. Disponibile su: <https://www.w3.org/TR/sparql11-query/>
- [62] «DBpedia». [Online]. Disponibile su: <https://wiki.dbpedia.org/>
- [63] «Wikidata». [Online]. Disponibile su: <https://www.wikidata.org/>
- [64] W3C, «RDF 1.1 XML Syntax», feb. 2014. [Online]. Disponibile su: <https://www.w3.org/TR/rdf-syntax-grammar/>
- [65] W3C, «RDF 1.1 Turtle», feb. 2025. [Online]. Disponibile su: <https://w3c.github.io/rdf-turtle/spec/>
- [66] A. Rajaraman e J. D. Ullman, «Data Mining», in *Mining of Massive Datasets*, Cambridge University Press, 2011, pp. 1–17.
- [67] S. Robertson, S. Walker, S. Jones, M. Hancock-Beaulieu, e M. Gatford, «Okapi at TREC-3.», 1994.
- [68] N. Reimers e I. Gurevych, «Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks». [Online]. Disponibile su: <https://arxiv.org/abs/1908.10084>
- [69] Z. Wang, P. Ng, R. Nallapati, e B. Xiang, «Retrieval, Re-ranking and Multi-task Learning for Knowledge-Base Question Answering», in *Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics: Main Volume*, P. Merlo, J. Tiedemann, e R. Tsarfaty, A c. di, Association for Computational Linguistics, apr. 2021, pp. 347–357. doi: [10.18653/v1/2021.eacl-main.26](https://doi.org/10.18653/v1/2021.eacl-main.26).
- [70] James Saryerwinnie, «JMESPath is a query language for JSON». [Online]. Disponibile su: <https://jmespath.org/>
- [71] Z. Kasner e O. Dušek, «Beyond Traditional Benchmarks: Analyzing Behaviors of Open LLMs on Data-to-Text Generation», in *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, L.-W. Ku, A. Martins, e V. Srikumar, A c. di, Association for Computational Linguistics, 2024, pp. 12045–12072. [Online]. Disponibile su: <https://aclanthology.org/2024.acl-long.651>

- [72] S. Yuan e M. Faerber, «Evaluating Generative Models for Graph-to-Text Generation», in *Proceedings of the 14th International Conference on Recent Advances in Natural Language Processing*, R. Mitkov e G. Angelova, A c. di, INCOMA Ltd., Shoumen, Bulgaria, set. 2023, pp. 1256–1264. [Online]. Disponibile su: <https://aclanthology.org/2023.ranlp-1.133/>
- [73] A. Axelsson e G. Skantze, «Using Large Language Models for Zero-Shot Natural Language Generation from Knowledge Graphs», 2023. [Online]. Disponibile su: <https://arxiv.org/abs/2307.07312>
- [74] M. Sun, Y. Yin, Z. Xu, J. Z. Kolter, e Z. Liu, «Idiosyncrasies in Large Language Models», 2025. [Online]. Disponibile su: <https://arxiv.org/abs/2502.12150>
- [75] «Home Assistant». [Online]. Disponibile su: <https://www.home-assistant.io/>
- [76] Sal Kimmich, «Is that LLM Actually "Open Source"? We Need to Talk About Open-Washing in AI Governance», 8 settembre 2024. [Online]. Disponibile su: <https://hackernoon.com/is-that-llm-actually-open-source-we-need-to-talk-open-washing-in-ai-governance>
- [77] *Factgenie*. [Online]. Disponibile su: <https://github.com/ufal/factgenie>
- [78] Z. Kasner, O. Platek, P. Schmidtova, S. Balloccu, e O. Dusek, «factgenie: A Framework for Span-based Evaluation of Generated Texts», in *Proceedings of the 17th International Natural Language Generation Conference: System Demonstrations*, S. Mahamood, N. L. Minh, e D. Ippolito, A c. di, Association for Computational Linguistics, 2024, pp. 13–15. [Online]. Disponibile su: <https://aclanthology.org/2024.inlg-demos.5>
- [79] J. Wang *et al.*, «Is ChatGPT a Good NLG Evaluator? A Preliminary Study», 2023. doi: [10.48550/arXiv.2303.04048](https://doi.org/10.48550/arXiv.2303.04048).
- [80] A. Sottana, B. Liang, K. Zou, e Z. Yuan, «Evaluation Metrics in the Era of GPT-4: Reliably Evaluating Large Language Models on Sequence to Sequence Tasks», in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, H. Bouamor, J. Pino, e K. Bali, A c. di, Association for Computational Linguistics, dic. 2023, pp. 8776–8788. doi: [10.18653/v1/2023.emnlp-main.543](https://doi.org/10.18653/v1/2023.emnlp-main.543).
- [81] T. Kocmi e C. Federmann, «GEMBA-MQM: Detecting Translation Quality Error Spans with GPT-4», in *Proceedings of the Eighth Conference on Machine Translation*, P. Koehn, B. Haddow, T. Kocmi, e C. Monz, A c. di, Association for Computational Linguistics, dic. 2023, pp. 768–775. doi: [10.18653/v1/2023.wmt-1.64](https://doi.org/10.18653/v1/2023.wmt-1.64).
- [82] J. Wei *et al.*, «Chain-of-Thought Prompting Elicits Reasoning in Large Language Models», 2023, doi: [10.48550/arXiv.2201.11903](https://doi.org/10.48550/arXiv.2201.11903).
- [83] A. B. Abacha *et al.*, «MEDEC: A Benchmark for Medical Error Detection and Correction in Clinical Notes», 2025. doi: [10.48550/arXiv.2412.19260](https://doi.org/10.48550/arXiv.2412.19260).
- [84] bycloud, *Cheating LLM Benchmarks Is Easier Than You Think...*, (10 marzo 2025). [Online Video]. Disponibile su: <https://www.youtube.com/watch?v=IbBEbjeVWgI>
- [85] R. Min, T. Pang, C. Du, Q. Liu, M. Cheng, e M. Lin, «Improving Your Model Ranking on Chatbot Arena by Vote Rigging», 2025. doi: [10.48550/arXiv.2501.17858](https://doi.org/10.48550/arXiv.2501.17858).
- [86] gleuch, [Online]. Disponibile su: <https://github.com/gleuch/aiml-high>
- [87] paulovn, [Online]. Disponibile su: <https://github.com/paulovn/python-aiml>
- [88] T. Strangmann, L. Purucker, J. K. H. Franke, I. Rapant, F. Ferreira, e F. Hutter, «Transfer Learning for Finetuning Large Language Models», 2024. doi: [10.48550/arXiv.2411.01195](https://doi.org/10.48550/arXiv.2411.01195).

- [89] «Python Developers Survey 2021 Results», 2021. [Online]. Disponibile su: <https://lp.jetbrains.com/python-developers-survey-2021/>
- [90] F. Nah, «A Study on Tolerable Waiting Time: How Long Are Web Users Willing to Wait?», 2003, p. 285. doi: [10.1080/01449290410001669914](https://doi.org/10.1080/01449290410001669914).
- [91] «YAML: YAML Ain't Markup Language™». [Online]. Disponibile su: <https://yaml.org/>
- [92] «Code Smells». [Online]. Disponibile su: <https://c2.com/xp/CodeSmell.html>
- [93] G. Bracha e W. Cook, «Mixin-based inheritance», in *Proceedings of the European Conference on Object-Oriented Programming on Object-Oriented Programming Systems, Languages, and Applications*, in OOPSLA/ECOOP '90. Association for Computing Machinery, 1990, pp. 303–311. doi: [10.1145/97945.97982](https://doi.org/10.1145/97945.97982).
- [94] E. Gamma, R. Helm, R. Johnson, e J. Vlissides, *Design Patterns: Elements of Reusable Object-Oriented Software*. Addison-Wesley Professional, 1994.
- [95] E. Tempero, H. Y. Yang, e J. Noble, «What Programmers Do with Inheritance in Java», in *ECOOP 2013 - Object-Oriented Programming*, G. Castagna, A. C. di, Springer Berlin Heidelberg, 2013, pp. 577–601.
- [96] lmfitt, ASTEVAL. [Online]. Disponibile su: <https://github.com/lmfitt/asteval/>